Tarea 3: Introducción a Series de Tiempo

Análisis y Ciencia de Datos

Herman Andrés Echeverría Rojas
Facultad de Ingeniería, Universidad del Istmo de Guatemala

18 de octubre de 2026

Resumen

Este documento acompaña al repositorio `https://github.com/HermanEcheverria/Series-de-Tiempo`. Todas las figuras y tablas que aparecen aquí las generan los scripts del repositorio a partir del archivo original `Online Retail.xlsx` y de las semillas documentadas en el código.

Índice

1. Parte 0: procesos simulados **2**
1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria 2
1.2. Inciso 0.2: simulación del AR(1) 3
1.3. Inciso 0.3: lo que dice la tabla 4
1.4. Inciso 0.4: las dos razones para reprobar 4
1.5. Inciso 0.5: la prueba que sí ve 6

1. Parte 0: procesos simulados

Antes de tocar datos reales conviene ver cómo se comportan la ACF y las pruebas de ruido blanco en procesos donde la respuesta es conocida. Todo lo de esta sección lo produce `parte0.py`, con las semillas de `semillas.py`; las funciones r_k, Ljung–Box y el estimado OLS de ϕ están implementadas a mano en `series.py` y son las mismas que se usan con la serie de ventas en las Partes 3 y 4.

1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria

Sea $Y_t = c + \phi Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, $|\phi| < 1$, y supongamos que el proceso es débilmente estacionario: $E[Y_t] = \mu$ y $\text{Var}(Y_t) = \gamma_0$ para todo t.

Media. Tomando esperanza en ambos lados y usando $E[\varepsilon_t] = 0$:

$$\mu = E[Y_t] = c + \phi\, E[Y_{t-1}] + E[\varepsilon_t] = c + \phi\mu \quad \Longrightarrow \quad \mu(1-\phi) = c \quad \Longrightarrow \quad E[Y_t] = \frac{c}{1-\phi}.$$

La división es válida porque $|\phi| < 1$ implica $\phi \neq 1$.

Varianza. Y_{t-1} depende solo de $\varepsilon_{t-1}, \varepsilon_{t-2}, \ldots$, así que es independiente de ε_t y la covarianza entre ambos es cero. La constante c no aporta varianza. Entonces

$$\gamma_0 = \text{Var}(c + \phi Y_{t-1} + \varepsilon_t) = \phi^2\, \text{Var}(Y_{t-1}) + \text{Var}(\varepsilon_t) + 2\phi\, \text{Cov}(Y_{t-1}, \varepsilon_t) = \phi^2 \gamma_0 + \sigma^2,$$

donde se usó $\text{Var}(Y_{t-1}) = \text{Var}(Y_t) = \gamma_0$. Despejando,

$$\text{Var}(Y_t) = \gamma_0 = \frac{\sigma^2}{1-\phi^2},$$

que es positiva y finita justamente porque $\phi^2 < 1$.

Autocorrelación. Para $k \geq 1$, Y_{t-k} depende solo de choques anteriores a $t-k+1$, así que $\text{Cov}(\varepsilon_t, Y_{t-k}) = 0$ y la constante no covaría con nada:

$$\gamma_k = \text{Cov}(Y_t, Y_{t-k}) = \text{Cov}(c + \phi Y_{t-1} + \varepsilon_t,\ Y_{t-k}) = \phi\ \text{Cov}(Y_{t-1}, Y_{t-k}) = \phi\, \gamma_{k-1}.$$

El último paso usa la estacionariedad: la covarianza entre Y_{t-1} y Y_{t-k} solo depende de su separación, $k-1$. Iterando la recursión desde γ_0 se obtiene $\gamma_k = \phi^k \gamma_0$, y por lo tanto

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k.$$

Caminata aleatoria. Con $\phi = 1$, $c = 0$ y $Y_0 = 0$, sustituyendo hacia atrás,

$$Y_t = Y_{t-1} + \varepsilon_t = Y_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \cdots = Y_0 + \sum_{i=1}^{t} \varepsilon_i = \sum_{i=1}^{t} \varepsilon_i.$$

Los ε_i son independientes, así que la varianza de la suma es la suma de las varianzas:

$$\text{Var}(Y_t) = \sum_{i=1}^{t} \text{Var}(\varepsilon_i) = t\sigma^2.$$

La media sí es constante ($E[Y_t] = 0$), pero la varianza crece linealmente con t: depende del momento en que se observa, y eso viola directamente la condición $\text{Var}(Y_t) = \sigma^2$ para todo t de la estacionariedad débil. Dicho de otra forma, la fórmula $\sigma^2/(1-\phi^2)$ explota cuando $\phi \to 1$: no existe una varianza estacionaria a la cual converger. Tampoco la autocorrelación es función solo del rezago: $\text{Corr}(Y_t, Y_{t-k}) = \sqrt{(t-k)/t}$, que depende de t.

1.2. Inciso 0.2: simulación del AR(1)

La función `simular_ar1` genera $200 + 300$ pasos de un AR(1) con $c = 0$ y $\sigma = 1$ a partir de $Y_0 = 0$ y descarta los primeros 200. Con $|\phi| < 1$ el efecto del valor inicial decae como ϕ^t; a los 200 pasos, incluso con $\phi = 0.9$, queda $0.9^{200} \approx 7 \times 10^{-10}$ del valor inicial, así que la serie que se conserva ya está en su distribución estacionaria. Con $\phi = 1$ eso no funciona: la serie conservada es $Y_t = Y_{200} + \sum_{i=201}^{t} \varepsilon_i$, una caminata aleatoria que arranca en Y_{200} en lugar de 0, y la varianza sigue creciendo sin límite. Pero el punto de arranque no afecta a r_k: sumar una constante a toda la serie mueve también a $\bar{y}$ y deja intactas las desviaciones $y_t - \bar{y}$, que son lo único que entra en la fórmula. Por eso descartar o no los 200 pasos no cambia en nada los resultados de r_k para la caminata.

La figura 1 muestra una realización de cada proceso. Con $\phi = 0$ la serie no tiene ninguna inercia; con $\phi = 0.5$ aparecen rachas cortas; con $\phi = 0.9$ la serie pasa decenas de pasos de un mismo lado de cero, aunque siempre regresa; y con $\phi = 1$ nunca regresa: se aleja de su origen (nótese que arranca en $Y_{200} \neq 0$) y lo que en un AR estacionario serían fluctuaciones aquí parece una tendencia.

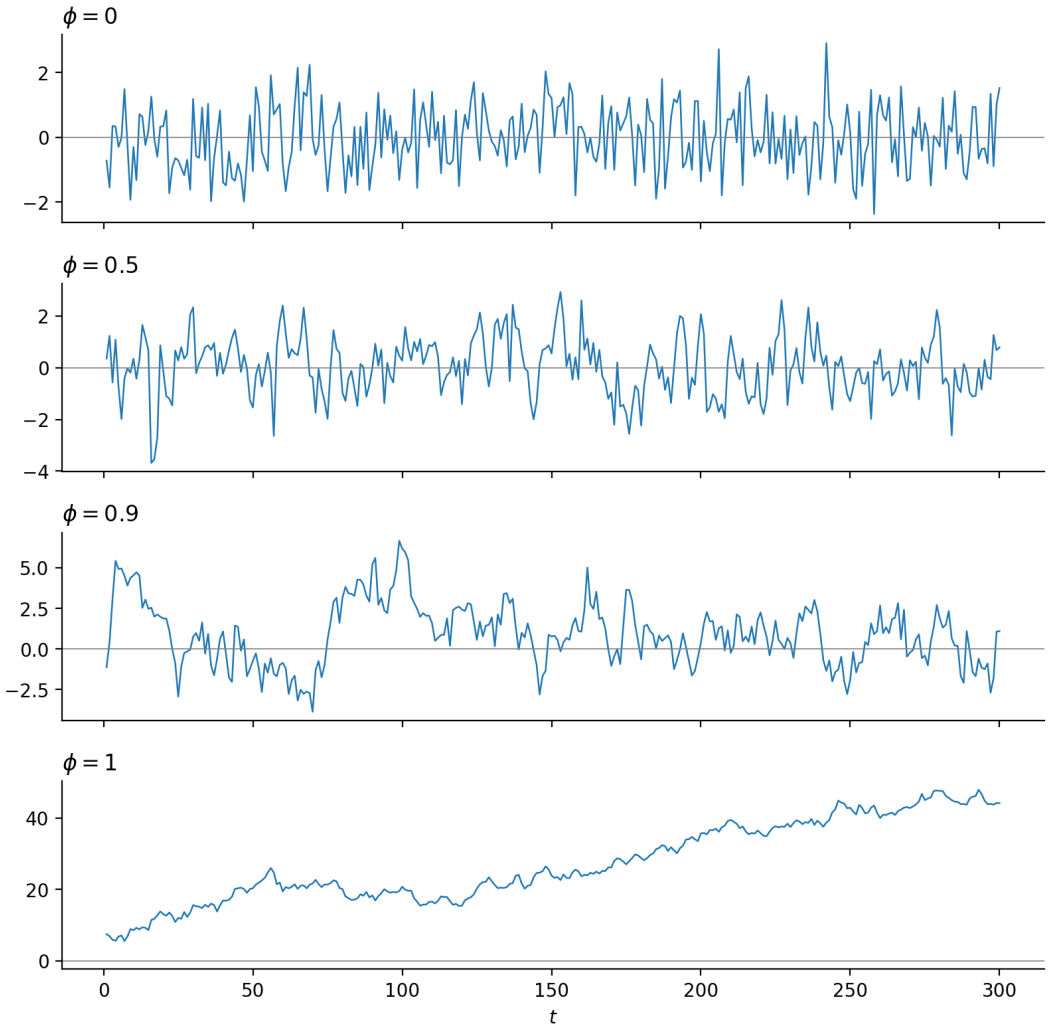


Figura 1: Una realización de 300 pasos de cada AR(1), después de descartar 200 pasos de arranque. La escala vertical cambia entre paneles: la varianza estacionaria $1/(1-\phi^2)$ vale 1, 1.33 y 5.26 para $\phi = 0, 0.5, 0.9$, y no existe para $\phi = 1$.

La tabla 1 resume las 5 000 réplicas por escenario. Cada celda es el promedio sobre réplicas y, entre paréntesis, su error estándar $s/\sqrt{5000}$. La tasa de rechazo es la fracción de réplicas en que $|r_1| > 1.96/\sqrt{300} = 0.113$, es decir, en que la prueba de retardo 1 de la Tarea 2 declara que la serie no es ruido blanco.

ϕ	$\bar{r}_1$	$\bar{r}_5$	ϕ^5	Rechazo $\lvert r_1\rvert > 1.96/\sqrt{n}$	$\bar{\hat{\phi}}_{\text{OLS}}$
0	-0.002 (0.001)	-0.003 (0.001)	0.000	0.046 (0.003)	-0.002 (0.001)
0.5	0.491 (0.001)	0.020 (0.001)	0.031	1.000 (0.000)	0.492 (0.001)
0.9	0.884 (0.000)	0.534 (0.001)	0.590	1.000 (0.000)	0.887 (0.000)
1	0.976 (0.000)	0.883 (0.001)	1.000	1.000 (0.000)	0.982 (0.000)

Tabla 1: AR(1) con $n = 300$ y 5 000 réplicas por valor de ϕ. Promedio (error estándar).

1.3. Inciso 0.3: lo que dice la tabla

Ruido blanco. Con $\phi = 0$ la prueba rechaza en el 4.62 % de las réplicas, con error estándar de 0.30 puntos: está a poco más de un error estándar del 5 % nominal, que es lo esperado. La prueba está construida precisamente para equivocarse un 5 % de las veces cuando la hipótesis nula es cierta, y aquí la nula es cierta por construcción. Que quede un poco por debajo de 5 % tiene además una razón teórica: bajo ruido blanco, $E[r_1] \approx -1/n$ y $\mathrm{Var}(r_1) \approx (n-1)/(n(n+2))$, ligeramente menor que la $1/n$ con que se dibujan las bandas, así que la tasa exacta ronda 4.9 %. El $\bar{r}_1 = -0.0023$ observado también es compatible con $-1/300 = -0.0033$.

Caminata aleatoria. La teoría estacionaria diría $\rho_5 = \phi^5 = 1$, pero el promedio de r_5 es 0.883. No es un error de simulación (el error estándar es 0.001): para una caminata aleatoria la ACF muestral está fuertemente sesgada hacia abajo. La razón es que r_k mide desviaciones respecto a $\bar{y}$, y en una caminata $\bar{y}$ es una media que no representa a ningún tramo de la serie: la serie se pasa largos periodos de un lado y luego del otro. Además el denominador usa los n términos y el numerador solo $n - k$. De hecho, la fórmula $\rho_k = \phi^k$ ni siquiera aplica, porque la derivación del inciso 0.1 supuso estacionariedad. Lo que sí se ve es la huella visual que menciona el enunciado: la ACF de la caminata baja muy despacio ($\bar{r}_1 = 0.976$, $\bar{r}_5 = 0.883$), mientras que con $\phi = 0.5$ el valor ya cayó a casi cero en el rezago 5. Para los procesos estacionarios el sesgo de r_5 también existe pero es menor: con $\phi = 0.9$ se obtiene 0.534 contra $0.9^5 = 0.590$, y con $\phi = 0.5$, 0.020 contra 0.031.

Sesgo del estimado OLS. El estimado OLS de ϕ queda sistemáticamente por debajo del valor verdadero, y el sesgo crece con ϕ: -0.002 para $\phi = 0$, -0.008 para 0.5, -0.013 para 0.9 y -0.018 para 1, todos varias veces mayores que su error estándar. Es el sesgo de Hurwicz: en una autorregresión el regresor y_{t-1} no es independiente de los errores pasados, y la aproximación clásica $E[\hat{\phi}] - \phi \approx -(1+3\phi)/n$ da -0.003, -0.008 y -0.012 para los tres casos estacionarios, muy cerca de lo observado. El estimador es consistente: el sesgo es de orden $1/n$ y desaparece cuando la muestra crece, aunque con 300 observaciones todavía se nota. En la caminata, la teoría de Dickey–Fuller dice que $\hat{\phi}$ converge todavía más rápido (a ritmo $1/n$ en vez de $1/\sqrt{n}$) pero con una distribución asimétrica, cargada hacia valores menores que 1, y eso es lo que se ve en el 0.982.

1.4. Inciso 0.4: las dos razones para reprobar

Ahora $Y_t = m_t + \varepsilon_t$ no tiene ninguna memoria: los ε_t son independientes y m_t es determinista. La figura 2 muestra una realización de cada proceso y la tabla 2 repite la tabla del inciso 0.2 agregando

$\bar{r}_7$; la primera fila es el ruido blanco del inciso anterior, como referencia.

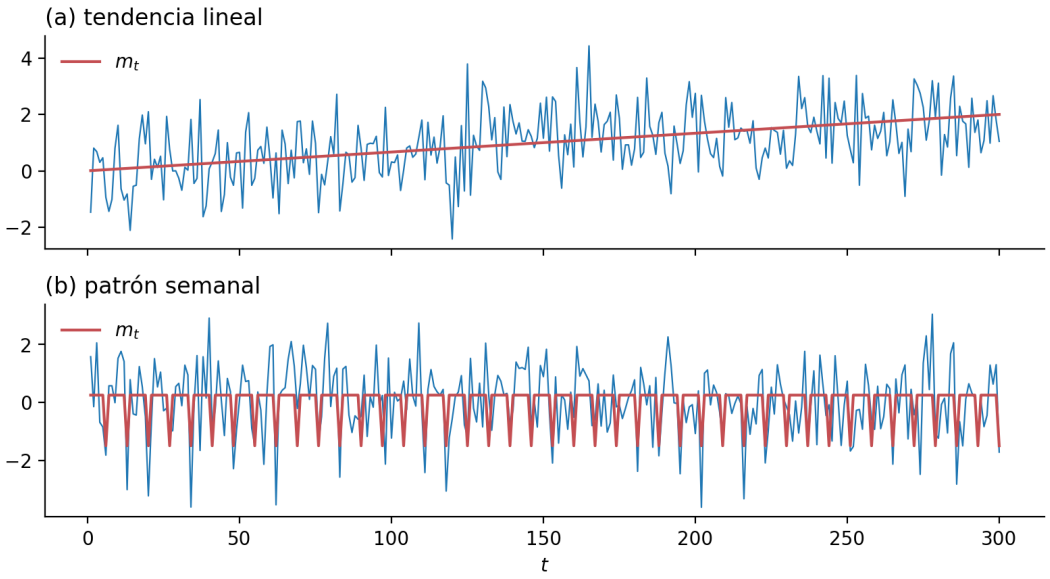


Figura 2: Procesos sin memoria con media variable. En rojo, la media m_t.

Proceso	$\bar{r}_1$	$\bar{r}_5$	$\bar{r}_7$	Rechazo r_1	$\bar{\hat{\phi}}_{\text{OLS}}$
Ruido blanco ($\phi = 0$)	-0.002 (0.001)	-0.003 (0.001)	-0.004 (0.001)	0.046 (0.003)	-0.002 (0.001)
(a) Tendencia	0.246 (0.001)	0.235 (0.001)	0.230 (0.001)	0.986 (0.002)	0.247 (0.001)
(b) Semanal	-0.047 (0.001)	-0.050 (0.001)	0.266 (0.001)	0.112 (0.004)	-0.048 (0.001)

Tabla 2: Procesos sin memoria, $n = 300$, 5 000 réplicas. Promedio (error estándar).

La tendencia reprueba sin tener memoria. La serie con tendencia rechaza la prueba de retardo 1 en el 98.6 % de las réplicas, y el OLS le asigna $\hat{\phi} \approx 0.25$ a un proceso cuyo ϕ verdadero es cero. Se puede predecir el número: m_t recorre $[0, 2]$ de forma casi uniforme, con varianza $\approx 4/12 = 1/3$, y como dos días cercanos tienen casi la misma m_t, la covarianza entre vecinos es esa misma varianza; así $r_k \approx (1/3)/(1/3 + 1) = 0.25$ para todo rezago pequeño. Eso es exactamente lo que dice la tabla: $\bar{r}_1 = 0.246$, $\bar{r}_5 = 0.235$, $\bar{r}_7 = 0.230$, una ACF que casi no decae. Es la razón (2) del enunciado: $\bar{y}$ no es la media de nadie, los días del final quedan todos por encima y los del inicio todos por debajo, y eso se ve como correlación.

El patrón semanal pasa aunque tenga estructura. La serie semanal rechaza solo en el 11.2 % de las réplicas, poco más que el ruido blanco, y su $\bar{r}_1 = -0.047$ es diminuto. De nuevo se puede calcular: sobre un ciclo de 7 días m_t tiene media 0 y varianza $(6 \cdot 0.25^2 + 1.5^2)/7 = 0.375$, pero la covarianza entre días consecutivos es solo $(5 \cdot 0.25^2 - 2 \cdot 0.375)/7 = -0.0625$, y $r_1 \approx -0.0625/1.375 = -0.045$. Toda la estructura está a distancia 7: un domingo se parece al domingo anterior, no al sábado. Por eso $\bar{r}_7 = 0.266$ (la predicción es $0.375/1.375 = 0.273$), mientras que r_1 y r_5 están cerca de cero.

Conexión con RANDU. Es el mismo fenómeno que con RANDU en la Tarea 2: RANDU pasaba las pruebas unidimensionales y de pares consecutivos y, sin embargo, sus ternas caían en solo 15 planos, porque su dependencia vivía en una combinación de los rezagos 1 y 2 que esas pruebas no miran. La prueba de retardo 1 solo puede ver estructura en el rezago 1; un proceso con la dependencia en otro lado (el rezago 7, o una combinación lineal de rezagos) la pasa sin problema. Pasar una prueba nunca demuestra independencia: solo dice que en la dirección que esa prueba mira no se encontró nada.

1.5. Inciso 0.5: la prueba que sí ve

La tabla 3 compara la tasa de rechazo de la prueba de retardo 1 con la de Ljung–Box al 5 %, con $m = 10$ (la recomendación de FPP2 sin estacionalidad) y con $m = 6 \approx \log(300) = 5.7$ (la sugerencia de Tsay). La implementación propia coincide con `statsmodels.stats.diagnostic.acorr_ljungbox` hasta el sexto decimal en el estadístico y en el valor-p; `parte0.py` lo verifica con un `assert` en una réplica de cada proceso.

Proceso	Rechazo r_1	LB $m = 10$	LB $m = 6$
Ruido blanco ($\phi = 0$)	0.046 (0.003)	0.053 (0.003)	0.053 (0.003)
(a) Tendencia	0.986 (0.002)	1.000 (0.000)	1.000 (0.000)
(b) Semanal	0.112 (0.004)	0.956 (0.003)	0.209 (0.006)

Tabla 3: Tasa de rechazo al 5 % sobre 5 000 réplicas, $n = 300$. Promedio (error estándar).

Con ruido blanco las dos versiones de Ljung–Box rechazan alrededor del 5 % (5.3 %), como deben. Con la tendencia rechazan siempre, igual que la prueba de retardo 1: ahí la estructura se ve en todos los rezagos.

El cambio está en el patrón semanal. Ljung–Box con $m = 10$ lo rechaza en el 95.6 % de las réplicas, contra el 11.2 % de la prueba de retardo 1, porque $Q(10)$ suma r_k^2 para $k = 1, \ldots, 10$ y eso incluye el $r_7 \approx 0.27$ que la prueba de retardo 1 no mira; elevado al cuadrado y multiplicado por $n(n+2)/(n-7)$, ese solo término aporta alrededor de 22 al estadístico, cuando el valor crítico de una χ^2_{10} al 5 % es 18.3. En cambio, con $m = 6$ la tasa cae a 20.9 %: seis rezagos no llegan al 7, así que $Q(6)$ es casi tan ciego como la prueba de retardo 1. Esta es la comparación que pedía el enunciado entre las dos reglas para escoger m, y la lección es que m tiene que cubrir al menos el periodo estacional; por eso FPP2 recomienda $m = 2s$ cuando hay estacionalidad. Con datos diarios de una tienda, la regla $m \approx \log n$ por sí sola no es suficiente.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`

[2] D. Chen, S. L. Sain y K. Guo. "Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining". *Journal of Database Marketing & Customer Strategy Management* 19.3 (2012), pp. 197–208.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005.