Tarea 3: Introducción a Series de Tiempo

Análisis y Ciencia de Datos

Herman Andrés Echeverría Rojas
Facultad de Ingeniería, Universidad del Istmo de Guatemala

18 de octubre de 2026

Resumen

Este documento acompaña al repositorio `https://github.com/HermanEcheverria/Series-de-Tiempo`. Todas las figuras y tablas que aparecen aquí las generan los scripts del repositorio a partir del archivo original `Online Retail.xlsx` y de las semillas documentadas en el código.

Índice

1. Parte 0: procesos simulados **3**
1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria . . . 3
1.2. Inciso 0.2: simulación del AR(1) . . . 4
1.3. Inciso 0.3: lo que dice la tabla . . . 5
1.4. Inciso 0.4: las dos razones para reprobar . . . 5
1.5. Inciso 0.5: la prueba que sí ve . . . 7

2. Parte 1: limpieza **7**
2.1. Inciso 1.1: el archivo crudo . . . 8
2.2. Inciso 1.2: caso por caso . . . 8
2.3. Inciso 1.3: bitácora de limpieza . . . 10
2.4. Inciso 1.4: las seis líneas más grandes . . . 11

3. Parte 2: el calendario **11**
3.1. Inciso 2.1: la serie de venta neta diaria . . . 12
3.2. Inciso 2.2: los días sin transacciones . . . 12
3.3. Inciso 2.3: ¿cero o faltante? . . . 14
3.4. Inciso 2.4: el último día . . . 14

4. Parte 3: tendencia, estacionalidad y autocorrelación **15**
4.1. Inciso 3.1: tendencia . . . 15
4.2. Inciso 3.2: estacionalidad . . . 17
4.3. Inciso 3.3: autocorrelación . . . 18

5. Parte 4: del AR(1) al SARIMA **19**
5.1. Inciso 4.1: quitar el día de la semana . . . 19
5.2. Inciso 4.2: un AR(1) sobre los residuos . . . 21
5.3. Inciso 4.3: SARIMA . . . 22

5.4. Inciso 4.4: diagnóstico 23
5.5. Inciso 4.5: hacia dónde van los pronósticos 23

6. Parte 5: pronóstico y fuga **24**
6.1. Inciso 5.1: los modelos 24
6.2. Inciso 5.2: tres formas de estimar el error 25
6.3. Inciso 5.3: qué modelo gana en la prueba 26
6.4. Inciso 5.4: la trampa 28
6.5. Inciso 5.5: por qué el entrenamiento se queda corto 29

7. Parte 6: detrás de la serie hay clientes **30**
7.1. Inciso 6.1: R, F y M antes del 1 de octubre 30
7.2. Inciso 6.2: puntajes por quintiles 31
7.3. Inciso 6.3: ¿quién compró del 1 de octubre al 8 de diciembre? 31
7.4. Inciso 6.4: los campeones 33
7.5. Inciso 6.5: los clientes nuevos 33

1. Parte 0: procesos simulados

Antes de tocar datos reales conviene ver cómo se comportan la ACF y las pruebas de ruido blanco en procesos donde la respuesta es conocida. Todo lo de esta sección lo produce `parte0.py`, con las semillas de `semillas.py`; las funciones r_k, Ljung–Box y el estimado OLS de ϕ están implementadas a mano en `series.py` y son las mismas que se usan con la serie de ventas en las Partes 3 y 4.

1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria

Sea $Y_t = c + \phi Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, $|\phi| < 1$, y supongamos que el proceso es débilmente estacionario: $E[Y_t] = \mu$ y $\text{Var}(Y_t) = \gamma_0$ para todo t.

Media. Tomando esperanza en ambos lados y usando $E[\varepsilon_t] = 0$:

$$\mu = E[Y_t] = c + \phi\, E[Y_{t-1}] + E[\varepsilon_t] = c + \phi\mu \quad \Longrightarrow \quad \mu(1-\phi) = c \quad \Longrightarrow \quad E[Y_t] = \frac{c}{1-\phi}.$$

La división es válida porque $|\phi| < 1$ implica $\phi \neq 1$.

Varianza. Y_{t-1} depende solo de $\varepsilon_{t-1}, \varepsilon_{t-2}, \ldots$, así que es independiente de ε_t y la covarianza entre ambos es cero. La constante c no aporta varianza. Entonces

$$\gamma_0 = \text{Var}(c + \phi Y_{t-1} + \varepsilon_t) = \phi^2\, \text{Var}(Y_{t-1}) + \text{Var}(\varepsilon_t) + 2\phi\, \text{Cov}(Y_{t-1}, \varepsilon_t) = \phi^2 \gamma_0 + \sigma^2,$$

donde se usó $\text{Var}(Y_{t-1}) = \text{Var}(Y_t) = \gamma_0$. Despejando,

$$\text{Var}(Y_t) = \gamma_0 = \frac{\sigma^2}{1-\phi^2},$$

que es positiva y finita justamente porque $\phi^2 < 1$.

Autocorrelación. Para $k \geq 1$, Y_{t-k} depende solo de choques anteriores a $t-k+1$, así que $\text{Cov}(\varepsilon_t, Y_{t-k}) = 0$ y la constante no covaría con nada:

$$\gamma_k = \text{Cov}(Y_t, Y_{t-k}) = \text{Cov}(c + \phi Y_{t-1} + \varepsilon_t,\ Y_{t-k}) = \phi\ \text{Cov}(Y_{t-1}, Y_{t-k}) = \phi\, \gamma_{k-1}.$$

El último paso usa la estacionariedad: la covarianza entre Y_{t-1} y Y_{t-k} solo depende de su separación, $k-1$. Iterando la recursión desde γ_0 se obtiene $\gamma_k = \phi^k \gamma_0$, y por lo tanto

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k.$$

Caminata aleatoria. Con $\phi = 1$, $c = 0$ y $Y_0 = 0$, sustituyendo hacia atrás,

$$Y_t = Y_{t-1} + \varepsilon_t = Y_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \cdots = Y_0 + \sum_{i=1}^{t} \varepsilon_i = \sum_{i=1}^{t} \varepsilon_i.$$

Los ε_i son independientes, así que la varianza de la suma es la suma de las varianzas:

$$\text{Var}(Y_t) = \sum_{i=1}^{t} \text{Var}(\varepsilon_i) = t\sigma^2.$$

La media sí es constante ($E[Y_t] = 0$), pero la varianza crece linealmente con t: depende del momento en que se observa, y eso viola directamente la condición $\text{Var}(Y_t) = \sigma^2$ para todo t de la estacionariedad débil. Dicho de otra forma, la fórmula $\sigma^2/(1-\phi^2)$ explota cuando $\phi \to 1$: no existe una varianza estacionaria a la cual converger. Tampoco la autocorrelación es función solo del rezago: $\text{Corr}(Y_t, Y_{t-k}) = \sqrt{(t-k)/t}$, que depende de t.

1.2. Inciso 0.2: simulación del AR(1)

La función `simular_ar1` genera $200 + 300$ pasos de un AR(1) con $c = 0$ y $\sigma = 1$ a partir de $Y_0 = 0$ y descarta los primeros 200. Con $|\phi| < 1$ el efecto del valor inicial decae como ϕ^t; a los 200 pasos, incluso con $\phi = 0.9$, queda $0.9^{200} \approx 7 \times 10^{-10}$ del valor inicial, así que la serie que se conserva ya está en su distribución estacionaria. Con $\phi = 1$ eso no funciona: la serie conservada es $Y_t = Y_{200} + \sum_{i=201}^{t} \varepsilon_i$, una caminata aleatoria que arranca en Y_{200} en lugar de 0, y la varianza sigue creciendo sin límite. Pero el punto de arranque no afecta a r_k: sumar una constante a toda la serie mueve también a $\bar{y}$ y deja intactas las desviaciones $y_t - \bar{y}$, que son lo único que entra en la fórmula. Por eso descartar o no los 200 pasos no cambia en nada los resultados de r_k para la caminata.

La figura 1 muestra una realización de cada proceso. Con $\phi = 0$ la serie no tiene ninguna inercia; con $\phi = 0.5$ aparecen rachas cortas; con $\phi = 0.9$ la serie pasa decenas de pasos de un mismo lado de cero, aunque siempre regresa; y con $\phi = 1$ nunca regresa: se aleja de su origen (nótese que arranca en $Y_{200} \neq 0$) y lo que en un AR estacionario serían fluctuaciones aquí parece una tendencia.

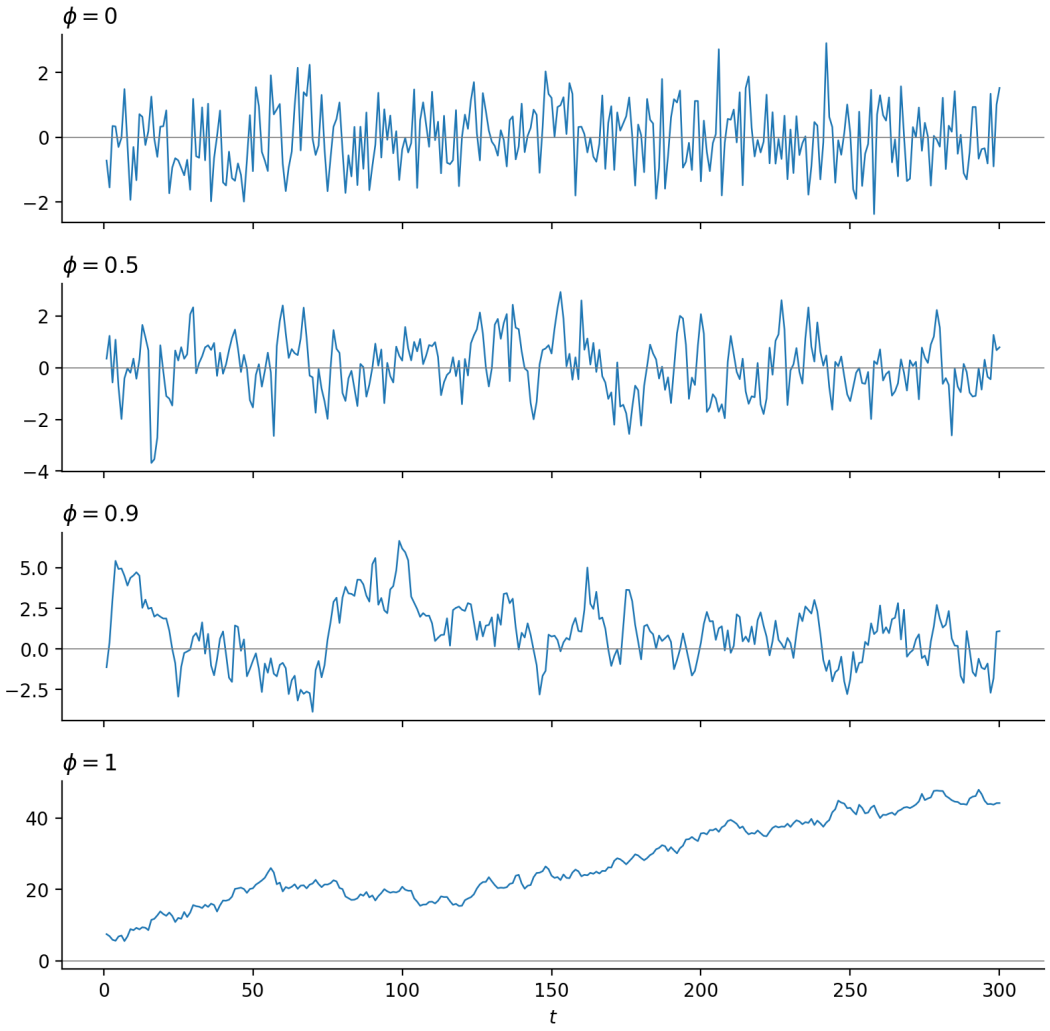


Figura 1: Una realización de 300 pasos de cada AR(1), después de descartar 200 pasos de arranque. La escala vertical cambia entre paneles: la varianza estacionaria $1/(1-\phi^2)$ vale 1, 1.33 y 5.26 para $\phi = 0, 0.5, 0.9$, y no existe para $\phi = 1$.

La tabla 1 resume las 5 000 réplicas por escenario. Cada celda es el promedio sobre réplicas y, entre paréntesis, su error estándar $s/\sqrt{5000}$. La tasa de rechazo es la fracción de réplicas en que $|r_1| > 1.96/\sqrt{300} = 0.113$, es decir, en que la prueba de retardo 1 de la Tarea 2 declara que la serie no es ruido blanco.

ϕ	$\bar{r}_1$	$\bar{r}_5$	ϕ^5	Rechazo $\lvert r_1\rvert > 1.96/\sqrt{n}$	$\bar{\hat{\phi}}_{\text{OLS}}$
0	-0.002 (0.001)	-0.003 (0.001)	0.000	0.046 (0.003)	-0.002 (0.001)
0.5	0.491 (0.001)	0.020 (0.001)	0.031	1.000 (0.000)	0.492 (0.001)
0.9	0.884 (0.000)	0.534 (0.001)	0.590	1.000 (0.000)	0.887 (0.000)
1	0.976 (0.000)	0.883 (0.001)	1.000	1.000 (0.000)	0.982 (0.000)

Tabla 1: AR(1) con $n = 300$ y 5 000 réplicas por valor de ϕ. Promedio (error estándar).

1.3. Inciso 0.3: lo que dice la tabla

Ruido blanco. Con $\phi = 0$ la prueba rechaza en el 4.62 % de las réplicas, con error estándar de 0.30 puntos: está a poco más de un error estándar del 5 % nominal, que es lo esperado. La prueba está construida precisamente para equivocarse un 5 % de las veces cuando la hipótesis nula es cierta, y aquí la nula es cierta por construcción. Que quede un poco por debajo de 5 % tiene además una razón teórica: bajo ruido blanco, $E[r_1] \approx -1/n$ y $\mathrm{Var}(r_1) \approx (n-1)/(n(n+2))$, ligeramente menor que la $1/n$ con que se dibujan las bandas, así que la tasa exacta ronda 4.9 %. El $\bar{r}_1 = -0.0023$ observado también es compatible con $-1/300 = -0.0033$.

Caminata aleatoria. La teoría estacionaria diría $\rho_5 = \phi^5 = 1$, pero el promedio de r_5 es 0.883. No es un error de simulación (el error estándar es 0.001): para una caminata aleatoria la ACF muestral está fuertemente sesgada hacia abajo. La razón es que r_k mide desviaciones respecto a $\bar{y}$, y en una caminata $\bar{y}$ es una media que no representa a ningún tramo de la serie: la serie se pasa largos periodos de un lado y luego del otro. Además el denominador usa los n términos y el numerador solo $n - k$. De hecho, la fórmula $\rho_k = \phi^k$ ni siquiera aplica, porque la derivación del inciso 0.1 supuso estacionariedad. Lo que sí se ve es la huella visual que menciona el enunciado: la ACF de la caminata baja muy despacio ($\bar{r}_1 = 0.976$, $\bar{r}_5 = 0.883$), mientras que con $\phi = 0.5$ el valor ya cayó a casi cero en el rezago 5. Para los procesos estacionarios el sesgo de r_5 también existe pero es menor: con $\phi = 0.9$ se obtiene 0.534 contra $0.9^5 = 0.590$, y con $\phi = 0.5$, 0.020 contra 0.031.

Sesgo del estimado OLS. El estimado OLS de ϕ queda sistemáticamente por debajo del valor verdadero, y el sesgo crece con ϕ: -0.002 para $\phi = 0$, -0.008 para 0.5, -0.013 para 0.9 y -0.018 para 1, todos varias veces mayores que su error estándar. Es el sesgo de Hurwicz: en una autorregresión el regresor y_{t-1} no es independiente de los errores pasados, y la aproximación clásica $E[\hat{\phi}] - \phi \approx -(1+3\phi)/n$ da -0.003, -0.008 y -0.012 para los tres casos estacionarios, muy cerca de lo observado. El estimador es consistente: el sesgo es de orden $1/n$ y desaparece cuando la muestra crece, aunque con 300 observaciones todavía se nota. En la caminata, la teoría de Dickey–Fuller dice que $\hat{\phi}$ converge todavía más rápido (a ritmo $1/n$ en vez de $1/\sqrt{n}$) pero con una distribución asimétrica, cargada hacia valores menores que 1, y eso es lo que se ve en el 0.982.

1.4. Inciso 0.4: las dos razones para reprobar

Ahora $Y_t = m_t + \varepsilon_t$ no tiene ninguna memoria: los ε_t son independientes y m_t es determinista. La figura 2 muestra una realización de cada proceso y la tabla 2 repite la tabla del inciso 0.2 agregando

$\bar{r}_7$; la primera fila es el ruido blanco del inciso anterior, como referencia.

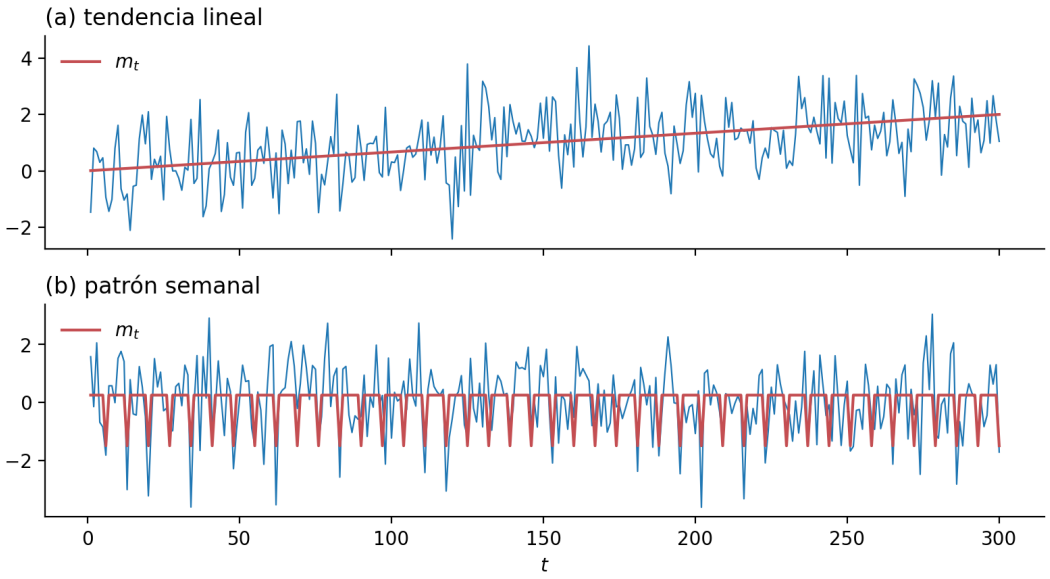


Figura 2: Procesos sin memoria con media variable. En rojo, la media m_t.

Proceso	$\bar{r}_1$	$\bar{r}_5$	$\bar{r}_7$	Rechazo r_1	$\bar{\hat{\phi}}_{\text{OLS}}$
Ruido blanco ($\phi = 0$)	-0.002 (0.001)	-0.003 (0.001)	-0.004 (0.001)	0.046 (0.003)	-0.002 (0.001)
(a) Tendencia	0.246 (0.001)	0.235 (0.001)	0.230 (0.001)	0.986 (0.002)	0.247 (0.001)
(b) Semanal	-0.047 (0.001)	-0.050 (0.001)	0.266 (0.001)	0.112 (0.004)	-0.048 (0.001)

Tabla 2: Procesos sin memoria, $n = 300$, 5 000 réplicas. Promedio (error estándar).

La tendencia reprueba sin tener memoria. La serie con tendencia rechaza la prueba de retardo 1 en el 98.6 % de las réplicas, y el OLS le asigna $\hat{\phi} \approx 0.25$ a un proceso cuyo ϕ verdadero es cero. Se puede predecir el número: m_t recorre $[0, 2]$ de forma casi uniforme, con varianza $\approx 4/12 = 1/3$, y como dos días cercanos tienen casi la misma m_t, la covarianza entre vecinos es esa misma varianza; así $r_k \approx (1/3)/(1/3 + 1) = 0.25$ para todo rezago pequeño. Eso es exactamente lo que dice la tabla: $\bar{r}_1 = 0.246$, $\bar{r}_5 = 0.235$, $\bar{r}_7 = 0.230$, una ACF que casi no decae. Es la razón (2) del enunciado: $\bar{y}$ no es la media de nadie, los días del final quedan todos por encima y los del inicio todos por debajo, y eso se ve como correlación.

El patrón semanal pasa aunque tenga estructura. La serie semanal rechaza solo en el 11.2 % de las réplicas, poco más que el ruido blanco, y su $\bar{r}_1 = -0.047$ es diminuto. De nuevo se puede calcular: sobre un ciclo de 7 días m_t tiene media 0 y varianza $(6 \cdot 0.25^2 + 1.5^2)/7 = 0.375$, pero la covarianza entre días consecutivos es solo $(5 \cdot 0.25^2 - 2 \cdot 0.375)/7 = -0.0625$, y $r_1 \approx -0.0625/1.375 = -0.045$. Toda la estructura está a distancia 7: un domingo se parece al domingo anterior, no al sábado. Por eso $\bar{r}_7 = 0.266$ (la predicción es $0.375/1.375 = 0.273$), mientras que r_1 y r_5 están cerca de cero.

Conexión con RANDU. Es el mismo fenómeno que con RANDU en la Tarea 2: RANDU pasaba las pruebas unidimensionales y de pares consecutivos y, sin embargo, sus ternas caían en solo 15 planos, porque su dependencia vivía en una combinación de los rezagos 1 y 2 que esas pruebas no miran. La prueba de retardo 1 solo puede ver estructura en el rezago 1; un proceso con la dependencia en otro lado (el rezago 7, o una combinación lineal de rezagos) la pasa sin problema. Pasar una prueba nunca demuestra independencia: solo dice que en la dirección que esa prueba mira no se encontró nada.

1.5. Inciso 0.5: la prueba que sí ve

La tabla 3 compara la tasa de rechazo de la prueba de retardo 1 con la de Ljung–Box al 5 %, con $m = 10$ (la recomendación de FPP2 sin estacionalidad) y con $m = 6 \approx \log(300) = 5.7$ (la sugerencia de Tsay). La implementación propia coincide con `statsmodels.stats.diagnostic.acorr_ljungbox` hasta el sexto decimal en el estadístico y en el valor-p; `parte0.py` lo verifica con un `assert` en una réplica de cada proceso.

Proceso	Rechazo r_1	LB $m = 10$	LB $m = 6$
Ruido blanco ($\phi = 0$)	0.046 (0.003)	0.053 (0.003)	0.053 (0.003)
(a) Tendencia	0.986 (0.002)	1.000 (0.000)	1.000 (0.000)
(b) Semanal	0.112 (0.004)	0.956 (0.003)	0.209 (0.006)

Tabla 3: Tasa de rechazo al 5 % sobre 5 000 réplicas, $n = 300$. Promedio (error estándar).

Con ruido blanco las dos versiones de Ljung–Box rechazan alrededor del 5 % (5.3 %), como deben. Con la tendencia rechazan siempre, igual que la prueba de retardo 1: ahí la estructura se ve en todos los rezagos.

El cambio está en el patrón semanal. Ljung–Box con $m = 10$ lo rechaza en el 95.6 % de las réplicas, contra el 11.2 % de la prueba de retardo 1, porque $Q(10)$ suma r_k^2 para $k = 1, \ldots, 10$ y eso incluye el $r_7 \approx 0.27$ que la prueba de retardo 1 no mira; elevado al cuadrado y multiplicado por $n(n+2)/(n-7)$, ese solo término aporta alrededor de 22 al estadístico, cuando el valor crítico de una χ^2_{10} al 5 % es 18.3. En cambio, con $m = 6$ la tasa cae a 20.9 %: seis rezagos no llegan al 7, así que $Q(6)$ es casi tan ciego como la prueba de retardo 1. Esta es la comparación que pedía el enunciado entre las dos reglas para escoger m, y la lección es que m tiene que cubrir al menos el periodo estacional; por eso FPP2 recomienda $m = 2s$ cuando hay estacionalidad. Con datos diarios de una tienda, la regla $m \approx \log n$ por sí sola no es suficiente.

2. Parte 1: limpieza

La limpieza vive en `limpiar.py` y la reproduce `parte1.py`. El archivo se carga con `datos.cargar_crudo()`, que lee `InvoiceNo`, `StockCode` y `CustomerID` como texto. El enunciado sugiere hacerlo y pide averiguar por qué; leyendo el archivo sin indicarle tipos a pandas se ve el problema en cada columna:

- `InvoiceNo` queda como una columna con 532 618 enteros (`536365`) y 9 291 cadenas (`C536379`) revueltos. Entonces `str.startswith('C')` devuelve `NaN`, no `False`, en todas las filas numéricas, y cualquier filtro de cancelaciones construido así falla en silencio.

- `StockCode` mezcla 487 036 códigos numéricos con 54 873 alfanuméricos (`85123A`, `POST`). Una regla sobre el texto del código, como "empieza con cinco dígitos", se salta todas las filas que pandas convirtió en enteros.
- `CustomerID` tiene faltantes, y como una columna entera de pandas no admite `NaN`, se convierte a `float`: `17850.0`. Un identificador no es una cantidad: no se suma ni se promedia, y no debería tener decimales.

2.1. Inciso 1.1: el archivo crudo

Concepto	Valor
Filas	541,909
Facturas distintas	25,900
Productos distintos (StockCode)	4,070
Productos distintos sin distinguir mayúsculas	3,958
Clientes distintos (CustomerID)	4,372
Filas sin CustomerID	135,080 (24.9 %)
Primera factura	2010-12-01 08:26:00
Última factura	2011-12-09 12:50:00

Tabla 4: Tamaño del archivo original, antes de limpiar.

El archivo tiene 541 909 líneas de 25 900 facturas, 4 070 códigos de producto y 4 372 clientes (tabla 4). El 24.9 % de las filas no tiene `CustomerID`. El número de productos depende de cómo se cuente: 117 códigos aparecen también en minúscula (`85123a` junto a `85123A`), y unificándolos quedan 3 958.

2.2. Inciso 1.2: caso por caso

La tabla 5 cuenta cada caso sobre los datos crudos, sin aplicar ninguna otra regla, y resume la decisión. El monto es la suma con signo de `Quantity` × `UnitPrice` de esas filas.

Caso	Filas	Monto neto (£)	Decisión
(a) Duplicados exactos	5,268	21,740.98	Se va
(b) Facturas con prefijo C	9,288	-896,812.49	Se queda (resta)
(b) Facturas con prefijo A	3	-11,062.06	Se va
(c) Códigos que no son productos	2,297	29,406.91	Se va
(c) Códigos en minúscula	1,943	30,702.15	Se transforma
(d) Precio negativo	2	-22,124.12	Se va
(d) Precio cero	2,515	0.00	Se va
(e) Cantidad negativa sin ser cancelación	1,336	0.00	Se va
(f) Sin CustomerID	135,080	1,447,682.12	Serie: se queda; RFM: se va

Tabla 5: Casos del inciso 1.2 sobre los datos crudos. Un caso puede traslapar con otro; el efecto conjunto está en la bitácora (tabla 7).

(a) Duplicados exactos: se van. Hay 5 268 filas idénticas en las ocho columnas a otra fila anterior: misma factura, mismo producto, misma cantidad y mismo minuto. Una factura que de

verdad incluyera dos veces el mismo artículo lo registraría como una línea con la cantidad sumada; dos líneas idénticas son una doble captura. Se conserva la primera. Representan £21 741.

(b) Facturas que no empiezan con un dígito. Hay dos prefijos. El `C` marca 9 288 cancelaciones, todas con cantidad negativa: *se quedan*, porque la venta neta diaria las define como líneas que restan el día en que ocurren. El `A` aparece en tres facturas del 12 de agosto de 2011 con el código `B`, "Adjust bad debt", por +11 062 y dos veces −11 062 libras: *se van*, porque son asientos contables de deuda incobrable, no ventas ni devoluciones de mercancía.

(c) Códigos que no son productos. La tabla 6 lista todos los códigos que no empiezan con cinco dígitos. No todos son iguales:

- *Se van* los cargos que no son mercancía: envío (`POST`, `DOT`, `C2`), comisiones (`AMAZONFEE`, `CRUK`), cargos bancarios, muestras (`S`), el ajuste de deuda `B` y los vales de regalo `gift_0001_*`, que son dinero adelantado y se contarían dos veces cuando se canjearan. El caso que más pesa es `AMAZONFEE`: 32 de sus 34 filas son "cancelaciones" de hasta £17 836, que en realidad son la comisión que cobra Amazon. Dejarlas habría restado £221 521 de ventas que nunca se devolvieron.
- *Se quedan* los `DCGS...` (artículos de la tienda *dotcom*, como bolsas de fiesta o collares) y `PADS`, que sí son productos aunque su código no tenga cinco dígitos.
- *Se quedan* también `D` (descuento) y `M` (ajuste manual). No son productos, pero corrigen el precio de mercancía que sí se vendió: un descuento reduce lo que la tienda cobró. El inciso 1.4 muestra qué pasa si se quitan: la factura 556444 cobró por error 60 canastas a £649.50 cada una, y la corrección es la línea `M` de la cancelación C556445. Si se quitaran las `M`, la serie se quedaría con una venta fantasma de £38 970.
- *Se transforman* los 117 códigos en minúscula, que se pasan a mayúscula.

StockCode	Filas	Monto neto (£)	Descripción	% cancelación	Decisión
POST	1,256	66,230.64	POSTAGE	10	Se va
DOT	710	206,245.48	DOTCOM POSTAGE	0	Se va
M	571	-68,674.19	Manual	43	Se queda
C2	144	6,986.00	CARRIAGE	1	Se va
D	77	-5,696.22	Discount	100	Se queda
S	63	-3,049.39	SAMPLES	97	Se va
DCGS...	45	398.45	SUNJAR LED NIGHT NIGHT LIGHT	0	Se queda
BANK CHARGES	37	-7,175.64	Bank Charges	68	Se va
AMAZONFEE	34	-221,520.50	AMAZON FEE	94	Se va
gift_0001_...	34	685.81	Dotcomgiftshop Gift Voucher £40.	0	Se va
CRUK	16	-7,933.43	CRUK Commission	100	Se va
PADS	4	0.00	PADS TO MATCH ALL CUSHIONS	0	Se queda
B	3	-11,062.06	Adjust bad debt	0	Se va
m	1	2.55	Manual	0	Se queda

Tabla 6: Códigos que no empiezan con cinco dígitos, en los datos crudos. La columna de cancelación es el porcentaje de sus filas en facturas `C`.

(d) Precios iguales a cero o negativos: se van. Los dos precios negativos son las líneas de deuda incobrable del caso (b). Los 2 515 precios en cero no aportan nada a la venta (su monto es exactamente cero), y casi todos son movimientos de inventario sin cliente: 1 336 tienen cantidad negativa (caso e) y, de las que tienen cantidad positiva, solo 40 tienen cliente, probablemente obsequios. Para la serie da igual quitarlos o no; se quitan para que no inflen la frecuencia de compra en la Parte 6.

(e) Cantidades negativas que no son cancelaciones: se van. Son 1 336 filas, todas con precio cero y ninguna con cliente. Su descripción lo explica: vacía (862), "check" (123), "damaged" o "damages" (103), "?" (41), "sold as set on dotcom", "thrown away", "wet damaged", "missing"... Son ajustes de inventario por mercancía dañada, perdida o reetiquetada, no devoluciones de clientes.

(f) Filas sin `CustomerID`: depende. Para la serie de ventas *se quedan*: una venta sin cliente identificado sigue siendo dinero que entró a la tienda. Después de la limpieza son el 24.8 % de las filas y el 15.4 % de la venta neta (£1.50 millones), casi todas del Reino Unido; quitarlas bajaría el nivel de la serie y, si su peso cambia con el tiempo, también su forma. Para la Parte 6 *se van*, porque el RFM necesita saber quién compró. Por eso `limpiar` tiene el argumento `requiere_cliente`.

2.3. Inciso 1.3: bitácora de limpieza

Las reglas se aplican en el orden de la tabla 7. La columna "Sola" cuenta las filas que la regla quitaría aplicada sobre los datos crudos; "En orden" cuenta las que realmente quita después de las anteriores. El monto corresponde a las filas que quita en orden: el neto es la suma con signo y el absoluto, la suma de $|\texttt{Quantity} \times \texttt{UnitPrice}|$. La regla 6 solo se aplica para la Parte 6.

Orden	Regla	Sola	En orden	Monto neto (£)	Monto absoluto (£)
1	Duplicados exactos	5,268	5,268	21,740.98	27,406.50
2	Facturas con prefijo A (ajuste de deuda)	3	3	-11,062.06	33,186.18
3	Códigos que no son productos	2,297	2,293	40,478.71	571,674.49
4	Precio igual a cero o negativo	2,517	2,499	0.00	0.00
5	Cantidad negativa sin ser cancelación	1,336	0	0.00	0.00
6	Sin CustomerID	135,080	131,656	1,495,555.05	1,573,094.09
	Total		141,719	1,546,712.68	2,205,361.26

Tabla 7: Bitácora de limpieza, en el orden en que se aplican las reglas.

El orden sí cambia los conteos. La regla 5 no quita ninguna fila en orden, pero aplicada sola quitaría 1 336: todas las cantidades negativas sin cancelación tienen precio cero, así que la regla 4 ya las eliminó. Si el orden fuera el inverso, la regla 5 se llevaría 1 336 filas y la 4, 1 336 menos. Del mismo modo, la regla 3 quita 2 293 filas y no 2 297 porque las tres líneas `B` ya cayeron con el prefijo `A` y una más era duplicado; y la regla 4 quita 2 499 y no 2 517 porque los dos precios negativos ya cayeron con el prefijo `A`, cinco eran duplicados y once tenían un código que no es producto. Ninguna de estas diferencias cambia el resultado final: las reglas solo deciden a qué renglón de la bitácora se le atribuye cada fila.

Para la serie de ventas (reglas 1 a 5) quedan 531 846 filas con una venta neta total de £9 696 590; 8 989 de esas filas son cancelaciones que suman −£628 382. Para el RFM (reglas 1 a 6) quedan 400 190 filas.

2.4. Inciso 1.4: las seis líneas más grandes

La tabla 8 muestra las seis líneas con mayor $|\texttt{Quantity} \times \texttt{UnitPrice}|$ en los datos crudos. Son tres pares venta–cancelación.

Factura	Fecha	Cliente	Producto	Cantidad	Precio	Monto (£)	¿Sobrevive?
C581484	09/12/2011 09:27	16446	Paper Craft , Little Birdie	-80,995	2.08	-168,469.60	Sí
581483	09/12/2011 09:15	16446	Paper Craft , Little Birdie	80,995	2.08	168,469.60	Sí
C541433	18/01/2011 10:17	12346	Medium Ceramic Top Storage Jar	-74,215	1.04	-77,183.60	Sí
541431	18/01/2011 10:01	12346	Medium Ceramic Top Storage Jar	74,215	1.04	77,183.60	Sí
C556445	10/06/2011 15:31	15098	Manual	-1	38,970.00	-38,970.00	Sí
556444	10/06/2011 15:28	15098	Picnic Basket Wicker 60 Pieces	60	649.50	38,970.00	Sí

Tabla 8: Las seis líneas con mayor monto absoluto antes de limpiar. "¿Sobrevive?" indica si la línea sigue en los datos limpios.

- **Paper Craft, Little Birdie (cliente 16446).** El 9 de diciembre de 2011 a las 9:15 la factura 581483 vende 80 995 unidades a £2.08, £168 470 en una sola línea, y doce minutos después la C581484 la cancela completa. El cliente solo tiene otra compra en todo el año: dos artículos por £2.90 en mayo. Es casi seguro un error de captura, corregido de inmediato.
- **Medium Ceramic Top Storage Jar (cliente 12346).** El 18 de enero de 2011 la factura 541431 vende 74 215 frascos a £1.04 (£77 184), y dieciséis minutos después la C541433 la cancela. Es la única actividad del cliente en todo el archivo, así que su venta neta total es cero; vuelve a aparecer en la Parte 6 como un cliente con $M \leq 0$.
- **Picnic Basket Wicker 60 Pieces (cliente 15098).** El 10 de junio de 2011 la secuencia completa es: 556442 vende 60 canastas pequeñas a £4.95 (£297); 556444 cobra 60 unidades a £649.50, que es el precio del juego de 60 piezas, no de una canasta (£38 970); C556445 lo corrige con una línea `Manual` de −£38 970; 556446 cobra el juego correcto, una unidad a £649.50; y C556448 cancela las canastas pequeñas. Lo que el cliente compró en realidad fue un juego de £649.50.

¿Las resuelve la limpieza? No: las seis sobreviven, y está bien que sobrevivan. Ninguna regla las identifica como errores (son productos reales, con precio positivo y con cliente), y quitar una sola mitad del par sería peor que dejar las dos. Si una regla quitara la venta de 80 995 unidades por "atípica", la cancelación quedaría huérfana y restaría £168 470 ese día. Por la misma razón la regla de códigos no quita la línea `M`: quitarla dejaría la venta de £38 970.

¿Las resuelve el neteo por día? Sí, porque en los tres casos la venta y su corrección ocurren el mismo día, con minutos de diferencia. En la venta neta del 18 de enero el par del frasco suma exactamente cero; la del 10 de junio recibe del cliente 15098 exactamente los £649.50 que compró; y el par del 9 de diciembre suma cero (además, la Parte 2 descarta ese día por incompleto). La serie diaria es inmune a estos errores siempre que se corrijan el mismo día. Un análisis por cliente o por factura no lo es: en la Parte 6 cada una de estas facturas cuenta como una compra para la frecuencia, aunque el monto neto sea cero.

3. Parte 2: el calendario

La serie se construye en `calendario.py`: se suma $\texttt{Quantity} \times \texttt{UnitPrice}$ por día sobre los datos de `limpiar(df)` (reglas 1 a 5, con cancelaciones restando y con las ventas sin cliente) y se lleva al

calendario completo. Las tablas y figuras de esta sección las genera `parte2.py`.

3.1. Inciso 2.1: la serie de venta neta diaria

Concepto	Días
Días calendario (1/12/2010 al 9/12/2011)	374
Días con al menos una transacción	305
Días sin transacciones	69
sábados	53
cierre de Navidad (sin sábados)	9
feriados de 2011	7

Tabla 9: Días calendario y días con transacciones.

Entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011, contando ambos, hay 374 días calendario, y en 305 hubo al menos una transacción (tabla 9). Es decir, en 69 días (el 18 %) la tienda no registró nada. La figura 3 muestra la serie en los días abiertos. Los cierres entre semana están marcados con una cruz sobre el eje; los sábados no se marcan porque ocurren todas las semanas.

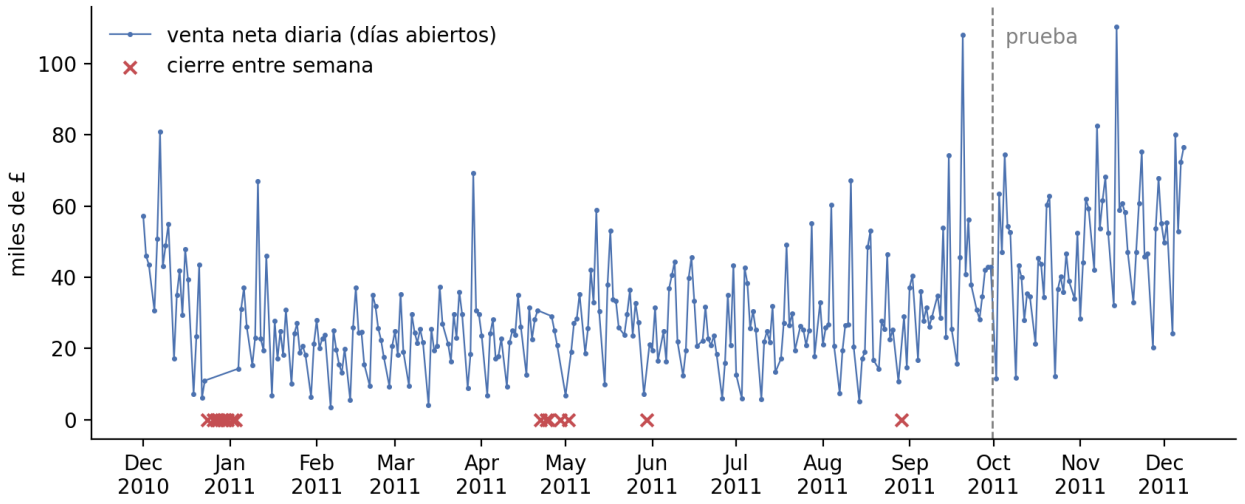


Figura 3: Venta neta diaria en los días abiertos, del 1 de diciembre de 2010 al 8 de diciembre de 2011. La línea une días abiertos consecutivos, así que salta por encima de los sábados y de los cierres. La línea punteada separa el entrenamiento (hasta el 30 de septiembre) de la prueba.

La figura ya anticipa lo que se va a modelar en las siguientes partes: un nivel de alrededor de £20–30 mil diarios entre enero y agosto, un crecimiento fuerte desde septiembre (la temporada navideña de una tienda de regalos que vende a mayoristas) y mucha variación de un día a otro, con picos aislados de más de £100 mil.

3.2. Inciso 2.2: los días sin transacciones

Los sábados. 53 de los 69 días faltantes son sábados: *todos* los sábados del periodo. No hay ni una sola transacción en sábado en todo el año, así que la tienda no abre ese día. En cambio sí abre

los domingos.

Los otros 16. La tabla 10 los lista y los clasifica usando el calendario de *bank holidays* de Inglaterra y Gales.

Fecha	Día	Tipo	Motivo
24/12/2010	viernes	Cierre de Navidad	Nochebuena
26/12/2010	domingo	Cierre de Navidad	Boxing Day (domingo)
27/12/2010	lunes	Cierre de Navidad	Feriado: traslado de Navidad
28/12/2010	martes	Cierre de Navidad	Feriado: traslado de Boxing Day
29/12/2010	miércoles	Cierre de Navidad	Entre Navidad y Año Nuevo
30/12/2010	jueves	Cierre de Navidad	Entre Navidad y Año Nuevo
31/12/2010	viernes	Cierre de Navidad	Fin de año
02/01/2011	domingo	Cierre de Navidad	Domingo antes del traslado
03/01/2011	lunes	Cierre de Navidad	Feriado: traslado de Año Nuevo
22/04/2011	viernes	Feriado móvil (Pascua)	Viernes Santo
24/04/2011	domingo	Feriado móvil (Pascua)	Domingo de Pascua
25/04/2011	lunes	Feriado móvil (Pascua)	Lunes de Pascua
29/04/2011	viernes	Feriado único	Boda real (Guillermo y Catalina)
02/05/2011	lunes	Feriado de lunes	Early May bank holiday
30/05/2011	lunes	Feriado de lunes	Spring bank holiday
29/08/2011	lunes	Feriado de lunes	Summer bank holiday

Tabla 10: Días entre semana (sin contar sábados) sin ninguna transacción.

- **Cierre de Navidad: 9 días**, del viernes 24 de diciembre de 2010 al lunes 3 de enero de 2011. En 2010 Navidad cayó en sábado y el *Boxing Day* en domingo, así que los feriados oficiales se trasladaron al lunes 27 y al martes 28; Año Nuevo de 2011 cayó en sábado y se trasladó al lunes 3 de enero. Los días que quedan en medio (29, 30 y 31 de diciembre y el domingo 2 de enero) no son feriados oficiales: la tienda simplemente cerró entre fiestas, algo común en un negocio que le vende a otros negocios.
- **Pascua: 3 días**, el Viernes Santo (22 de abril), el Domingo de Pascua (24 de abril) y el Lunes de Pascua (25 de abril). El domingo no es feriado oficial, pero la tienda, que sí abre otros domingos, no abrió entre los dos feriados.
- **La boda real: 1 día**, el viernes 29 de abril de 2011, el matrimonio del príncipe Guillermo con Catalina Middleton. Es el feriado que no se repite: el gobierno lo declaró solo para ese año.
- **Feriados de lunes: 3 días**, el *Early May bank holiday* (2 de mayo), el *Spring bank holiday* (30 de mayo) y el *Summer bank holiday* (29 de agosto).

Todos los feriados oficiales del periodo aparecen como días sin ventas, y fuera de los sábados no falta ningún otro día: no hay caídas del sistema ni días perdidos sin explicación.

¿Cuáles son móviles? Los de Pascua. La Pascua cae el primer domingo después de la primera luna llena de primavera, así que el Viernes Santo puede caer en cualquier fecha entre el 20 de marzo y el 23 de abril, y el Lunes de Pascua tres días después: de un año a otro se mueven hasta cinco semanas. Por eso FPP2 dice que son de lo más difícil de modelar con datos diarios: un modelo con

estacionalidad de 7 días o de 365 días no los puede anticipar, porque no caen a una distancia fija de nada. Los tres feriados de lunes también cambian de fecha de un año a otro, pero siguen una regla de calendario sencilla (primer o último lunes del mes), siempre caen en lunes y se conocen con años de anticipación. La Navidad tiene fecha fija, pero el día de la semana cambia y con él los traslados, como pasó en 2010. La boda real no se puede modelar con ningún patrón, porque solo ocurrió una vez.

3.3. Inciso 2.3: ¿cero o faltante?

Un día sin transacciones puede ser cualquiera de las dos cosas; depende de para qué se use la serie.

Cuándo es un cero. Cuando la pregunta es contable, como cuánto vendió la tienda en una semana o en un mes, o cuál es la venta promedio por día calendario. El sábado la caja recibió exactamente cero libras, y sumar la serie con ceros da el total correcto. Es el uso de la media móvil del inciso 3.1, donde el enunciado pide rellenar con cero: una semana con un feriado sí vendió menos que una semana normal, y la tendencia debe reflejarlo.

Cuándo es un faltante. Cuando se modela el comportamiento de la tienda en los días en que opera: los índices estacionales, la ACF, los modelos AR y SARIMA y la evaluación del pronóstico. Ahí un cero de sábado no es una observación de "un día malo": no hubo ningún día que observar. Si se deja como cero, el índice estacional del sábado sería cero (algo que ya se sabe y no hay que estimar); la media de la serie bajaría un 18 % (69 de 374 días); aparecería un r_7 enorme que no viene de la demanda sino del calendario; y un pronóstico que acierte "cero" cada sábado se vería artificialmente bueno. Por eso, de aquí en adelante, la serie tiene los días cerrados como faltantes y los modelos trabajan con una fila por día abierto.

3.4. Inciso 2.4: el último día

El 9 de diciembre de 2011 no está completo. Su última factura es de las 12:50 y suma £29 306 en 49 facturas, cuando un viernes de noviembre o diciembre vende una mediana de £52 410. Ningún día anterior del año registró su última factura antes de las 12:50: los datos se cortaron a mediodía, probablemente cuando se extrajo el archivo.

Se puede medir qué tan incompleto está. Para cada viernes anterior se calculó qué fracción de sus ventas se había registrado a las 12:50 (figura 4). La mediana es 54 %, así que el 9 de diciembre completo habría vendido alrededor de $29\,306/0.54 \approx$ £54 200, en línea con los viernes anteriores. Es decir, al día le falta casi la mitad.

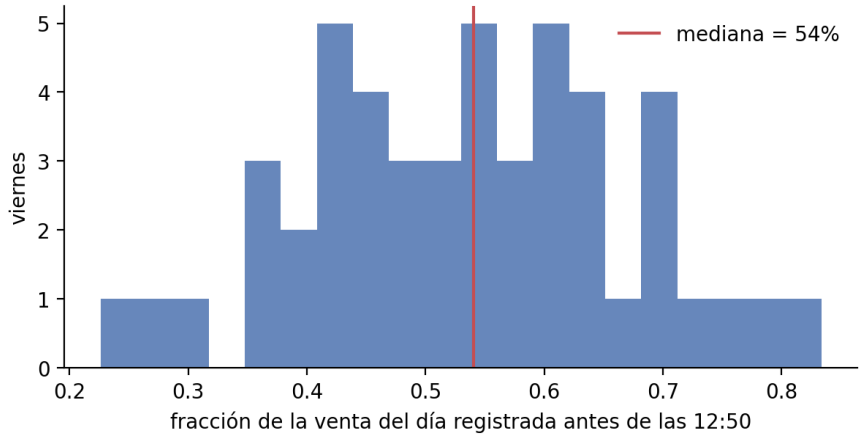


Figura 4: Fracción de la venta bruta de cada viernes registrada antes de las 12:50, la hora de la última factura del 9 de diciembre.

Se descarta. Dejarlo metería en el último punto de la serie una caída artificial a la mitad, justo en el día que más pesa al pronosticar, y es también el día del par venta–cancelación de £168 470 del inciso 1.4. Escalarlo por $1/0.54$ inventaría un dato con un supuesto sobre el reparto de las ventas en el día. Como es el último día y no hay nada que interpolar, quitarlo no le cuesta nada a la serie. La serie de trabajo termina el jueves 8 de diciembre de 2011.

4. Parte 3: tendencia, estacionalidad y autocorrelación

Los incisos 3.1 y 3.2 forman una descomposición clásica multiplicativa:

$$y_t = T_t \times S_t \times R_t,$$

donde la tendencia T_t se estima con una media móvil, el índice estacional S_t con el promedio de y_t/T_t por día de la semana, y R_t es lo que queda. Todo lo genera `parte3.py`.

4.1. Inciso 3.1: tendencia

La media móvil centrada de 7 días es

$$MA_t = \frac{1}{7} \sum_{j=-3}^{3} y_{t+j},$$

calculada sobre el calendario completo con los días cerrados en cero, como pide el enunciado (aquí el cero es el valor correcto: el inciso 2.3 explica por qué). Los tres primeros y los tres últimos días no tienen la ventana completa y quedan sin valor. La figura 5 la muestra sobre la serie.

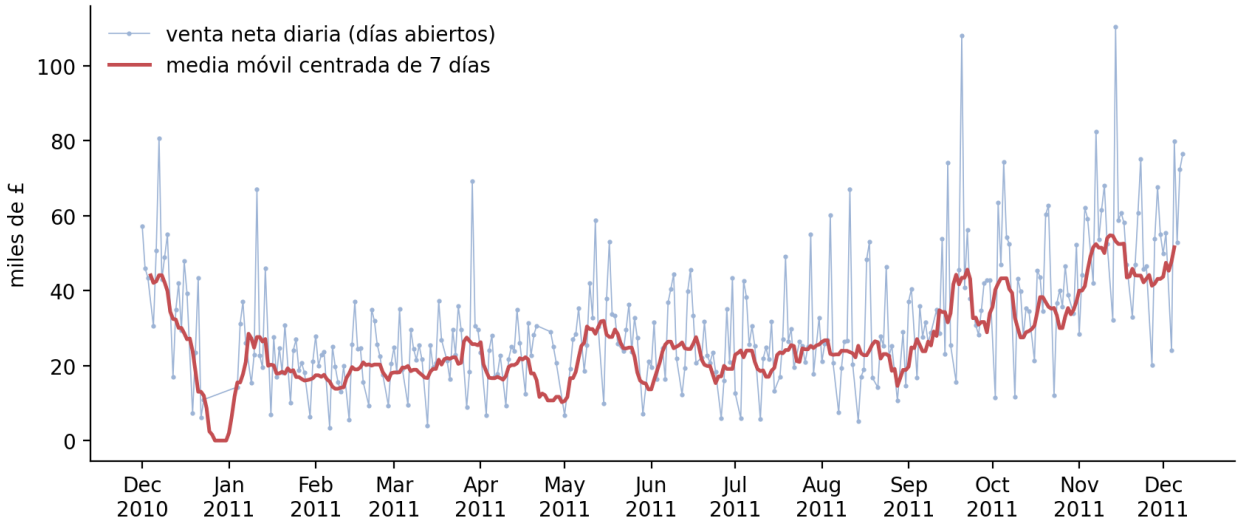


Figura 5: Venta neta diaria (días abiertos) y media móvil centrada de 7 días calculada con los días cerrados en cero.

¿Por qué 7? Porque es el periodo del patrón semanal. Una ventana de 7 días consecutivos contiene exactamente un lunes, un martes, ... y un sábado, así que en cada promedio entra cada día de la semana una sola vez y el patrón semanal se cancela: lo que queda es el nivel de esa semana. Con una ventana de 5 días la mezcla cambiaría de un día al siguiente (algunas ventanas tendrían el sábado en cero y otras no, o dos días fuertes y ninguno débil), y la "tendencia" oscilaría con periodo semanal. Con 30 días el patrón semanal tampoco se cancela exactamente, porque 30 no es múltiplo de 7 (cada ventana incluye dos días de la semana una vez de más), y además la ventana es tan ancha que aplana cambios reales de nivel, como el arranque de la temporada en septiembre o el cierre de Navidad.

¿Por qué centrada? Para que MA_t describa el nivel *alrededor* del día t, no el de los días anteriores. Una media móvil de los últimos 7 días (de $t-6$ a t) mide el nivel de hace tres días y, en una serie que sube, siempre se queda atrás. La centrada no tiene ese retraso, y por eso sirve para descomponer y para dividir y_t/MA_t en el inciso 3.2. El costo es que usa tres días del futuro, y_{t+1}, y_{t+2} y y_{t+3}: sirve para describir la serie, no para pronosticarla. Esto vuelve a aparecer en el inciso 5.4.

La tendencia. La venta arranca en diciembre de 2010 alrededor de £40 mil diarios, se desploma a cero con el cierre de Navidad y en enero reaparece en un nivel mucho menor. De enero a agosto queda prácticamente plana: el promedio mensual de la media móvil se mueve entre £17 y £24 mil, con altibajos de una o dos semanas pero sin dirección clara. Desde septiembre sube con fuerza, a £32 mil en septiembre, £35 mil en octubre y £47 mil en noviembre y diciembre, más del doble que en la primera mitad del año. Más que una tendencia lineal es la temporada navideña de una tienda de regalos que le vende a mayoristas: el nivel de diciembre de 2011 se parece al de diciembre de 2010.

4.2. Inciso 3.2: estacionalidad

Para cada día abierto del entrenamiento se calcula el cociente y_t/MA_t, y el índice estacional de cada día de la semana es el promedio de sus cocientes (tabla 11 y figura 6).

Día	Índice estacional	Días	Desv. est. del cociente
Lunes	1.164	37	0.324
Martes	1.545	42	0.543
Miércoles	1.232	42	0.385
Jueves	1.563	42	0.496
Viernes	1.118	39	0.317
Sábado	—	0	—
Domingo	0.580	40	0.302

Tabla 11: Índices estacionales con los días abiertos del entrenamiento (1 de diciembre de 2010 al 30 de septiembre de 2011). "Días" es cuántos cocientes entran en cada promedio.

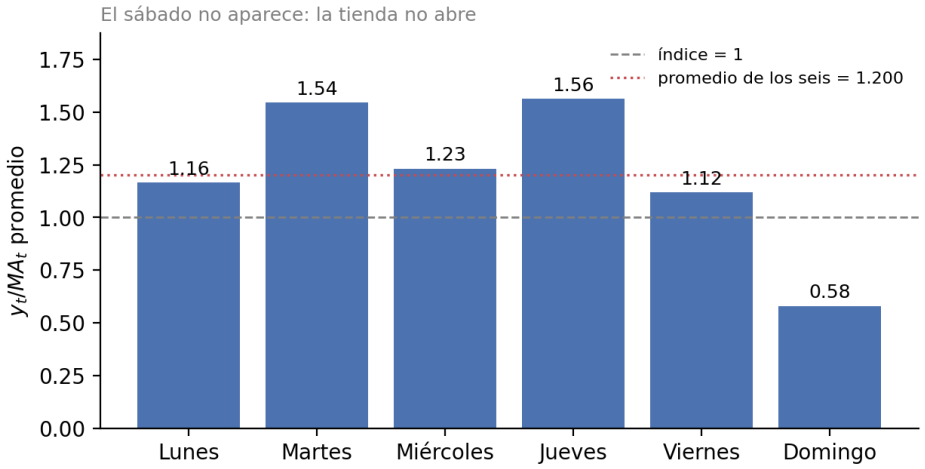


Figura 6: Índice estacional por día de la semana.

¿Qué días venden más? Martes (1.54) y jueves (1.56): esos días la tienda vende en promedio un 55 % más que el nivel de su semana. Les siguen miércoles (1.23), lunes (1.16) y viernes (1.12). El domingo es claramente el día débil (0.58). Los cocientes son muy dispersos (desviaciones estándar de 0.3 a 0.5), y los mayores son martes y jueves con pedidos grandes, como el martes 20 de septiembre, que vendió £108 mil, 2.5 veces la media móvil. Aun así, el orden no depende de esos extremos: con la mediana en lugar del promedio, martes y jueves siguen arriba (1.44 y 1.47) y el domingo abajo (0.53).

¿Por qué el promedio de los seis índices no es 1? Porque el séptimo día, el sábado, entra en la media móvil con un cero. Si la venta de una semana es V, la media móvil vale aproximadamente $V/7$, pero esas V libras se reparten entre solo seis días abiertos, que en promedio venden $V/6$. El cociente promedio de los días abiertos es entonces $(V/6)/(V/7) = 7/6 \approx 1.167$. En una descomposición clásica los siete índices deben promediar 1, y aquí lo hacen si se cuenta el sábado con índice cero: $(6 \times 1.2 + 0)/7 \approx 1.03$. El 1.200 observado queda un poco por encima de 7/6 por dos razones: las

semanas con feriado tienen todavía más ceros en la ventana, lo que baja la media móvil y sube los cocientes de los días vecinos (el mayor cociente del año es el martes 21 de diciembre de 2010, justo antes del cierre de Navidad, con 3.33), y el promedio de cocientes no es el cociente de promedios.

4.3. Inciso 3.3: autocorrelación

(a) Se calcula r_k con la función `acf` de `series.py`, la misma de la Parte 0, sobre los 245 días abiertos del entrenamiento puestos uno tras otro, una fila por día y sin calendario. Las bandas son $\pm 1.96/\sqrt{245} = \pm 0.125$.

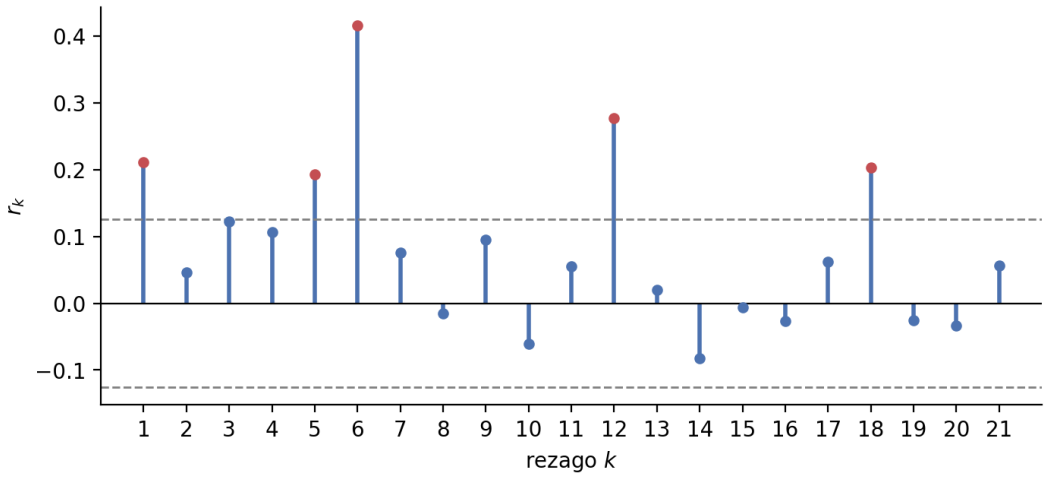


Figura 7: ACF de la venta neta en los días abiertos del entrenamiento ($n = 245$). En rojo, los rezagos fuera de las bandas.

k	r_k	Fuera	k	r_k	Fuera
1	0.210	sí	12	0.277	sí
2	0.046		13	0.020	
3	0.123		14	-0.083	
4	0.107		15	-0.006	
5	0.193	sí	16	-0.026	
6	0.416	sí	17	0.062	
7	0.075		18	0.203	sí
8	-0.015		19	-0.025	
9	0.095		20	-0.033	
10	-0.060		21	0.056	
11	0.056				

Estadístico	Valor	g.l.	Valor-p
$Q(6)$	71.4	6	2.1e-13
$Q(12)$	96.9	12	2.2e-15

Tabla 12: Izquierda: r_k para $k = 1, \ldots, 21$. Derecha: Ljung–Box sobre la serie.

- **Cinco rezagos se salen de las bandas**: 1, 5, 6, 12 y 18. Con 21 pruebas al 5 % se esperaría uno por azar, no cinco, y menos con el patrón que forman.
- **No pasa la prueba de retardo 1** de la Tarea 2: $r_1 = 0.210 > 0.125$.
- **El pico está en** $k = 6$, con $r_6 = 0.416$, y se repite en sus múltiplos: $r_{12} = 0.277$ y $r_{18} = 0.203$. Como la serie no tiene sábados, seis días abiertos hacia atrás son siete días calendario: una

semana. De los 239 pares de días a distancia 6 en el entrenamiento, 211 están separados exactamente por 7 días calendario; el resto están más separados porque entre ellos hay un feriado o el cierre de Navidad. El pico en 6 es el patrón semanal que encontró el inciso 3.2: un martes se parece al martes anterior.

- **Ljung–Box lo confirma**: $Q(6) = 71.4$ y $Q(12) = 96.9$, con valores-p del orden de 10^{-13} y 10^{-15}. La serie no es ruido blanco por ningún criterio.

(b) ¿Memoria o media no constante? La Parte 0 enseñó a reconocer las dos huellas. La serie tiene las dos.

- Los picos en 6, 12 y 18 son la huella del proceso semanal del inciso 0.4(b): un patrón que se repite cada semana produce autocorrelación en el periodo y sus múltiplos aunque no haya memoria. Es media no constante.
- Que casi todos los rezagos de 1 a 9 sean positivos, y que la ACF baje despacio, es la huella de la tendencia del inciso 0.4(a): desde septiembre todos los días quedan por encima de $\bar{y}$ y sus vecinos también. Eso también es media no constante.
- El $r_1 = 0.21$ puede venir de las dos cosas: de la tendencia o de memoria verdadera (un día de ventas altas seguido de otro igual porque los clientes compran en rachas). En el proceso semanal de la Parte 0 el patrón semanal por sí solo daba un r_1 ligeramente *negativo*, así que el r_1 positivo no lo explica el patrón semanal.

Con solo la ACF no se puede separar cuánto es cada cosa. La receta es la del enunciado: quitar primero la media no constante (el día de la semana, en el inciso 4.1) y ver qué memoria le queda al residuo.

5. Parte 4: del AR(1) al SARIMA

Se sigue la receta del enunciado: quitar la estacionalidad, mirar el residuo y modelar la memoria que quede. Toda la parte usa los 245 días abiertos del entrenamiento como una fila por día. El código está en `parte4.py` y la configuración de S1 y S2 en `modelos.py`, que se reusa en la Parte 5.

5.1. Inciso 4.1: quitar el día de la semana

Se ajusta por OLS $y_t = \sum_d \beta_d D_{d,t} + e_t$, con una indicadora $D_{d,t}$ por cada uno de los seis días abiertos y sin intercepto. Con esa especificación, cada $\hat{\beta}_d$ es simplemente la venta promedio de ese día de la semana: lunes £26 916, martes £34 988, miércoles £27 695, jueves £35 266, viernes £26 208 y domingo £13 706. El mismo orden que los índices estacionales del inciso 3.2.

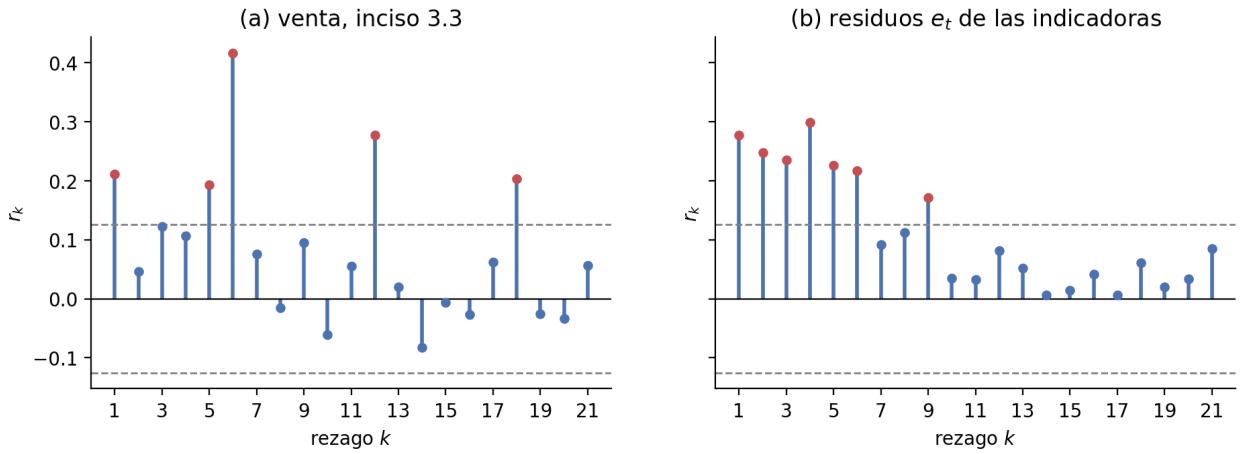


Figura 8: ACF antes (a) y después (b) de quitar el efecto del día de la semana, con las mismas bandas $\pm 1.96/\sqrt{245}$.

¿Qué cambió respecto a 3.3? Los picos en 6, 12 y 18 desaparecieron: r_{12} y r_{18} de los residuos ya están dentro de las bandas, y r_6 bajó de 0.42 a 0.22, al nivel de los rezagos vecinos (figura 8). Las indicadoras se llevaron el patrón semanal, que era media no constante, tal como se había anticipado en 3.3(b). Pero lo que queda no es ruido blanco: los nueve primeros rezagos son positivos y están fuera de las bandas (salvo el 7 y el 8, que quedan cerca), entre 0.17 y 0.30, y la ACF baja lentamente hasta desaparecer después del rezago 10. Ljung–Box es todavía mayor que antes ($Q(6) = 95.2$; tabla 13).

¿Se parece a un AR(1) o al proceso con tendencia? Un AR(1) con $\phi \approx 0.28$ (el r_1 de los residuos) tendría $r_2 \approx 0.08$ y $r_4 \approx 0.006$: una caída geométrica rápida. Aquí $r_2 = 0.25$, $r_3 = 0.24$ y $r_4 = 0.30$; la ACF casi no decae en los primeros seis rezagos. Esa es la forma de la ACF del proceso con tendencia de la Parte 0 (tabla 2), donde r_1, r_5 y r_7 eran todos parecidos. El residuo de la figura 9 muestra por qué: es positivo casi todo diciembre de 2010 y septiembre de 2011, y negativo casi todo de enero a abril. Los días vecinos comparten el signo porque comparten el nivel.

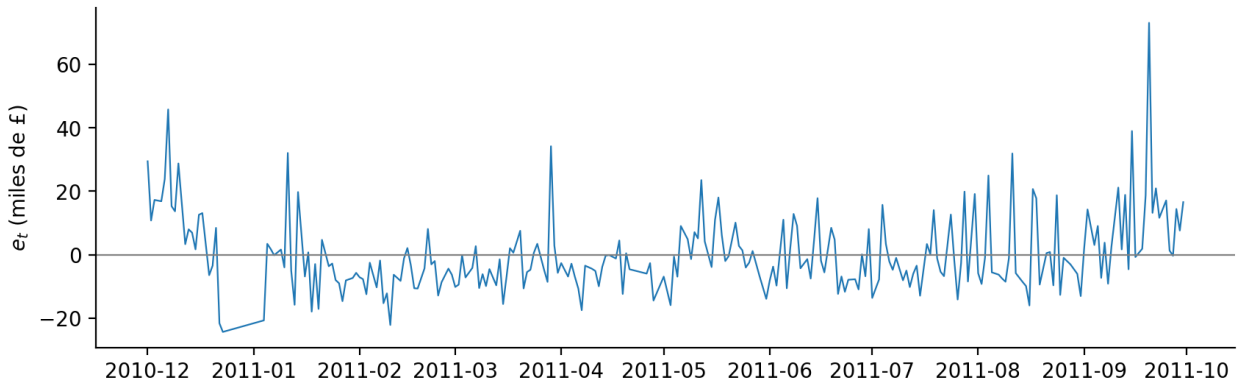


Figura 9: Residuos e_t de la regresión contra las indicadoras de día de la semana.

¿Qué le falta al modelo? Le falta el nivel. Las indicadoras suponen que un martes de febrero y un martes de septiembre tienen la misma media, pero la serie cambia de nivel (inciso 3.1): baja en

enero, queda plana y sube desde septiembre. Ese nivel que se mueve es media no constante que el modelo no tiene, y queda en los residuos como autocorrelación positiva en todos los rezagos cortos.

5.2. Inciso 4.2: un AR(1) sobre los residuos

Se ajusta por OLS $e_t = c + \phi e_{t-1} + u_t$ y se obtiene $\hat{\phi} = 0.279$ (con $\hat{c} = -101.7$, prácticamente cero, como corresponde a residuos de media cero). La figura 10 es la ACF de $u_t = e_t - \hat{c} - \hat{\phi} e_{t-1}$.

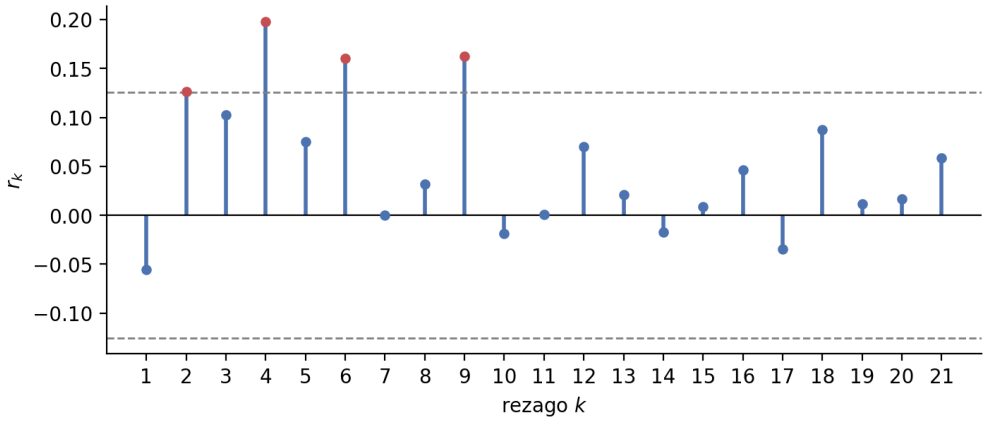


Figura 10: ACF de los residuos u_t del AR(1) ajustado a e_t.

Serie	m	g.l.	$Q(m)$	Valor-p
e_t (indicadoras)	6	6	95.2	2.49e-18
e_t (indicadoras)	12	12	110.4	5.1e-18
u_t (AR(1) sobre e_t)	6	5	25.1	0.000136
u_t (AR(1) sobre e_t)	12	11	33.4	0.000452
Residuos de S1	6	4	9.5	0.0488
Residuos de S1	12	10	23.5	0.00899
Residuos de S2 (sin los 7 primeros)	6	4	4.9	0.3
Residuos de S2 (sin los 7 primeros)	12	10	10.5	0.398

Tabla 13: Ljung–Box sobre los residuos de cada etapa. Los grados de libertad restan los parámetros de memoria estimados: uno para el AR(1) y dos para S1 y S2.

Todavía no son ruido blanco. El AR(1) se llevó el rezago 1 (r_1 pasó de 0.28 a -0.06), pero siguen fuera de las bandas los rezagos 2, 4, 6 y 9 ($r_4 = 0.20$, $r_6 = 0.16$, $r_9 = 0.16$). Ljung–Box lo confirma: $Q(6) = 25.1$ con 5 grados de libertad y $Q(12) = 33.4$ con 11, con valores-p de 10^{-4}. Un AR(1) no alcanzó, y era de esperarse: el AR(1) modela una memoria que se desvanece geométricamente, y lo que había en 4.1 era un nivel que se mueve durante meses. El AR(1) solo puede representarlo como "hoy se parece a ayer", y por eso arregla el rezago 1 y deja el resto.

5.3. Inciso 4.3: SARIMA

Con `statsmodels.tsa.statespace.sarimax.SARIMAX` se ajustan, sobre $\log y_t$, los dos modelos con $s = 6$:

S1: $(1 - \phi B)(1 - \Phi B^6)(\log y_t - \mu) = \varepsilon_t$, SARIMA$(1,0,0)(1,0,0)_6$ con constante;

S2: $(1 - B)(1 - B^6)\log y_t = (1 + \theta B)(1 + \Theta B^6)\varepsilon_t$, SARIMA$(0,1,1)(0,1,1)_6$ sin constante.

A `SARIMAX` se le pasa el arreglo de valores, no la serie con fechas. En `statsmodels` la constante de S1 se estima como el intercepto c de la ecuación, que se relaciona con la media por $c = \mu(1-\phi)(1-\Phi)$.

¿Por qué $s = 6$ y no 7? Porque el modelo trabaja con una fila por día abierto, y una semana tiene seis días abiertos: el martes anterior está seis filas atrás, no siete (el pico de la ACF del inciso 3.3 estaba en 6). Con $s = 7$ el modelo compararía cada día con un día de la semana distinto cada vez.

¿Cuándo se rompe esa suposición? Cuando una semana tiene menos de seis días abiertos. Después de un feriado, seis filas atrás ya no es el mismo día de la semana: después del Lunes de Pascua (25 de abril), por ejemplo, las filas quedan desfasadas un día durante una semana, y el modelo compara un martes con un miércoles. El caso extremo es el cierre de Navidad, que se come nueve días. Según el inciso 3.3, 28 de los 239 pares de días a distancia 6 no están a una semana; en esos puntos la estacionalidad del modelo apunta al día equivocado.

¿Por qué el logaritmo? Porque la variación de la serie crece con su nivel. En febrero la venta diaria promedia £20.7 mil con una desviación estándar de £8.5 mil; en septiembre promedia £38.9 mil y la desviación sube a £18.9 mil. En logaritmo, la desviación estándar mensual queda entre 0.35 y 0.69 durante todo el año, sin crecer con el nivel. Además, los índices estacionales del inciso 3.2 son multiplicativos: el martes vende un 55 % más que su semana, no una cantidad fija de libras más. FPP2 (§3.2) recomienda transformar cuando la variación depende del nivel. El logaritmo convierte la estructura multiplicativa en aditiva, $\log y_t = \log T_t + \log S_t + \log R_t$, que es lo que un SARIMA sabe modelar, y estabiliza la varianza. Además garantiza que el pronóstico en libras, $\exp(\cdot)$, sea positivo. Se puede usar porque en los días abiertos la venta neta es siempre positiva: el mínimo del entrenamiento es £3 440.

Convergencia. La tabla 14 muestra los parámetros con el límite de iteraciones por defecto (50) y con 500.

Modelo	maxiter	¿Convergió?	Iteraciones	c	ϕ	Φ	θ	Θ	σ^2	log-verosimilitud	AIC
S1	50	no	50	0.795	0.164	0.906	—	—	0.240	-185.942	379.884
S1	500	sí	81	4.210	0.132	0.521	—	—	0.216	-160.699	329.397
S2	50	sí	14	—	—	—	-0.914	-0.670	0.213	-156.953	319.906
S2	500	sí	14	—	—	—	-0.914	-0.670	0.213	-156.953	319.906

Tabla 14: Parámetros de S1 y S2 sobre $\log y_t$ con 50 y 500 iteraciones como máximo. "Convergió" es `mle_retvals['converged']`.

S2 converge en 14 iteraciones y sus parámetros no cambian al subir `maxiter`. S1 *no* converge con el valor por defecto: se detiene en la iteración 50 con $\Phi = 0.906$, $\phi = 0.164$ y $c = 0.795$. Con `maxiter=500` converge en 81 iteraciones a un modelo distinto: $\Phi = 0.521$, $\phi = 0.132$ y $c = 4.210$, con

una log-verosimilitud mucho mayor (-160.7 contra -185.9). Lo interesante es que los dos conjuntos de parámetros implican casi la misma media, $\mu = c/((1-\phi)(1-\Phi)) \approx 10.12$ en logaritmo, es decir, £24 900 diarios. Lo que cambia es la dinámica: el optimizador sin terminar estaba en una región con Φ cerca de 1, casi una raíz unitaria estacional, que es un modelo con mucha más memoria semanal de la que tienen los datos. Sin revisar `mle_retvals` se habría usado ese modelo sin saberlo. De aquí en adelante S1 se ajusta siempre con `maxiter=500`.

5.4. Inciso 4.4: diagnóstico

Los residuos de S2 empiezan con valores enormes (10.9 en el primero y -6.1 en el séptimo, cuando los demás son del orden de ± 0.5): con inicialización difusa, las primeras $1+6=7$ observaciones solo sirven para arrancar las diferencias $(1-B)(1-B^6)$ y sus residuos no significan nada. Se descartan. La figura 11 y la tabla 13 muestran el resultado, con $m-2$ grados de libertad.

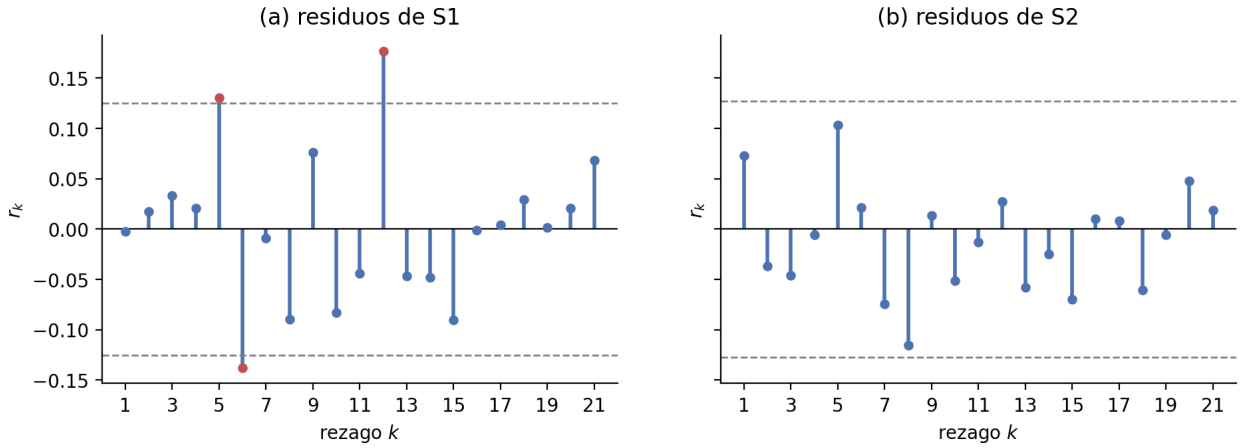


Figura 11: ACF de los residuos de S1 (con `maxiter=500`) y de S2 (sin sus primeros 7 residuos).

- **S1 no deja ruido blanco.** $Q(6) = 9.5$ con 4 grados de libertad ($p = 0.049$, justo en la frontera) y $Q(12) = 23.5$ con 10 ($p = 0.009$): se rechaza ruido blanco. S1 modela la memoria y el patrón semanal, pero alrededor de una media *fija*, y el cambio de nivel que se vio en 4.1 sigue en sus residuos.
- **S2 sí.** $Q(6) = 4.9$ ($p = 0.30$) y $Q(12) = 10.5$ ($p = 0.40$): no hay evidencia de autocorrelación en sus residuos. La diferencia $(1-B)$ es lo que le permite seguir un nivel que se mueve, y $(1-B^6)$ se lleva el patrón semanal.

5.5. Inciso 4.5: hacia dónde van los pronósticos

La figura 12 muestra los pronósticos de los dos modelos, ajustados con todo el entrenamiento, para los siguientes 120 días abiertos.

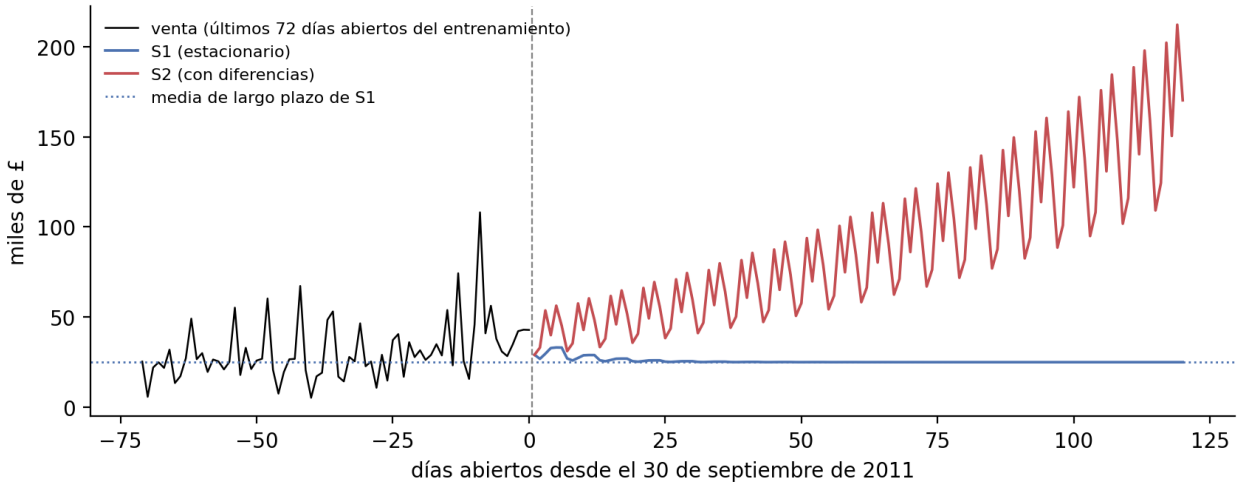


Figura 12: Pronósticos de S1 y S2 hasta 120 días abiertos después del 30 de septiembre de 2011, en libras (exp del pronóstico en logaritmo).

S1 regresa a su media. Es estacionario, y en un AR estacionario el efecto de lo observado decae como ϕ^h (inciso 0.1). Para S1 las dos memorias, ϕ^h con $\phi = 0.13$ y $\Phi^{h/6}$ con $\Phi = 0.52$, se desvanecen en unas pocas semanas, y el pronóstico converge a $\exp(\mu) \approx$ £24 875 diarios, la venta típica de enero a septiembre. A partir de un mes de horizonte, S1 pronostica lo mismo para todos los días: ni siquiera conserva el patrón semanal, porque ese patrón también lo modelaba como memoria que se desvanece.

S2 no regresa a ningún lado. Igual que la caminata aleatoria, que nunca olvida, S2 no tiene una media a la cual volver: su pronóstico arranca del último nivel observado y conserva el último patrón semanal. Y como tiene dos diferencias ($d = 1$ y $D = 1$), el pronóstico admite además una pendiente: la estima con el promedio reciente de los cambios, y el crecimiento de septiembre la hace positiva, así que la proyecta sin límite. A 120 días abiertos el pronóstico supera las £200 mil diarias. A horizontes cortos, ese comportamiento es justo lo que S1 no puede hacer (seguir un nivel nuevo); a horizontes largos, una extrapolación así es peligrosa. Para un pronóstico de una semana, que es lo que pide la Parte 5, lo que importa es el corto plazo.

6. Parte 5: pronóstico y fuga

Cada modelo está implementado en `parte5.py` como una función que recibe la serie, el origen (un domingo) y los días abiertos de la semana siguiente, y que solo puede mirar la serie hasta el origen. El origen móvil sigue exactamente las reglas del enunciado: los objetivos son los días abiertos de lunes a domingo después del origen; en (b) no se evalúa nada después del 30 de septiembre y en (c) el último día es el 8 de diciembre; para S1 y S2 el horizonte es la posición del objetivo entre los días abiertos posteriores al origen; y el MAE y el RMSE juntan todos los días pronosticados. En (b) hay 22 orígenes, del 1 de mayo al 25 de septiembre, con 128 días evaluados; en (c) hay 10, del 2 de octubre al 4 de diciembre, con 58.

6.1. Inciso 5.1: los modelos

- **B1**: el promedio de todos los días abiertos hasta el origen.

- **B2** (*naive* estacional): para cada objetivo, la venta del mismo día de la semana abierto más reciente hasta el origen.
- **M1**: OLS de y_t contra t (días desde el 1 de diciembre de 2010) y las seis indicadoras de día de la semana.
- **M2**: OLS de y_t contra las seis indicadoras, y_{t-7} y y_{t-14}. Si el día del rezago está cerrado se usa el mismo día de la semana abierto más reciente; el código verifica con un `assert` el ejemplo del enunciado (para el 9 de mayo, y_{t-7} es la venta del 18 de abril, £31 402). Para y_{t-14} se aplica la misma regla, así que el 9 de mayo sus dos rezagos son el 18 de abril. Las 12 filas del inicio que no tienen rezago no se usan para ajustar.
- **S1** y **S2**: los modelos del inciso 4.3, reajustados en cada origen con todos los días abiertos hasta el origen y llevados a libras con $\exp(\cdot)$.

¿Por qué M2 puede usar y_{t-7} pero no y_{t-1}? El pronóstico se hace el domingo para toda la semana siguiente. Para cualquier objetivo de lunes a domingo, siete días antes cae en el domingo de origen o antes, así que y_{t-7} ya se observó: el lunes usa el lunes anterior y el domingo usa el propio domingo de origen. En cambio, y_{t-1} solo se conoce para el lunes; para el martes, y_{t-1} es el lunes, que el domingo todavía no ha ocurrido. Una regresión que lo usara como variable necesitaría un dato del futuro.

¿Cómo usa S1 el rezago 1 de todas formas? De forma recursiva. Un modelo autorregresivo pronostica un paso a la vez y, cuando le falta un valor, usa su propio pronóstico en su lugar: $\hat{y}_{t+2} = c + \phi\,\hat{y}_{t+1} + \ldots$. El filtro de Kalman de `SARIMAX` hace exactamente eso. Por eso la información del último día observado se diluye como ϕ^h conforme crece el horizonte h: con $\phi \approx 0.13$, para el martes ya casi no queda nada del domingo. M2 no puede hacer esto porque es una regresión directa: no pronostica sus propias variables.

Convergencia en cada origen. Se reajustan S1 y S2 en los 32 orígenes de (b) y (c), con la configuración del inciso 4.3 (`maxiter=500`), y se revisa `mle_retvals['converged']` en cada uno. S2 convergió en los 32. S1 convergió en 31; en el del 1 de mayo L-BFGS se detuvo en la iteración 52 con `warnflag=2`, que significa que la búsqueda de línea ya no lograba mejorar. No fue por falta de iteraciones: con 1 000 o 2 000 se detiene en el mismo punto, con un gradiente del orden de 10^{-4}. El código reintenta con BFGS, que sí converge, a los mismos parámetros hasta el segundo decimal y con log-verosimilitud -80.3911 contra -80.3912. Los pronósticos cambian menos de £12. Es decir, el ajuste estaba en el óptimo y el optimizador no lo pudo certificar; aun así se usa el ajuste que sí convergió.

6.2. Inciso 5.2: tres formas de estimar el error

La tabla 15 reúne los tres esquemas. En (a), cada celda es la media ± la desviación estándar sobre las 10 semillas (`SEMILLAS_CV` en `semillas.py`) de una validación cruzada aleatoria de 5 *folds* sobre los días abiertos del entrenamiento.

Modelo	(a) MAE	(a) RMSE	(b) MAE	(b) RMSE	(c) MAE	(c) RMSE
B1	10,271 ± 53	14,249 ± 48	10,253	14,936	22,474	27,062
B2	—	—	11,340	15,651	14,409	18,637
M1	9,129 ± 112	12,546 ± 107	9,833	13,901	15,203	20,284
M2	8,345 ± 110	11,791 ± 212	9,258	13,412	15,219	19,917
S1	—	—	9,656	13,767	17,228	21,302
S2	—	—	10,058	14,028	12,545	15,901

Tabla 15: MAE y RMSE en libras: (a) validación cruzada aleatoria de 5 *folds* en el entrenamiento, con 10 semillas; (b) origen móvil semanal en el entrenamiento, orígenes de mayo a septiembre; (c) origen móvil semanal en la prueba.

¿Por qué no tiene sentido (a) para B2, S1 y S2? Porque los tres dependen del orden de la serie, y la validación cruzada aleatoria lo destruye. Al sacar al azar un 20 % de los días, el día a pronosticar queda rodeado de días de entrenamiento *posteriores* a él. Para B2, "el mismo día de la semana más reciente" de un día de marzo podría ser un día de abril, y eso ya no es un pronóstico sino una interpolación. S1 y S2 necesitan la secuencia completa para que B y B^6 signifiquen "ayer" y "hace una semana": con huecos aleatorios el rezago k deja de ser un rezago fijo, y el filtro, al estimar un día faltante, usaría los días siguientes. B1, M1 y M2 son regresiones cuyas filas se pueden repartir entre *folds*, así que mecánicamente sí se puede calcular (a) para ellas. Pero también están contaminadas: M1 estima la pendiente con días posteriores al que pronostica, y el nivel de los días vecinos (que son los que más se parecen) siempre queda en el entrenamiento.

¿Cuál se acerca más a (c)? El origen móvil. Para M1 y M2, (b) da errores más grandes que (a) y, por lo tanto, más cercanos a (c): M2 pasa de 8 345 en (a) a 9 258 en (b), contra 15 219 en (c), y M1 de 9 129 a 9 833, contra 15 203. Para B1 los dos esquemas coinciden (10 271 y 10 253): la media histórica no tiene cómo aprovechar a los vecinos de un día, así que la validación aleatoria no le regala nada. La validación cruzada aleatoria es la más optimista porque es la que más información del futuro deja entrar.

¿Alguna se acerca de verdad? No. El error en la prueba es entre 1.25 y 2.2 veces el de (b), y además el orden de los modelos cambia por completo. En (b) el mejor es M2 y S2 queda cuarto, por delante solo de B1 y B2; en (c) S2 es claramente el mejor y M2 queda en el lugar cuatro, empatado con M1. Ninguna estimación hecha dentro del entrenamiento habría escogido el modelo ganador. El inciso 5.5 discute por qué.

6.3. Inciso 5.3: qué modelo gana en la prueba

Gana S2, con MAE de £12 545 y RMSE de £15 901: un 13 % menos de MAE que el segundo lugar (B2, £14 409) y un 18 % menos que M1 y M2. La figura 13 muestra los pronósticos de todos los modelos contra la serie real.

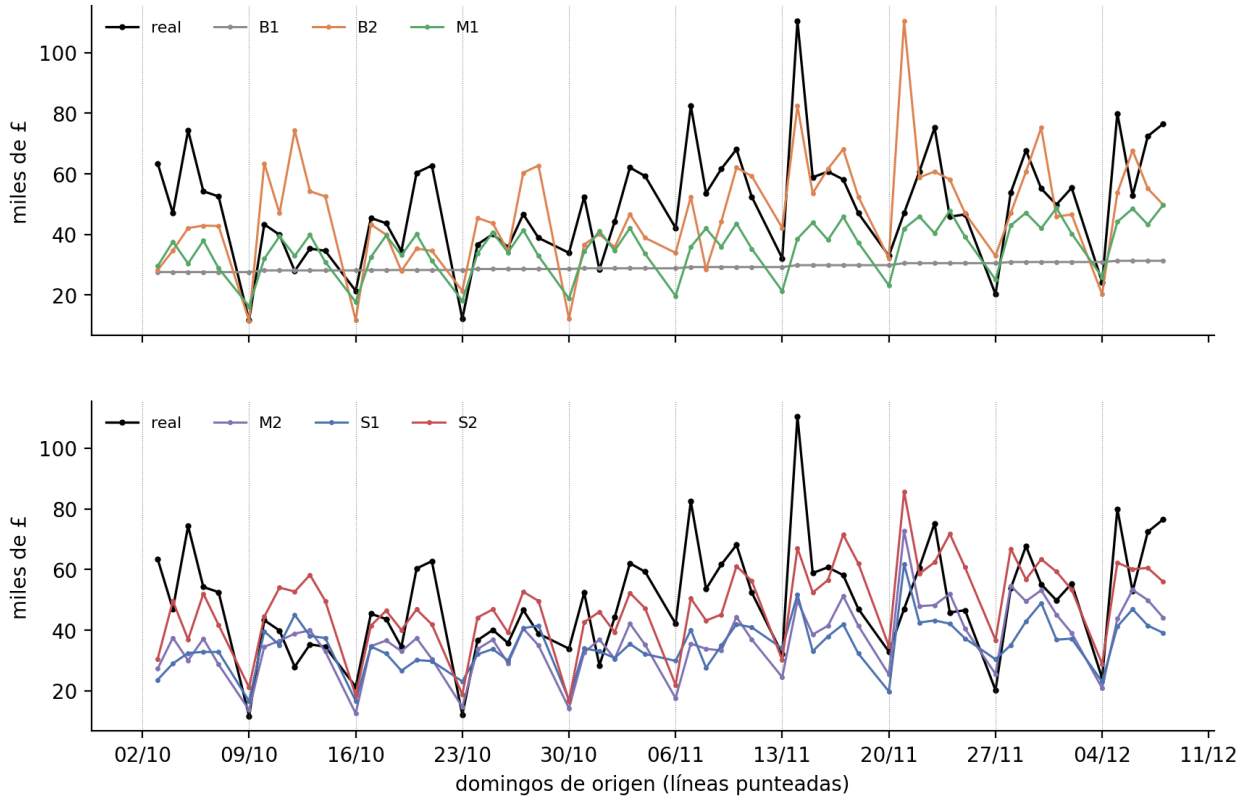


Figura 13: Pronósticos con origen móvil semanal en la prueba (octubre a diciembre de 2011) contra la venta real. Cada línea punteada es un domingo de origen; cada modelo pronostica los seis días abiertos que le siguen.

	B1	B2	M1	M2	S1	S2
Sesgo medio (real − pronóstico)	20,532	2,743	13,757	12,903	14,718	1,187

Tabla 16: Error medio en la prueba (real menos pronóstico), en libras. Un valor positivo significa que el modelo se queda corto.

Por qué gana S2. La prueba es la temporada navideña: la venta media de los días evaluados en (c) es £49 800, contra £29 500 en (b). La tabla 16 muestra qué hace cada modelo con ese cambio de nivel. B1, M1, M2 y S1 se quedan cortos, en promedio, por £13 000 a £20 500 diarios. B1 promedia todo el año. M1 ajusta una sola recta a un año que fue plano ocho meses y luego subió, y la recta queda por debajo del final. M2 le da poco peso a los rezagos (el día de la semana explica casi todo en el entrenamiento). Y S1, como se vio en el inciso 4.5, regresa a una media estimada con enero a septiembre. En la figura 13 se ve que sus pronósticos tienen la forma semanal correcta pero quedan sistemáticamente por debajo de la línea negra a partir de noviembre.

Solo dos modelos casi no tienen sesgo: B2 (£2 743) y S2 (£1 187). Los dos parten de lo que pasó la semana anterior y, por lo tanto, siguen el nivel. La diferencia entre ellos es el ruido: B2 copia una sola semana, con todos sus picos, así que cuando el martes anterior tuvo un pedido excepcional lo repite (para el lunes 21 de noviembre pronostica £110 mil porque ese fue el pico real del lunes 14; la venta fue de £47 mil). S2 hace lo mismo pero promediando: sus términos de promedio móvil,

$\theta = -0.91$ y $\Theta = -0.67$, convierten la diferencia en un promedio exponencialmente ponderado de las semanas recientes. Sigue el nivel como B2, pero sin copiar el ruido.

Esto es coherente con el diagnóstico del inciso 4.4: S2 fue el único modelo cuyos residuos parecían ruido blanco, porque fue el único que capturó el nivel que se mueve. S1 dejaba autocorrelación en los residuos, justamente por ese nivel, y en la prueba eso se convierte en sesgo. En (b), de mayo a septiembre, el nivel fue estable y modelos que regresan a la media no pagaban ese costo; la flexibilidad de S2 solo le añadía varianza. En la prueba, el nivel se movió y esa flexibilidad es la que gana.

Origen	B1	B2	M1	M2	S1	S2	Mejor
02/10	28.3	16.8	22.0	22.1	24.3	15.9	S2
09/10	7.9	20.0	4.8	6.3	6.0	13.5	M1
16/10	20.3	12.5	12.7	12.8	17.4	8.9	S2
23/10	10.1	12.2	5.2	7.1	7.0	8.6	M1
30/10	19.4	13.3	18.1	18.4	17.1	12.4	S2
06/11	29.2	15.9	22.7	23.6	22.4	11.9	S2
13/11	31.5	8.4	23.5	20.1	25.2	14.0	B2
20/11	22.2	17.5	11.5	13.8	14.7	18.4	M1
27/11	22.4	8.4	10.4	7.6	13.7	8.1	M2
04/12	39.1	21.3	24.0	22.9	28.2	14.4	S2

Tabla 17: MAE de cada semana de la prueba, en miles de libras. “Mejor” es el modelo con menor MAE esa semana.

La victoria no es de todas las semanas (tabla 17): S2 es el mejor en 5 de las 10 y M1 en 3, siempre en semanas tranquilas, sin cambio de nivel. Pero S2 nunca tiene una semana desastrosa, y por eso gana en el total. Los errores más grandes de todos los modelos vienen de días con pedidos excepcionales, como el lunes 14 de noviembre (£110 mil), que ningún modelo podía anticipar.

6.4. Inciso 5.4: la trampa

Se agrega a M2 la media móvil centrada de 7 días de la Parte 3, calculada una sola vez sobre toda la serie, como una variable más.

Modelo	(a) MAE	(a) RMSE	(b) MAE	(b) RMSE
M2	8,345	11,791	9,258	13,412
M2 + media móvil centrada	7,450	10,086	8,377	11,362

Tabla 18: M2 con y sin la media móvil centrada como predictor. (a): promedio sobre 10 semillas; (b): origen móvil en el entrenamiento.

Se ve mejor. Mucho mejor: el MAE baja de 8 345 a 7 450 en (a) y de 9 258 a 8 377 en (b), alrededor de un 10 % en los dos esquemas (tabla 18). El ajuste con todo el entrenamiento le da a la media móvil un coeficiente de 1.05 y deja los rezagos en prácticamente cero (0.01 y 0.05): el modelo descubre que la mejor forma de pronosticar la venta de un día es “la media móvil de ese día más el efecto del día de la semana”.

Por qué es ilegal. Porque MA_t contiene el futuro. La media centrada del día t promedia de y_{t-3} a y_{t+3}, así que incluye la venta del propio día que se quiere pronosticar (y_t, con peso 1/7) y la de

los tres días siguientes. El domingo de origen, para pronosticar el lunes se necesitarían las ventas de lunes a jueves; para pronosticar el jueves, hasta las del domingo siguiente. Ningún dato de la semana objetivo existe cuando se hace el pronóstico.

Por qué el origen móvil no lo detecta. Porque el origen móvil solo controla qué *filas* entran al ajuste; no revisa cómo se calcularon las *variables* de esas filas. Si la media móvil se calcula una vez sobre toda la serie y luego se parte en orígenes, la columna `ma7` del lunes objetivo ya trae adentro las ventas de la semana objetivo, aunque esas filas no se hayan usado para estimar los coeficientes. La fuga está en la construcción de la variable, antes de la validación, y ninguna partición de filas la puede ver. La única defensa es recalcular cada variable en cada origen usando solo datos hasta el origen, y con la media centrada eso es imposible para la semana objetivo.

Por qué (c) no se puede calcular sin hacer trampa. En la prueba, para el origen del 2 de octubre la media móvil de los objetivos necesita las ventas del 3 al 11 de octubre, que son precisamente los valores que se están evaluando. Calcular (c) con esa variable es darle al modelo parte de la respuesta del examen. La versión honesta requeriría pronosticar primero la media móvil, es decir, pronosticar las ventas de la semana, que es justo el problema que se quería resolver. Por eso esta variable no tiene versión legítima para pronosticar, y por eso su mejora en (a) y (b) es una ilusión.

6.5. Inciso 5.5: por qué el entrenamiento se queda corto

Todas las estimaciones hechas dentro del entrenamiento subestiman el error de la prueba. Hay dos causas, y conviene separarlas.

1. Cómo se partieron los datos. La validación cruzada aleatoria deja que el modelo aprenda del futuro y que el día pronosticado esté rodeado de días vecinos en el entrenamiento, que comparten su nivel. Es lo que separa (a) de (b): de 8 345 a 9 258 en M2, de 9 129 a 9 833 en M1. *Esta causa sí se arregla con una mejor validación*: el origen móvil reproduce las condiciones reales del pronóstico (solo pasado, horizonte de una semana) y la elimina.

2. La serie cambió. La prueba es la temporada navideña, con una venta media de £49 800 contra £29 500 de los días evaluados en (b), y los errores crecen con el nivel. Si el MAE se divide entre la venta media de los días evaluados, los modelos tienen errores relativos parecidos en los dos periodos: entre 31 % y 38 % en (b), y entre 25 % y 45 % en (c). M2, por ejemplo, tiene un 31 % en ambos. Lo que más cambia es para quién: B1 y S1, que regresan a la media, empeoran en términos relativos; S2 y B2, que siguen el nivel, mejoran. *Esta causa no se arregla con ninguna validación*: no existe forma de que una validación dentro de enero a septiembre mida cómo se comporta un modelo en un régimen que el entrenamiento nunca contuvo. Lo único que ayuda es tener datos de ese régimen, o un modelo que se adapte a cambios de nivel (como S2), y aun así sin poder medir de antemano cuánto.

¿Se puede estimar la estacionalidad anual con un año de datos? No. Para estimar un patrón que se repite cada año hay que verlo repetirse, es decir, al menos dos años completos; FPP2 lo plantea igual para cualquier estacionalidad. Con un año, cada día del año aparece una sola vez, y el "efecto noviembre" es indistinguible de una tendencia, de un cambio en la clientela o de un evento único: los tres producen la misma subida desde septiembre. Además, el único otro diciembre de los datos (el de 2010) está partido por el cierre de Navidad. Es justamente lo que le faltó a todos

los modelos: ninguno sabía que el cuarto trimestre vende el doble, porque en el entrenamiento no había un cuarto trimestre del cual aprenderlo.

7. Parte 6: detrás de la serie hay clientes

El análisis RFM usa `limpiar(df, requiere_cliente=True)`, es decir, las reglas 1 a 6 de la bitácora: las mismas de la serie más la que quita las filas sin `CustomerID`. Todo lo genera `parte6.py`. Para cada cliente se calcula:

- **R**: días entre su última factura de venta (no cancelación) y el 1 de octubre de 2011;
- **F**: número de facturas de venta distintas;
- **M**: venta neta total, con las cancelaciones restando.

7.1. Inciso 6.1: R, F y M antes del 1 de octubre

Con las transacciones anteriores al 1 de octubre de 2011 hay **3 658 clientes**. La tabla 19 resume sus tres variables, que son muy asimétricas: la mitad de los clientes compró dos veces o menos, mientras que el que más compró tiene 139 facturas, y el monto va de $-£4\,288$ a £201 772, con mediana de £562.

Variable	Media	Mín.	P20	P40	Mediana	P60	P80	Máx.
R (días)	95.5	1.0	15.0	43.0	66.0	96.0	181.0	305.0
F (facturas)	3.6	0.0	1.0	1.0	2.0	3.0	5.0	139.0
M (£)	1,581.5	-4,287.6	213.2	403.3	562.2	776.4	1,669.6	201,771.6

Tabla 19: Distribución de R, F y M para los 3 658 clientes con transacciones antes del 1 de octubre de 2011. P20, P40, P60 y P80 son los cortes de los quintiles.

Clientes con $M \leq 0$: 54. De ellos, 51 tienen $M < 0$ y 3 tienen $M = 0$. Hay dos tipos:

- **43 no tienen ninguna factura de venta** en el periodo, solo cancelaciones: devolvieron mercancía que habían comprado antes del 1 de diciembre de 2010, fuera de los datos. No tienen una "última compra" observada, así que se les asigna $R = 305$, un día más que a quien compró el primer día de los datos (su última compra fue antes).
- **11 compraron y luego cancelaron** lo mismo o más, como el cliente 12346 del inciso 1.4 (74 215 frascos vendidos y cancelados el mismo día, $F = 1$ y $M = 0$).

Se quedan en el análisis, como pide el inciso 6.2, y la decisión es defendible: son clientes reales que tuvieron actividad, y su M (y, para los 43, su R) los manda naturalmente al puntaje más bajo. Quitarlos cambiaría los cortes de los quintiles de todos los demás. Lo que no se hace es tratarlos como clientes valiosos: en ningún análisis de valor pueden aparecer arriba.

¿Por qué no usar nada posterior al 1 de octubre? Porque lo que se quiere evaluar es si R, F y M *anticipan* quién compra entre el 1 de octubre y el 8 de diciembre. Si se usaran transacciones posteriores, la respuesta se colaría en las variables: un cliente que compró en noviembre tendría una recencia pequeña *porque* compró en noviembre, y una frecuencia y un monto mayores por la misma razón. El AUC del inciso 6.3 saldría excelente y no mediría nada. Es la misma fuga del inciso 5.4: una variable que contiene el futuro hace que cualquier modelo se vea bien.

7.2. Inciso 6.2: puntajes por quintiles

A cada cliente se le asigna un puntaje de 1 a 5 en cada dimensión según su quintil; en recencia, 5 es el más reciente. Se siguió exactamente el procedimiento del enunciado: se ordenan todos los clientes por `CustomerID`, se barajan con `numpy.random.default_rng(2026).permutation` y se aplica `pd.qcut(x.rank(method='first'), 5)`, con $x = F$, $x = M$ y $x = -R$.

El problema con F. F es un conteo pequeño con muchísimos empates: el 39.6 % de los clientes tiene $F = 1$, el 18.9 % tiene $F = 2$, el 12.1 % tiene $F = 3$ y el 1.2 % tiene $F = 0$. El primer quintil (20 %) y el segundo (40 %) caen dentro del bloque de $F = 1$, así que los cortes de los quintiles se repiten: `pd.qcut(F, 5)` directamente falla con el error "Bin edges must be unique", porque los cortes son $0, 1, 1, 3, 5, 139$. No hay forma de partir a los clientes en cinco grupos del mismo tamaño usando solo su F.

F	Puntaje 1	Puntaje 2	Puntaje 3	Puntaje 4	Puntaje 5
0	43	0	0	0	0
1	689	731	29	0	0
2	0	0	692	0	0
3	0	0	11	431	0
4	0	0	0	279	0
5	0	0	0	21	157
6	0	0	0	0	118

Tabla 20: Número de clientes por valor de F y puntaje asignado, para $F \leq 6$. Los clientes con el mismo F que aparecen en varias columnas recibieron su puntaje por sorteo.

Lo que implica el desempate. Con `rank(method='first')`, los clientes empatados se ordenan según su posición en el barajado, así que el puntaje de los clientes que caen en una frontera se decide por sorteo (tabla 20). Los 1 449 clientes con $F = 1$ quedaron repartidos entre el puntaje 1 (689), el 2 (731) y el 3 (29); los de $F = 3$, entre 3 y 4; los de $F = 5$, entre 4 y 5. Para dos clientes con la misma F que caen en puntajes distintos, *la diferencia de puntaje no significa nada*: se comportaron igual y uno sacó mejor número en la rifa. Con otra semilla los puntajes cambian, y cualquier análisis que compare los puntajes 1 y 2 de F está comparando dos muestras al azar del mismo grupo. Se nota en el inciso 6.3: los puntajes 1 y 2 de F tienen exactamente la misma tasa de compra (31.8 % y 31.7 %). Fijar la semilla hace que todos obtengan los mismos puntajes, pero no les da significado.

7.3. Inciso 6.3: ¿quién compró del 1 de octubre al 8 de diciembre?

Sea $\text{compra}_i = 1$ si el cliente i tiene alguna factura de venta entre el 1 de octubre y el 8 de diciembre de 2011. Lo hizo el 50.4 % de los 3 658 clientes. La tabla 21 y la figura 14 muestran la tasa de compra por puntaje en cada dimensión.

Puntaje	R	F	M
1.0	27.5 %	31.8 %	28.8 %
2.0	37.5 %	31.7 %	37.3 %
3.0	55.2 %	44.1 %	44.8 %
4.0	65.9 %	58.8 %	61.0 %
5.0	66.1 %	85.7 %	80.2 %

Clasificador	AUC
R (con signo invertido)	0.674
F	0.721
M	0.710
Suma de los tres puntajes	0.735

Tabla 21: Izquierda: fracción de clientes que compró entre el 1 de octubre y el 8 de diciembre, por puntaje. Derecha: AUC de cada variable cruda y de la suma de los tres puntajes como clasificadores de compra_i.

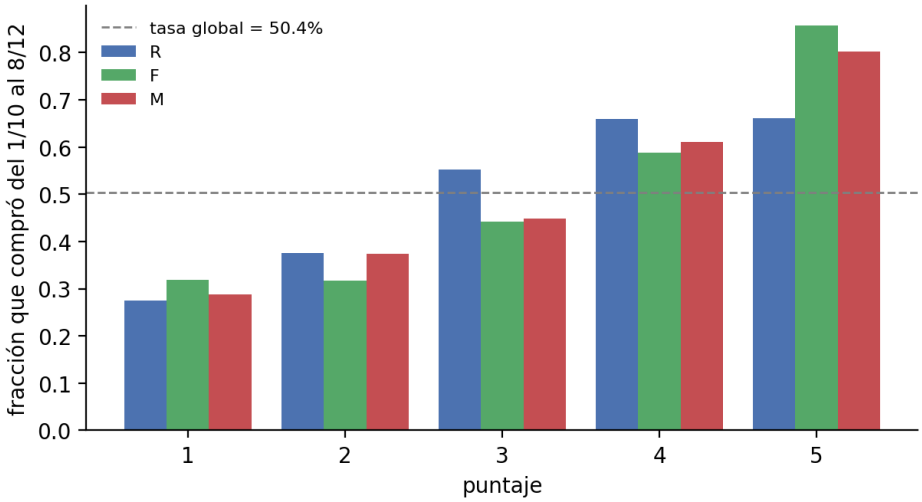


Figura 14: Tasa de compra en la ventana de prueba por puntaje de R, F y M.

Las tres dimensiones ordenan bien: la tasa de compra crece con el puntaje en las tres. Pero no separan igual.

- **F separa mejor**: del 31.7 % en los puntajes bajos al 85.7 % en el puntaje 5, el rango más amplio, y el mayor AUC de las tres variables crudas, 0.721. Quien ya compró muchas veces vuelve a comprar.
- **M** queda muy cerca (de 28.8 % a 80.2 %, AUC 0.710). Es natural: un cliente que compra muchas veces acumula más monto, así que M y F miden en buena parte lo mismo.
- **R** es la que menos separa (AUC 0.674). Distingue bien entre los puntajes bajos (27.5 % en el 1, 55.2 % en el 3), pero se satura arriba: los puntajes 4 y 5 tienen la misma tasa (65.9 % y 66.1 %). Haber comprado hace dos semanas o hace seis no hace diferencia en una ventana de diez semanas que además es la temporada alta, cuando incluso los clientes menos recientes vuelven.
- **La suma de los tres puntajes** tiene el mejor AUC, 0.735, pero apenas por encima de F sola: combinar las tres dimensiones agrega poco, porque están muy correlacionadas.

Un AUC de 0.72 significa que, si se toma al azar un cliente que compró y uno que no, F le da el valor más alto al que compró el 72 % de las veces: útil, pero lejos de una predicción segura.

7.4. Inciso 6.4: los campeones

Los clientes con puntaje 4 o 5 en las tres dimensiones son **792, el 21.7 % de los clientes**. Entre el 1 de octubre y el 8 de diciembre **generaron el 53.5 % de la venta neta** de todos los clientes con `CustomerID`, incluidos los nuevos: £1.28 millones de £2.40 millones (tabla 22). El 81.2 % de los campeones compró en esa ventana. Es la concentración típica de un negocio mayorista: uno de cada cinco clientes trae más de la mitad del dinero. Para una tienda, saber quiénes son vale más que cualquier pronóstico de la serie agregada.

Grupo	Clientes con movimiento	Venta (£)	% de la venta
Campeones (6.4)	650	1,284,885	53.5 %
Otros clientes con historia	1,223	737,944	30.7 %
Clientes nuevos	723	377,860	15.7 %
Total con CustomerID	2,596	2,400,689	100.0 %

Tabla 22: Reparto de la venta neta del 1 de octubre al 8 de diciembre de 2011 entre los clientes con `CustomerID`. "Clientes con movimiento" es cuántos clientes de cada grupo tuvieron alguna transacción en la ventana. Un cliente es nuevo si no tiene ninguna factura de venta antes del 1 de octubre.

7.5. Inciso 6.5: los clientes nuevos

De los 2 596 clientes con movimiento entre el 1 de octubre y el 8 de diciembre, **723 son nuevos**: no tienen ninguna factura de venta antes del 1 de octubre. Generaron **el 15.7 % de la venta neta** de la ventana, £377 860 (tabla 22).

¿Puede un RFM pronosticar esa venta? No, ni el RFM ni ningún modelo construido cliente por cliente. Un modelo así solo puede pronosticar a los clientes que tiene en su tabla, y un cliente nuevo no tiene fila: no hay R, ni F, ni M que calcular, porque todavía no ha hecho nada. Lo más que puede hacer un modelo por cliente es predecir que los clientes conocidos dejen de comprar; nunca que aparezcan clientes desconocidos. Ese 15.7 % es un error estructural, que no se corrige con un mejor modelo. Y es un mínimo: la venta sin `CustomerID`, el 15.4 % de toda la venta según el inciso 1.2(f), tampoco la ve ningún modelo por cliente.

Conexión con la Parte 5 y con el Proyecto 1. En el vocabulario de FPP2 (§10.3–10.4), la Parte 5 es un pronóstico *top-down*: se pronostica directamente la venta total. Un modelo que sume pronósticos cliente por cliente sería *bottom-up*. Solo el *top-down* puede ver a los clientes nuevos. No los ve como individuos, sino como parte del nivel de la serie: la llegada de cientos de clientes nuevos en el cuarto trimestre es una de las razones por las que la venta se duplicó desde septiembre, y es justamente ese cambio de nivel el que S2 siguió y le dio la victoria en el inciso 5.3. El *bottom-up*, en cambio, empieza con una desventaja: aunque pronosticara perfecto a cada cliente conocido, se quedaría corto en al menos un 15.7 % de la venta con cliente. Para la comparación que pide el Proyecto 1, esto significa que un pronóstico cliente por cliente necesita un componente aparte para la venta de clientes nuevos (que tendría que ser de algún modo *top-down*), o va a perder contra la serie agregada en cualquier periodo en que la tienda gane clientes, como en la temporada navideña.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`

[2] D. Chen, S. L. Sain y K. Guo. "Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining". *Journal of Database Marketing & Customer Strategy Management* 19.3 (2012), pp. 197–208.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005.