Tarea 3: Introducción a Series de Tiempo

Análisis y Ciencia de Datos

Herman Andrés Echeverría Rojas
Facultad de Ingeniería, Universidad del Istmo de Guatemala

18 de octubre de 2026

Resumen

Este documento acompaña al repositorio `https://github.com/HermanEcheverria/Series-de-Tiempo`. Todas las figuras y tablas que aparecen aquí las generan los scripts del repositorio a partir del archivo original `Online Retail.xlsx` y de las semillas documentadas en el código.

Índice

1. Parte 0: procesos simulados **2**
- 1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria . . . 2
- 1.2. Inciso 0.2: simulación del AR(1) . . . 3
- 1.3. Inciso 0.3: lo que dice la tabla . . . 4
- 1.4. Inciso 0.4: las dos razones para reprobar . . . 4
- 1.5. Inciso 0.5: la prueba que sí ve . . . 6

2. Parte 1: limpieza **6**
- 2.1. Inciso 1.1: el archivo crudo . . . 7
- 2.2. Inciso 1.2: caso por caso . . . 7
- 2.3. Inciso 1.3: bitácora de limpieza . . . 9
- 2.4. Inciso 1.4: las seis líneas más grandes . . . 10

1. Parte 0: procesos simulados

Antes de tocar datos reales conviene ver cómo se comportan la ACF y las pruebas de ruido blanco en procesos donde la respuesta es conocida. Todo lo de esta sección lo produce `parte0.py`, con las semillas de `semillas.py`; las funciones r_k, Ljung–Box y el estimado OLS de ϕ están implementadas a mano en `series.py` y son las mismas que se usan con la serie de ventas en las Partes 3 y 4.

1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria

Sea $Y_t = c + \phi Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, $|\phi| < 1$, y supongamos que el proceso es débilmente estacionario: $E[Y_t] = \mu$ y $\text{Var}(Y_t) = \gamma_0$ para todo t.

Media. Tomando esperanza en ambos lados y usando $E[\varepsilon_t] = 0$:

$$\mu = E[Y_t] = c + \phi\, E[Y_{t-1}] + E[\varepsilon_t] = c + \phi\mu \quad \Longrightarrow \quad \mu(1-\phi) = c \quad \Longrightarrow \quad E[Y_t] = \frac{c}{1-\phi}.$$

La división es válida porque $|\phi| < 1$ implica $\phi \neq 1$.

Varianza. Y_{t-1} depende solo de $\varepsilon_{t-1}, \varepsilon_{t-2}, \ldots$, así que es independiente de ε_t y la covarianza entre ambos es cero. La constante c no aporta varianza. Entonces

$$\gamma_0 = \text{Var}(c + \phi Y_{t-1} + \varepsilon_t) = \phi^2\, \text{Var}(Y_{t-1}) + \text{Var}(\varepsilon_t) + 2\phi\, \text{Cov}(Y_{t-1}, \varepsilon_t) = \phi^2 \gamma_0 + \sigma^2,$$

donde se usó $\text{Var}(Y_{t-1}) = \text{Var}(Y_t) = \gamma_0$. Despejando,

$$\text{Var}(Y_t) = \gamma_0 = \frac{\sigma^2}{1-\phi^2},$$

que es positiva y finita justamente porque $\phi^2 < 1$.

Autocorrelación. Para $k \geq 1$, Y_{t-k} depende solo de choques anteriores a $t-k+1$, así que $\text{Cov}(\varepsilon_t, Y_{t-k}) = 0$ y la constante no covaría con nada:

$$\gamma_k = \text{Cov}(Y_t, Y_{t-k}) = \text{Cov}(c + \phi Y_{t-1} + \varepsilon_t,\ Y_{t-k}) = \phi\ \text{Cov}(Y_{t-1}, Y_{t-k}) = \phi\, \gamma_{k-1}.$$

El último paso usa la estacionariedad: la covarianza entre Y_{t-1} y Y_{t-k} solo depende de su separación, $k-1$. Iterando la recursión desde γ_0 se obtiene $\gamma_k = \phi^k \gamma_0$, y por lo tanto

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k.$$

Caminata aleatoria. Con $\phi = 1$, $c = 0$ y $Y_0 = 0$, sustituyendo hacia atrás,

$$Y_t = Y_{t-1} + \varepsilon_t = Y_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \cdots = Y_0 + \sum_{i=1}^{t} \varepsilon_i = \sum_{i=1}^{t} \varepsilon_i.$$

Los ε_i son independientes, así que la varianza de la suma es la suma de las varianzas:

$$\text{Var}(Y_t) = \sum_{i=1}^{t} \text{Var}(\varepsilon_i) = t\sigma^2.$$

La media sí es constante ($E[Y_t] = 0$), pero la varianza crece linealmente con t: depende del momento en que se observa, y eso viola directamente la condición $\text{Var}(Y_t) = \sigma^2$ para todo t de la estacionariedad débil. Dicho de otra forma, la fórmula $\sigma^2/(1-\phi^2)$ explota cuando $\phi \to 1$: no existe una varianza estacionaria a la cual converger. Tampoco la autocorrelación es función solo del rezago: $\text{Corr}(Y_t, Y_{t-k}) = \sqrt{(t-k)/t}$, que depende de t.

1.2. Inciso 0.2: simulación del AR(1)

La función `simular_ar1` genera $200 + 300$ pasos de un AR(1) con $c = 0$ y $\sigma = 1$ a partir de $Y_0 = 0$ y descarta los primeros 200. Con $|\phi| < 1$ el efecto del valor inicial decae como ϕ^t; a los 200 pasos, incluso con $\phi = 0.9$, queda $0.9^{200} \approx 7 \times 10^{-10}$ del valor inicial, así que la serie que se conserva ya está en su distribución estacionaria. Con $\phi = 1$ eso no funciona: la serie conservada es $Y_t = Y_{200} + \sum_{i=201}^{t} \varepsilon_i$, una caminata aleatoria que arranca en Y_{200} en lugar de 0, y la varianza sigue creciendo sin límite. Pero el punto de arranque no afecta a r_k: sumar una constante a toda la serie mueve también a $\bar{y}$ y deja intactas las desviaciones $y_t - \bar{y}$, que son lo único que entra en la fórmula. Por eso descartar o no los 200 pasos no cambia en nada los resultados de r_k para la caminata.

La figura 1 muestra una realización de cada proceso. Con $\phi = 0$ la serie no tiene ninguna inercia; con $\phi = 0.5$ aparecen rachas cortas; con $\phi = 0.9$ la serie pasa decenas de pasos de un mismo lado de cero, aunque siempre regresa; y con $\phi = 1$ nunca regresa: se aleja de su origen (nótese que arranca en $Y_{200} \neq 0$) y lo que en un AR estacionario serían fluctuaciones aquí parece una tendencia.

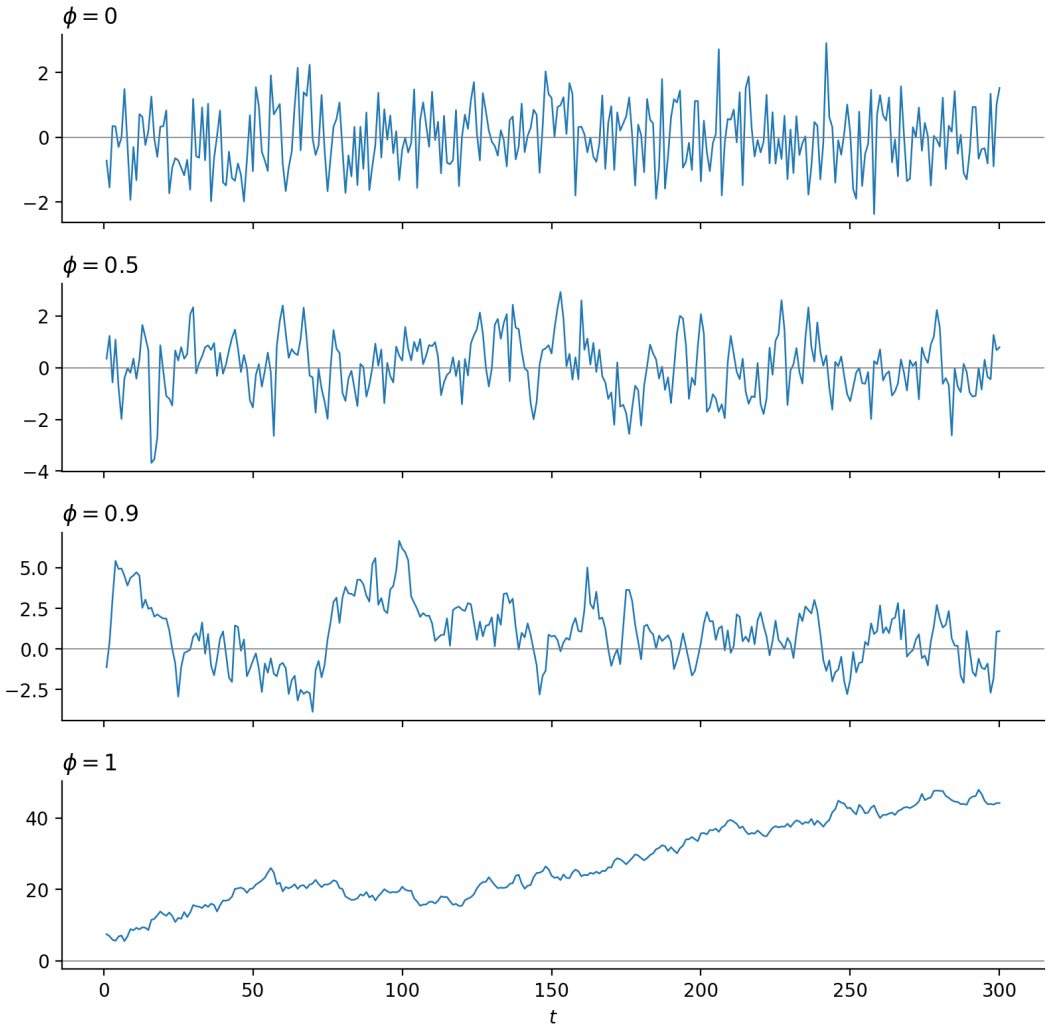


Figura 1: Una realización de 300 pasos de cada AR(1), después de descartar 200 pasos de arranque. La escala vertical cambia entre paneles: la varianza estacionaria $1/(1-\phi^2)$ vale 1, 1.33 y 5.26 para $\phi = 0, 0.5, 0.9$, y no existe para $\phi = 1$.

La tabla 1 resume las 5 000 réplicas por escenario. Cada celda es el promedio sobre réplicas y, entre paréntesis, su error estándar $s/\sqrt{5000}$. La tasa de rechazo es la fracción de réplicas en que $|r_1| > 1.96/\sqrt{300} = 0.113$, es decir, en que la prueba de retardo 1 de la Tarea 2 declara que la serie no es ruido blanco.

ϕ	$\bar{r}_1$	$\bar{r}_5$	ϕ^5	Rechazo $\lvert r_1\rvert > 1.96/\sqrt{n}$	$\bar{\hat{\phi}}_{\text{OLS}}$
0	-0.002 (0.001)	-0.003 (0.001)	0.000	0.046 (0.003)	-0.002 (0.001)
0.5	0.491 (0.001)	0.020 (0.001)	0.031	1.000 (0.000)	0.492 (0.001)
0.9	0.884 (0.000)	0.534 (0.001)	0.590	1.000 (0.000)	0.887 (0.000)
1	0.976 (0.000)	0.883 (0.001)	1.000	1.000 (0.000)	0.982 (0.000)

Tabla 1: AR(1) con $n = 300$ y 5 000 réplicas por valor de ϕ. Promedio (error estándar).

1.3. Inciso 0.3: lo que dice la tabla

Ruido blanco. Con $\phi = 0$ la prueba rechaza en el 4.62 % de las réplicas, con error estándar de 0.30 puntos: está a poco más de un error estándar del 5 % nominal, que es lo esperado. La prueba está construida precisamente para equivocarse un 5 % de las veces cuando la hipótesis nula es cierta, y aquí la nula es cierta por construcción. Que quede un poco por debajo de 5 % tiene además una razón teórica: bajo ruido blanco, $E[r_1] \approx -1/n$ y $\mathrm{Var}(r_1) \approx (n-1)/(n(n+2))$, ligeramente menor que la $1/n$ con que se dibujan las bandas, así que la tasa exacta ronda 4.9 %. El $\bar{r}_1 = -0.0023$ observado también es compatible con $-1/300 = -0.0033$.

Caminata aleatoria. La teoría estacionaria diría $\rho_5 = \phi^5 = 1$, pero el promedio de r_5 es 0.883. No es un error de simulación (el error estándar es 0.001): para una caminata aleatoria la ACF muestral está fuertemente sesgada hacia abajo. La razón es que r_k mide desviaciones respecto a $\bar{y}$, y en una caminata $\bar{y}$ es una media que no representa a ningún tramo de la serie: la serie se pasa largos periodos de un lado y luego del otro. Además el denominador usa los n términos y el numerador solo $n - k$. De hecho, la fórmula $\rho_k = \phi^k$ ni siquiera aplica, porque la derivación del inciso 0.1 supuso estacionariedad. Lo que sí se ve es la huella visual que menciona el enunciado: la ACF de la caminata baja muy despacio ($\bar{r}_1 = 0.976$, $\bar{r}_5 = 0.883$), mientras que con $\phi = 0.5$ el valor ya cayó a casi cero en el rezago 5. Para los procesos estacionarios el sesgo de r_5 también existe pero es menor: con $\phi = 0.9$ se obtiene 0.534 contra $0.9^5 = 0.590$, y con $\phi = 0.5$, 0.020 contra 0.031.

Sesgo del estimado OLS. El estimado OLS de ϕ queda sistemáticamente por debajo del valor verdadero, y el sesgo crece con ϕ: -0.002 para $\phi = 0$, -0.008 para 0.5, -0.013 para 0.9 y -0.018 para 1, todos varias veces mayores que su error estándar. Es el sesgo de Hurwicz: en una autorregresión el regresor y_{t-1} no es independiente de los errores pasados, y la aproximación clásica $E[\hat{\phi}] - \phi \approx -(1+3\phi)/n$ da -0.003, -0.008 y -0.012 para los tres casos estacionarios, muy cerca de lo observado. El estimador es consistente: el sesgo es de orden $1/n$ y desaparece cuando la muestra crece, aunque con 300 observaciones todavía se nota. En la caminata, la teoría de Dickey–Fuller dice que $\hat{\phi}$ converge todavía más rápido (a ritmo $1/n$ en vez de $1/\sqrt{n}$) pero con una distribución asimétrica, cargada hacia valores menores que 1, y eso es lo que se ve en el 0.982.

1.4. Inciso 0.4: las dos razones para reprobar

Ahora $Y_t = m_t + \varepsilon_t$ no tiene ninguna memoria: los ε_t son independientes y m_t es determinista. La figura 2 muestra una realización de cada proceso y la tabla 2 repite la tabla del inciso 0.2 agregando

$\bar{r}_7$; la primera fila es el ruido blanco del inciso anterior, como referencia.

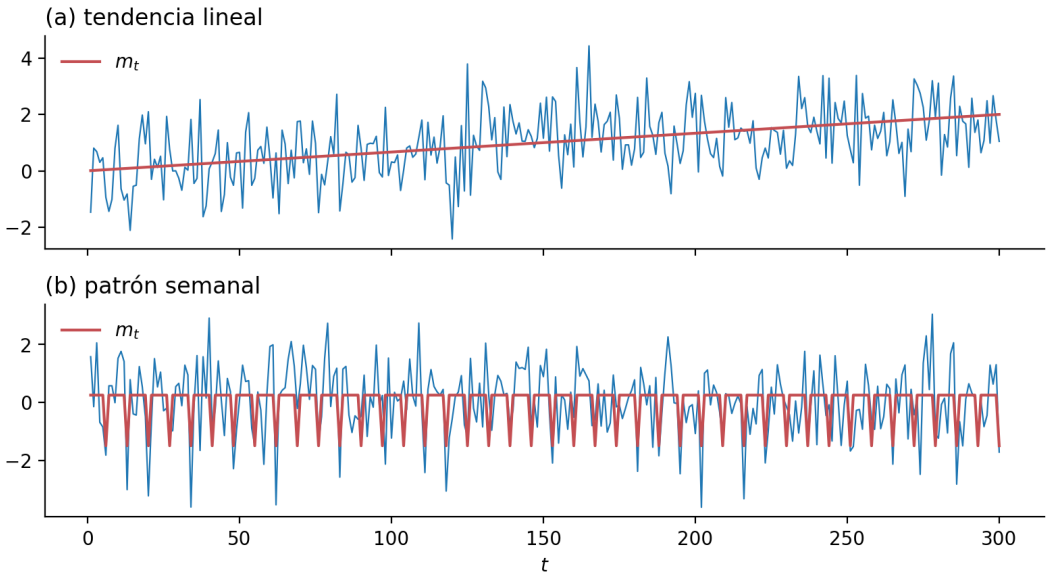


Figura 2: Procesos sin memoria con media variable. En rojo, la media m_t.

Proceso	$\bar{r}_1$	$\bar{r}_5$	$\bar{r}_7$	Rechazo r_1	$\bar{\hat{\phi}}_{\text{OLS}}$
Ruido blanco ($\phi = 0$)	-0.002 (0.001)	-0.003 (0.001)	-0.004 (0.001)	0.046 (0.003)	-0.002 (0.001)
(a) Tendencia	0.246 (0.001)	0.235 (0.001)	0.230 (0.001)	0.986 (0.002)	0.247 (0.001)
(b) Semanal	-0.047 (0.001)	-0.050 (0.001)	0.266 (0.001)	0.112 (0.004)	-0.048 (0.001)

Tabla 2: Procesos sin memoria, $n = 300$, 5 000 réplicas. Promedio (error estándar).

La tendencia reprueba sin tener memoria. La serie con tendencia rechaza la prueba de retardo 1 en el 98.6 % de las réplicas, y el OLS le asigna $\hat{\phi} \approx 0.25$ a un proceso cuyo ϕ verdadero es cero. Se puede predecir el número: m_t recorre $[0, 2]$ de forma casi uniforme, con varianza $\approx 4/12 = 1/3$, y como dos días cercanos tienen casi la misma m_t, la covarianza entre vecinos es esa misma varianza; así $r_k \approx (1/3)/(1/3 + 1) = 0.25$ para todo rezago pequeño. Eso es exactamente lo que dice la tabla: $\bar{r}_1 = 0.246$, $\bar{r}_5 = 0.235$, $\bar{r}_7 = 0.230$, una ACF que casi no decae. Es la razón (2) del enunciado: $\bar{y}$ no es la media de nadie, los días del final quedan todos por encima y los del inicio todos por debajo, y eso se ve como correlación.

El patrón semanal pasa aunque tenga estructura. La serie semanal rechaza solo en el 11.2 % de las réplicas, poco más que el ruido blanco, y su $\bar{r}_1 = -0.047$ es diminuto. De nuevo se puede calcular: sobre un ciclo de 7 días m_t tiene media 0 y varianza $(6 \cdot 0.25^2 + 1.5^2)/7 = 0.375$, pero la covarianza entre días consecutivos es solo $(5 \cdot 0.25^2 - 2 \cdot 0.375)/7 = -0.0625$, y $r_1 \approx -0.0625/1.375 = -0.045$. Toda la estructura está a distancia 7: un domingo se parece al domingo anterior, no al sábado. Por eso $\bar{r}_7 = 0.266$ (la predicción es $0.375/1.375 = 0.273$), mientras que r_1 y r_5 están cerca de cero.

Conexión con RANDU. Es el mismo fenómeno que con RANDU en la Tarea 2: RANDU pasaba las pruebas unidimensionales y de pares consecutivos y, sin embargo, sus ternas caían en solo 15 planos, porque su dependencia vivía en una combinación de los rezagos 1 y 2 que esas pruebas no miran. La prueba de retardo 1 solo puede ver estructura en el rezago 1; un proceso con la dependencia en otro lado (el rezago 7, o una combinación lineal de rezagos) la pasa sin problema. Pasar una prueba nunca demuestra independencia: solo dice que en la dirección que esa prueba mira no se encontró nada.

1.5. Inciso 0.5: la prueba que sí ve

La tabla 3 compara la tasa de rechazo de la prueba de retardo 1 con la de Ljung–Box al 5 %, con $m = 10$ (la recomendación de FPP2 sin estacionalidad) y con $m = 6 \approx \log(300) = 5.7$ (la sugerencia de Tsay). La implementación propia coincide con `statsmodels.stats.diagnostic.acorr_ljungbox` hasta el sexto decimal en el estadístico y en el valor-p; `parte0.py` lo verifica con un `assert` en una réplica de cada proceso.

Proceso	Rechazo r_1	LB $m = 10$	LB $m = 6$
Ruido blanco ($\phi = 0$)	0.046 (0.003)	0.053 (0.003)	0.053 (0.003)
(a) Tendencia	0.986 (0.002)	1.000 (0.000)	1.000 (0.000)
(b) Semanal	0.112 (0.004)	0.956 (0.003)	0.209 (0.006)

Tabla 3: Tasa de rechazo al 5 % sobre 5 000 réplicas, $n = 300$. Promedio (error estándar).

Con ruido blanco las dos versiones de Ljung–Box rechazan alrededor del 5 % (5.3 %), como deben. Con la tendencia rechazan siempre, igual que la prueba de retardo 1: ahí la estructura se ve en todos los rezagos.

El cambio está en el patrón semanal. Ljung–Box con $m = 10$ lo rechaza en el 95.6 % de las réplicas, contra el 11.2 % de la prueba de retardo 1, porque $Q(10)$ suma r_k^2 para $k = 1, \ldots, 10$ y eso incluye el $r_7 \approx 0.27$ que la prueba de retardo 1 no mira; elevado al cuadrado y multiplicado por $n(n+2)/(n-7)$, ese solo término aporta alrededor de 22 al estadístico, cuando el valor crítico de una χ^2_{10} al 5 % es 18.3. En cambio, con $m = 6$ la tasa cae a 20.9 %: seis rezagos no llegan al 7, así que $Q(6)$ es casi tan ciego como la prueba de retardo 1. Esta es la comparación que pedía el enunciado entre las dos reglas para escoger m, y la lección es que m tiene que cubrir al menos el periodo estacional; por eso FPP2 recomienda $m = 2s$ cuando hay estacionalidad. Con datos diarios de una tienda, la regla $m \approx \log n$ por sí sola no es suficiente.

2. Parte 1: limpieza

La limpieza vive en `limpiar.py` y la reproduce `parte1.py`. El archivo se carga con `datos.cargar_crudo()`, que lee `InvoiceNo`, `StockCode` y `CustomerID` como texto. El enunciado sugiere hacerlo y pide averiguar por qué; leyendo el archivo sin indicarle tipos a pandas se ve el problema en cada columna:

- `InvoiceNo` queda como una columna con 532 618 enteros (`536365`) y 9 291 cadenas (`C536379`) revueltos. Entonces `str.startswith('C')` devuelve `NaN`, no `False`, en todas las filas numéricas, y cualquier filtro de cancelaciones construido así falla en silencio.

- `StockCode` mezcla 487 036 códigos numéricos con 54 873 alfanuméricos (`85123A`, `POST`). Una regla sobre el texto del código, como "empieza con cinco dígitos", se salta todas las filas que pandas convirtió en enteros.
- `CustomerID` tiene faltantes, y como una columna entera de pandas no admite `NaN`, se convierte a `float`: `17850.0`. Un identificador no es una cantidad: no se suma ni se promedia, y no debería tener decimales.

2.1. Inciso 1.1: el archivo crudo

Concepto	Valor
Filas	541,909
Facturas distintas	25,900
Productos distintos (StockCode)	4,070
Productos distintos sin distinguir mayúsculas	3,958
Clientes distintos (CustomerID)	4,372
Filas sin CustomerID	135,080 (24.9 %)
Primera factura	2010-12-01 08:26:00
Última factura	2011-12-09 12:50:00

Tabla 4: Tamaño del archivo original, antes de limpiar.

El archivo tiene 541 909 líneas de 25 900 facturas, 4 070 códigos de producto y 4 372 clientes (tabla 4). El 24.9 % de las filas no tiene `CustomerID`. El número de productos depende de cómo se cuente: 117 códigos aparecen también en minúscula (`85123a` junto a `85123A`), y unificándolos quedan 3 958.

2.2. Inciso 1.2: caso por caso

La tabla 5 cuenta cada caso sobre los datos crudos, sin aplicar ninguna otra regla, y resume la decisión. El monto es la suma con signo de `Quantity` × `UnitPrice` de esas filas.

Caso	Filas	Monto neto (£)	Decisión
(a) Duplicados exactos	5,268	21,740.98	Se va
(b) Facturas con prefijo C	9,288	-896,812.49	Se queda (resta)
(b) Facturas con prefijo A	3	-11,062.06	Se va
(c) Códigos que no son productos	2,297	29,406.91	Se va
(c) Códigos en minúscula	1,943	30,702.15	Se transforma
(d) Precio negativo	2	-22,124.12	Se va
(d) Precio cero	2,515	0.00	Se va
(e) Cantidad negativa sin ser cancelación	1,336	0.00	Se va
(f) Sin CustomerID	135,080	1,447,682.12	Serie: se queda; RFM: se va

Tabla 5: Casos del inciso 1.2 sobre los datos crudos. Un caso puede traslapar con otro; el efecto conjunto está en la bitácora (tabla 7).

(a) Duplicados exactos: se van. Hay 5 268 filas idénticas en las ocho columnas a otra fila anterior: misma factura, mismo producto, misma cantidad y mismo minuto. Una factura que de

verdad incluyera dos veces el mismo artículo lo registraría como una línea con la cantidad sumada; dos líneas idénticas son una doble captura. Se conserva la primera. Representan £21 741.

(b) Facturas que no empiezan con un dígito. Hay dos prefijos. El `C` marca 9 288 cancelaciones, todas con cantidad negativa: *se quedan*, porque la venta neta diaria las define como líneas que restan el día en que ocurren. El `A` aparece en tres facturas del 12 de agosto de 2011 con el código `B`, "Adjust bad debt", por +11 062 y dos veces −11 062 libras: *se van*, porque son asientos contables de deuda incobrable, no ventas ni devoluciones de mercancía.

(c) Códigos que no son productos. La tabla 6 lista todos los códigos que no empiezan con cinco dígitos. No todos son iguales:

- *Se van* los cargos que no son mercancía: envío (`POST`, `DOT`, `C2`), comisiones (`AMAZONFEE`, `CRUK`), cargos bancarios, muestras (`S`), el ajuste de deuda `B` y los vales de regalo `gift_0001_*`, que son dinero adelantado y se contarían dos veces cuando se canjearan. El caso que más pesa es `AMAZONFEE`: 32 de sus 34 filas son "cancelaciones" de hasta £17 836, que en realidad son la comisión que cobra Amazon. Dejarlas habría restado £221 521 de ventas que nunca se devolvieron.
- *Se quedan* los `DCGS...` (artículos de la tienda *dotcom*, como bolsas de fiesta o collares) y `PADS`, que sí son productos aunque su código no tenga cinco dígitos.
- *Se quedan* también `D` (descuento) y `M` (ajuste manual). No son productos, pero corrigen el precio de mercancía que sí se vendió: un descuento reduce lo que la tienda cobró. El inciso 1.4 muestra qué pasa si se quitan: la factura 556444 cobró por error 60 canastas a £649.50 cada una, y la corrección es la línea `M` de la cancelación C556445. Si se quitaran las `M`, la serie se quedaría con una venta fantasma de £38 970.
- *Se transforman* los 117 códigos en minúscula, que se pasan a mayúscula.

StockCode	Filas	Monto neto (£)	Descripción	% cancelación	Decisión
POST	1,256	66,230.64	POSTAGE	10	Se va
DOT	710	206,245.48	DOTCOM POSTAGE	0	Se va
M	571	-68,674.19	Manual	43	Se queda
C2	144	6,986.00	CARRIAGE	1	Se va
D	77	-5,696.22	Discount	100	Se queda
S	63	-3,049.39	SAMPLES	97	Se va
DCGS...	45	398.45	SUNJAR LED NIGHT NIGHT LIGHT	0	Se queda
BANK CHARGES	37	-7,175.64	Bank Charges	68	Se va
AMAZONFEE	34	-221,520.50	AMAZON FEE	94	Se va
gift_0001_...	34	685.81	Dotcomgiftshop Gift Voucher £40.	0	Se va
CRUK	16	-7,933.43	CRUK Commission	100	Se va
PADS	4	0.00	PADS TO MATCH ALL CUSHIONS	0	Se queda
B	3	-11,062.06	Adjust bad debt	0	Se va
m	1	2.55	Manual	0	Se queda

Tabla 6: Códigos que no empiezan con cinco dígitos, en los datos crudos. La columna de cancelación es el porcentaje de sus filas en facturas `C`.

(d) Precios iguales a cero o negativos: se van. Los dos precios negativos son las líneas de deuda incobrable del caso (b). Los 2 515 precios en cero no aportan nada a la venta (su monto es exactamente cero), y casi todos son movimientos de inventario sin cliente: 1 336 tienen cantidad negativa (caso e) y, de las que tienen cantidad positiva, solo 40 tienen cliente, probablemente obsequios. Para la serie da igual quitarlos o no; se quitan para que no inflen la frecuencia de compra en la Parte 6.

(e) Cantidades negativas que no son cancelaciones: se van. Son 1 336 filas, todas con precio cero y ninguna con cliente. Su descripción lo explica: vacía (862), "check" (123), "damaged" o "damages" (103), "?" (41), "sold as set on dotcom", "thrown away", "wet damaged", "missing"... Son ajustes de inventario por mercancía dañada, perdida o reetiquetada, no devoluciones de clientes.

(f) Filas sin `CustomerID`: depende. Para la serie de ventas *se quedan*: una venta sin cliente identificado sigue siendo dinero que entró a la tienda. Después de la limpieza son el 24.8 % de las filas y el 15.4 % de la venta neta (£1.50 millones), casi todas del Reino Unido; quitarlas bajaría el nivel de la serie y, si su peso cambia con el tiempo, también su forma. Para la Parte 6 *se van*, porque el RFM necesita saber quién compró. Por eso `limpiar` tiene el argumento `requiere_cliente`.

2.3. Inciso 1.3: bitácora de limpieza

Las reglas se aplican en el orden de la tabla 7. La columna "Sola" cuenta las filas que la regla quitaría aplicada sobre los datos crudos; "En orden" cuenta las que realmente quita después de las anteriores. El monto corresponde a las filas que quita en orden: el neto es la suma con signo y el absoluto, la suma de $|\texttt{Quantity} \times \texttt{UnitPrice}|$. La regla 6 solo se aplica para la Parte 6.

Orden	Regla	Sola	En orden	Monto neto (£)	Monto absoluto (£)
1	Duplicados exactos	5,268	5,268	21,740.98	27,406.50
2	Facturas con prefijo A (ajuste de deuda)	3	3	-11,062.06	33,186.18
3	Códigos que no son productos	2,297	2,293	40,478.71	571,674.49
4	Precio igual a cero o negativo	2,517	2,499	0.00	0.00
5	Cantidad negativa sin ser cancelación	1,336	0	0.00	0.00
6	Sin CustomerID	135,080	131,656	1,495,555.05	1,573,094.09
	Total		141,719	1,546,712.68	2,205,361.26

Tabla 7: Bitácora de limpieza, en el orden en que se aplican las reglas.

El orden sí cambia los conteos. La regla 5 no quita ninguna fila en orden, pero aplicada sola quitaría 1 336: todas las cantidades negativas sin cancelación tienen precio cero, así que la regla 4 ya las eliminó. Si el orden fuera el inverso, la regla 5 se llevaría 1 336 filas y la 4, 1 336 menos. Del mismo modo, la regla 3 quita 2 293 filas y no 2 297 porque las tres líneas `B` ya cayeron con el prefijo `A` y una más era duplicado; y la regla 4 quita 2 499 y no 2 517 porque los dos precios negativos ya cayeron con el prefijo `A`, cinco eran duplicados y once tenían un código que no es producto. Ninguna de estas diferencias cambia el resultado final: las reglas solo deciden a qué renglón de la bitácora se le atribuye cada fila.

Para la serie de ventas (reglas 1 a 5) quedan 531 846 filas con una venta neta total de £9 696 590; 8 989 de esas filas son cancelaciones que suman −£628 382. Para el RFM (reglas 1 a 6) quedan 400 190 filas.

2.4. Inciso 1.4: las seis líneas más grandes

La tabla 8 muestra las seis líneas con mayor $|\texttt{Quantity} \times \texttt{UnitPrice}|$ en los datos crudos. Son tres pares venta–cancelación.

Factura	Fecha	Cliente	Producto	Cantidad	Precio	Monto (£)	¿Sobrevive?
C581484	09/12/2011 09:27	16446	Paper Craft , Little Birdie	-80,995	2.08	-168,469.60	Sí
581483	09/12/2011 09:15	16446	Paper Craft , Little Birdie	80,995	2.08	168,469.60	Sí
C541433	18/01/2011 10:17	12346	Medium Ceramic Top Storage Jar	-74,215	1.04	-77,183.60	Sí
541431	18/01/2011 10:01	12346	Medium Ceramic Top Storage Jar	74,215	1.04	77,183.60	Sí
C556445	10/06/2011 15:31	15098	Manual	-1	38,970.00	-38,970.00	Sí
556444	10/06/2011 15:28	15098	Picnic Basket Wicker 60 Pieces	60	649.50	38,970.00	Sí

Tabla 8: Las seis líneas con mayor monto absoluto antes de limpiar. "¿Sobrevive?" indica si la línea sigue en los datos limpios.

- **Paper Craft, Little Birdie (cliente 16446).** El 9 de diciembre de 2011 a las 9:15 la factura 581483 vende 80 995 unidades a £2.08, £168 470 en una sola línea, y doce minutos después la C581484 la cancela completa. El cliente solo tiene otra compra en todo el año: dos artículos por £2.90 en mayo. Es casi seguro un error de captura, corregido de inmediato.
- **Medium Ceramic Top Storage Jar (cliente 12346).** El 18 de enero de 2011 la factura 541431 vende 74 215 frascos a £1.04 (£77 184), y dieciséis minutos después la C541433 la cancela. Es la única actividad del cliente en todo el archivo, así que su venta neta total es cero; vuelve a aparecer en la Parte 6 como un cliente con $M \leq 0$.
- **Picnic Basket Wicker 60 Pieces (cliente 15098).** El 10 de junio de 2011 la secuencia completa es: 556442 vende 60 canastas pequeñas a £4.95 (£297); 556444 cobra 60 unidades a £649.50, que es el precio del juego de 60 piezas, no de una canasta (£38 970); C556445 lo corrige con una línea `Manual` de −£38 970; 556446 cobra el juego correcto, una unidad a £649.50; y C556448 cancela las canastas pequeñas. Lo que el cliente compró en realidad fue un juego de £649.50.

¿Las resuelve la limpieza? No: las seis sobreviven, y está bien que sobrevivan. Ninguna regla las identifica como errores (son productos reales, con precio positivo y con cliente), y quitar una sola mitad del par sería peor que dejar las dos. Si una regla quitara la venta de 80 995 unidades por "atípica", la cancelación quedaría huérfana y restaría £168 470 ese día. Por la misma razón la regla de códigos no quita la línea `M`: quitarla dejaría la venta de £38 970.

¿Las resuelve el neteo por día? Sí, porque en los tres casos la venta y su corrección ocurren el mismo día, con minutos de diferencia. En la venta neta del 18 de enero el par del frasco suma exactamente cero; la del 10 de junio recibe del cliente 15098 exactamente los £649.50 que compró; y el par del 9 de diciembre suma cero (además, la Parte 2 descarta ese día por incompleto). La serie diaria es inmune a estos errores siempre que se corrijan el mismo día. Un análisis por cliente o por factura no lo es: en la Parte 6 cada una de estas facturas cuenta como una compra para la frecuencia, aunque el monto neto sea cero.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`

[2] D. Chen, S. L. Sain y K. Guo. "Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining". *Journal of Database Marketing & Customer Strategy Management* 19.3 (2012), pp. 197–208.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005.