Tarea 3: Introducción a Series de Tiempo

Análisis y Ciencia de Datos

Herman Andrés Echeverría Rojas
Facultad de Ingeniería, Universidad del Istmo de Guatemala

18 de octubre de 2026

Resumen

Este documento acompaña al repositorio `https://github.com/HermanEcheverria/Series-de-Tiempo`. Todas las figuras y tablas que aparecen aquí las generan los scripts del repositorio a partir del archivo original `Online Retail.xlsx` y de las semillas documentadas en el código.

Índice

1. Parte 0: procesos simulados **2**
- 1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria . . . 2
- 1.2. Inciso 0.2: simulación del AR(1) . . . 3
- 1.3. Inciso 0.3: lo que dice la tabla . . . 4
- 1.4. Inciso 0.4: las dos razones para reprobar . . . 4
- 1.5. Inciso 0.5: la prueba que sí ve . . . 6

2. Parte 1: limpieza **6**
- 2.1. Inciso 1.1: el archivo crudo . . . 7
- 2.2. Inciso 1.2: caso por caso . . . 7
- 2.3. Inciso 1.3: bitácora de limpieza . . . 9
- 2.4. Inciso 1.4: las seis líneas más grandes . . . 10

3. Parte 2: el calendario **10**
- 3.1. Inciso 2.1: la serie de venta neta diaria . . . 11
- 3.2. Inciso 2.2: los días sin transacciones . . . 11
- 3.3. Inciso 2.3: ¿cero o faltante? . . . 13
- 3.4. Inciso 2.4: el último día . . . 13

1. Parte 0: procesos simulados

Antes de tocar datos reales conviene ver cómo se comportan la ACF y las pruebas de ruido blanco en procesos donde la respuesta es conocida. Todo lo de esta sección lo produce `parte0.py`, con las semillas de `semillas.py`; las funciones r_k, Ljung–Box y el estimado OLS de ϕ están implementadas a mano en `series.py` y son las mismas que se usan con la serie de ventas en las Partes 3 y 4.

1.1. Inciso 0.1: momentos del AR(1) y de la caminata aleatoria

Sea $Y_t = c + \phi Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$, $|\phi| < 1$, y supongamos que el proceso es débilmente estacionario: $E[Y_t] = \mu$ y $\text{Var}(Y_t) = \gamma_0$ para todo t.

Media. Tomando esperanza en ambos lados y usando $E[\varepsilon_t] = 0$:

$$\mu = E[Y_t] = c + \phi\, E[Y_{t-1}] + E[\varepsilon_t] = c + \phi\mu \quad \Longrightarrow \quad \mu(1-\phi) = c \quad \Longrightarrow \quad E[Y_t] = \frac{c}{1-\phi}.$$

La división es válida porque $|\phi| < 1$ implica $\phi \neq 1$.

Varianza. Y_{t-1} depende solo de $\varepsilon_{t-1}, \varepsilon_{t-2}, \ldots$, así que es independiente de ε_t y la covarianza entre ambos es cero. La constante c no aporta varianza. Entonces

$$\gamma_0 = \text{Var}(c + \phi Y_{t-1} + \varepsilon_t) = \phi^2\, \text{Var}(Y_{t-1}) + \text{Var}(\varepsilon_t) + 2\phi\, \text{Cov}(Y_{t-1}, \varepsilon_t) = \phi^2 \gamma_0 + \sigma^2,$$

donde se usó $\text{Var}(Y_{t-1}) = \text{Var}(Y_t) = \gamma_0$. Despejando,

$$\text{Var}(Y_t) = \gamma_0 = \frac{\sigma^2}{1-\phi^2},$$

que es positiva y finita justamente porque $\phi^2 < 1$.

Autocorrelación. Para $k \geq 1$, Y_{t-k} depende solo de choques anteriores a $t-k+1$, así que $\text{Cov}(\varepsilon_t, Y_{t-k}) = 0$ y la constante no covaría con nada:

$$\gamma_k = \text{Cov}(Y_t, Y_{t-k}) = \text{Cov}(c + \phi Y_{t-1} + \varepsilon_t,\ Y_{t-k}) = \phi\ \text{Cov}(Y_{t-1}, Y_{t-k}) = \phi\, \gamma_{k-1}.$$

El último paso usa la estacionariedad: la covarianza entre Y_{t-1} y Y_{t-k} solo depende de su separación, $k-1$. Iterando la recursión desde γ_0 se obtiene $\gamma_k = \phi^k \gamma_0$, y por lo tanto

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \phi^k.$$

Caminata aleatoria. Con $\phi = 1$, $c = 0$ y $Y_0 = 0$, sustituyendo hacia atrás,

$$Y_t = Y_{t-1} + \varepsilon_t = Y_{t-2} + \varepsilon_{t-1} + \varepsilon_t = \cdots = Y_0 + \sum_{i=1}^{t} \varepsilon_i = \sum_{i=1}^{t} \varepsilon_i.$$

Los ε_i son independientes, así que la varianza de la suma es la suma de las varianzas:

$$\text{Var}(Y_t) = \sum_{i=1}^{t} \text{Var}(\varepsilon_i) = t\sigma^2.$$

La media sí es constante ($E[Y_t] = 0$), pero la varianza crece linealmente con t: depende del momento en que se observa, y eso viola directamente la condición $\text{Var}(Y_t) = \sigma^2$ para todo t de la estacionariedad débil. Dicho de otra forma, la fórmula $\sigma^2/(1-\phi^2)$ explota cuando $\phi \to 1$: no existe una varianza estacionaria a la cual converger. Tampoco la autocorrelación es función solo del rezago: $\text{Corr}(Y_t, Y_{t-k}) = \sqrt{(t-k)/t}$, que depende de t.

1.2. Inciso 0.2: simulación del AR(1)

La función `simular_ar1` genera $200 + 300$ pasos de un AR(1) con $c = 0$ y $\sigma = 1$ a partir de $Y_0 = 0$ y descarta los primeros 200. Con $|\phi| < 1$ el efecto del valor inicial decae como ϕ^t; a los 200 pasos, incluso con $\phi = 0.9$, queda $0.9^{200} \approx 7 \times 10^{-10}$ del valor inicial, así que la serie que se conserva ya está en su distribución estacionaria. Con $\phi = 1$ eso no funciona: la serie conservada es $Y_t = Y_{200} + \sum_{i=201}^{t} \varepsilon_i$, una caminata aleatoria que arranca en Y_{200} en lugar de 0, y la varianza sigue creciendo sin límite. Pero el punto de arranque no afecta a r_k: sumar una constante a toda la serie mueve también a $\bar{y}$ y deja intactas las desviaciones $y_t - \bar{y}$, que son lo único que entra en la fórmula. Por eso descartar o no los 200 pasos no cambia en nada los resultados de r_k para la caminata.

La figura 1 muestra una realización de cada proceso. Con $\phi = 0$ la serie no tiene ninguna inercia; con $\phi = 0.5$ aparecen rachas cortas; con $\phi = 0.9$ la serie pasa decenas de pasos de un mismo lado de cero, aunque siempre regresa; y con $\phi = 1$ nunca regresa: se aleja de su origen (nótese que arranca en $Y_{200} \neq 0$) y lo que en un AR estacionario serían fluctuaciones aquí parece una tendencia.

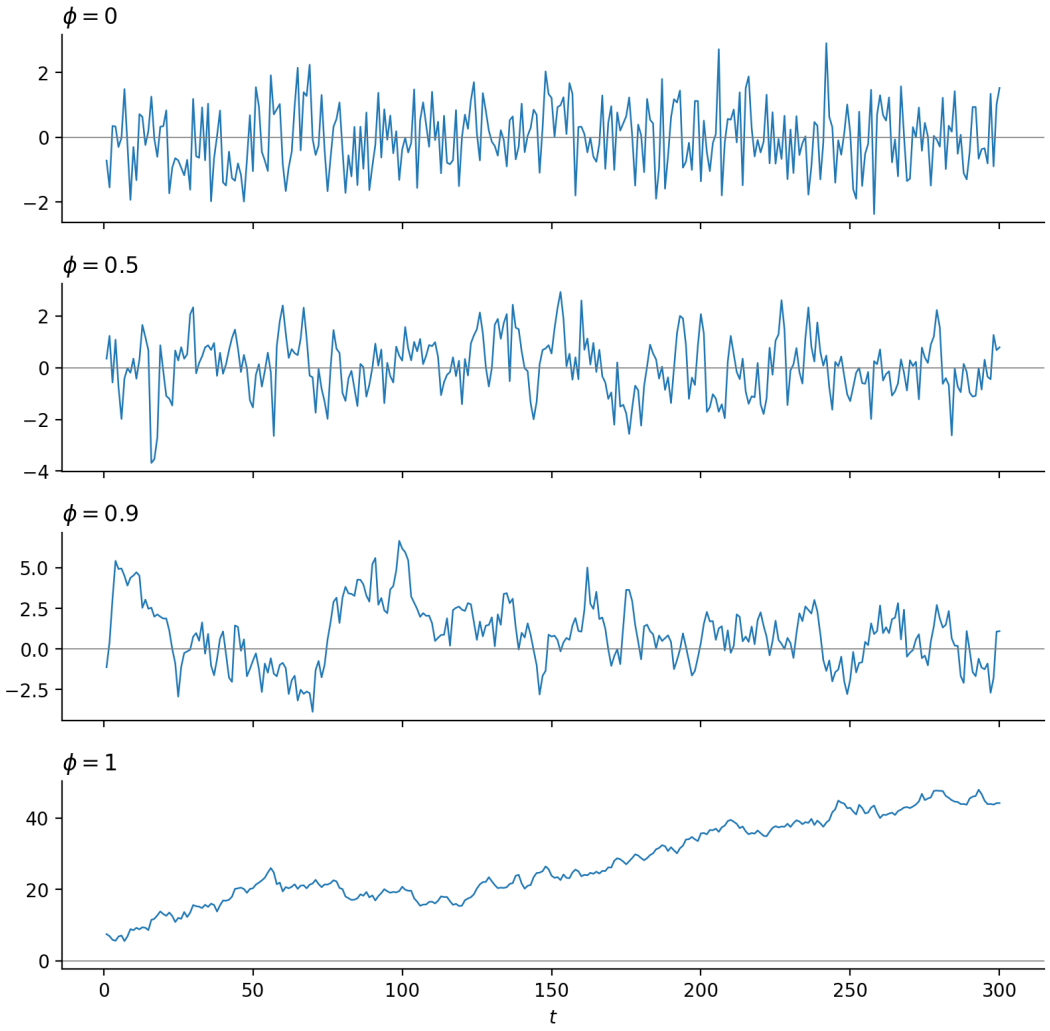


Figura 1: Una realización de 300 pasos de cada AR(1), después de descartar 200 pasos de arranque. La escala vertical cambia entre paneles: la varianza estacionaria $1/(1-\phi^2)$ vale 1, 1.33 y 5.26 para $\phi = 0, 0.5, 0.9$, y no existe para $\phi = 1$.

La tabla 1 resume las 5 000 réplicas por escenario. Cada celda es el promedio sobre réplicas y, entre paréntesis, su error estándar $s/\sqrt{5000}$. La tasa de rechazo es la fracción de réplicas en que $|r_1| > 1.96/\sqrt{300} = 0.113$, es decir, en que la prueba de retardo 1 de la Tarea 2 declara que la serie no es ruido blanco.

ϕ	$\bar{r}_1$	$\bar{r}_5$	ϕ^5	Rechazo $\lvert r_1\rvert > 1.96/\sqrt{n}$	$\bar{\hat{\phi}}_{\text{OLS}}$
0	-0.002 (0.001)	-0.003 (0.001)	0.000	0.046 (0.003)	-0.002 (0.001)
0.5	0.491 (0.001)	0.020 (0.001)	0.031	1.000 (0.000)	0.492 (0.001)
0.9	0.884 (0.000)	0.534 (0.001)	0.590	1.000 (0.000)	0.887 (0.000)
1	0.976 (0.000)	0.883 (0.001)	1.000	1.000 (0.000)	0.982 (0.000)

Tabla 1: AR(1) con $n = 300$ y 5 000 réplicas por valor de ϕ. Promedio (error estándar).

1.3. Inciso 0.3: lo que dice la tabla

Ruido blanco. Con $\phi = 0$ la prueba rechaza en el 4.62 % de las réplicas, con error estándar de 0.30 puntos: está a poco más de un error estándar del 5 % nominal, que es lo esperado. La prueba está construida precisamente para equivocarse un 5 % de las veces cuando la hipótesis nula es cierta, y aquí la nula es cierta por construcción. Que quede un poco por debajo de 5 % tiene además una razón teórica: bajo ruido blanco, $E[r_1] \approx -1/n$ y $\mathrm{Var}(r_1) \approx (n-1)/(n(n+2))$, ligeramente menor que la $1/n$ con que se dibujan las bandas, así que la tasa exacta ronda 4.9 %. El $\bar{r}_1 = -0.0023$ observado también es compatible con $-1/300 = -0.0033$.

Caminata aleatoria. La teoría estacionaria diría $\rho_5 = \phi^5 = 1$, pero el promedio de r_5 es 0.883. No es un error de simulación (el error estándar es 0.001): para una caminata aleatoria la ACF muestral está fuertemente sesgada hacia abajo. La razón es que r_k mide desviaciones respecto a $\bar{y}$, y en una caminata $\bar{y}$ es una media que no representa a ningún tramo de la serie: la serie se pasa largos periodos de un lado y luego del otro. Además el denominador usa los n términos y el numerador solo $n - k$. De hecho, la fórmula $\rho_k = \phi^k$ ni siquiera aplica, porque la derivación del inciso 0.1 supuso estacionariedad. Lo que sí se ve es la huella visual que menciona el enunciado: la ACF de la caminata baja muy despacio ($\bar{r}_1 = 0.976$, $\bar{r}_5 = 0.883$), mientras que con $\phi = 0.5$ el valor ya cayó a casi cero en el rezago 5. Para los procesos estacionarios el sesgo de r_5 también existe pero es menor: con $\phi = 0.9$ se obtiene 0.534 contra $0.9^5 = 0.590$, y con $\phi = 0.5$, 0.020 contra 0.031.

Sesgo del estimado OLS. El estimado OLS de ϕ queda sistemáticamente por debajo del valor verdadero, y el sesgo crece con ϕ: -0.002 para $\phi = 0$, -0.008 para 0.5, -0.013 para 0.9 y -0.018 para 1, todos varias veces mayores que su error estándar. Es el sesgo de Hurwicz: en una autorregresión el regresor y_{t-1} no es independiente de los errores pasados, y la aproximación clásica $E[\hat{\phi}] - \phi \approx -(1+3\phi)/n$ da -0.003, -0.008 y -0.012 para los tres casos estacionarios, muy cerca de lo observado. El estimador es consistente: el sesgo es de orden $1/n$ y desaparece cuando la muestra crece, aunque con 300 observaciones todavía se nota. En la caminata, la teoría de Dickey–Fuller dice que $\hat{\phi}$ converge todavía más rápido (a ritmo $1/n$ en vez de $1/\sqrt{n}$) pero con una distribución asimétrica, cargada hacia valores menores que 1, y eso es lo que se ve en el 0.982.

1.4. Inciso 0.4: las dos razones para reprobar

Ahora $Y_t = m_t + \varepsilon_t$ no tiene ninguna memoria: los ε_t son independientes y m_t es determinista. La figura 2 muestra una realización de cada proceso y la tabla 2 repite la tabla del inciso 0.2 agregando

$\bar{r}_7$; la primera fila es el ruido blanco del inciso anterior, como referencia.

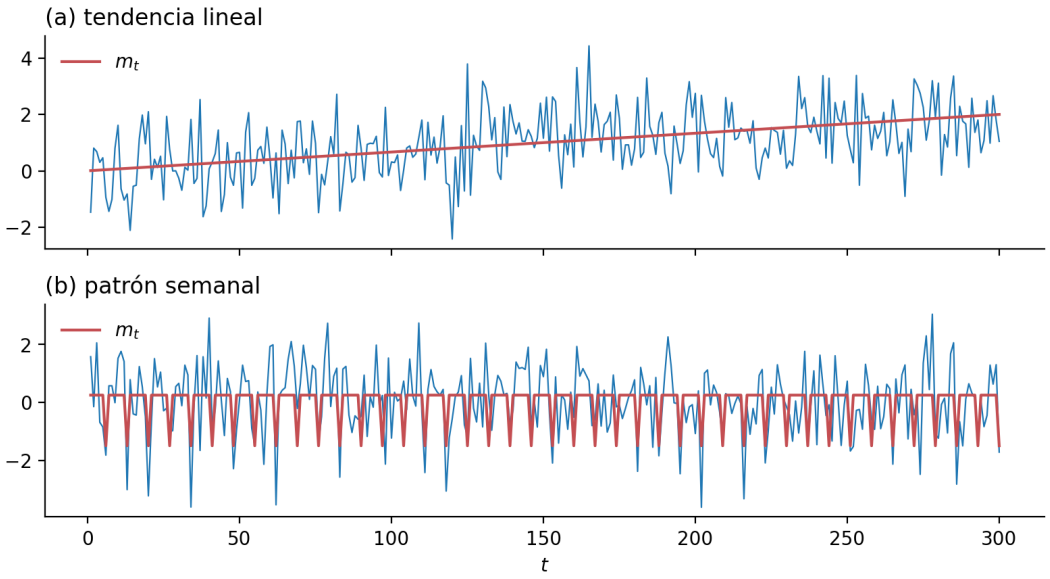


Figura 2: Procesos sin memoria con media variable. En rojo, la media m_t.

Proceso	$\bar{r}_1$	$\bar{r}_5$	$\bar{r}_7$	Rechazo r_1	$\bar{\hat{\phi}}_{\text{OLS}}$
Ruido blanco ($\phi = 0$)	-0.002 (0.001)	-0.003 (0.001)	-0.004 (0.001)	0.046 (0.003)	-0.002 (0.001)
(a) Tendencia	0.246 (0.001)	0.235 (0.001)	0.230 (0.001)	0.986 (0.002)	0.247 (0.001)
(b) Semanal	-0.047 (0.001)	-0.050 (0.001)	0.266 (0.001)	0.112 (0.004)	-0.048 (0.001)

Tabla 2: Procesos sin memoria, $n = 300$, 5 000 réplicas. Promedio (error estándar).

La tendencia reprueba sin tener memoria. La serie con tendencia rechaza la prueba de retardo 1 en el 98.6 % de las réplicas, y el OLS le asigna $\hat{\phi} \approx 0.25$ a un proceso cuyo ϕ verdadero es cero. Se puede predecir el número: m_t recorre $[0, 2]$ de forma casi uniforme, con varianza $\approx 4/12 = 1/3$, y como dos días cercanos tienen casi la misma m_t, la covarianza entre vecinos es esa misma varianza; así $r_k \approx (1/3)/(1/3 + 1) = 0.25$ para todo rezago pequeño. Eso es exactamente lo que dice la tabla: $\bar{r}_1 = 0.246$, $\bar{r}_5 = 0.235$, $\bar{r}_7 = 0.230$, una ACF que casi no decae. Es la razón (2) del enunciado: $\bar{y}$ no es la media de nadie, los días del final quedan todos por encima y los del inicio todos por debajo, y eso se ve como correlación.

El patrón semanal pasa aunque tenga estructura. La serie semanal rechaza solo en el 11.2 % de las réplicas, poco más que el ruido blanco, y su $\bar{r}_1 = -0.047$ es diminuto. De nuevo se puede calcular: sobre un ciclo de 7 días m_t tiene media 0 y varianza $(6 \cdot 0.25^2 + 1.5^2)/7 = 0.375$, pero la covarianza entre días consecutivos es solo $(5 \cdot 0.25^2 - 2 \cdot 0.375)/7 = -0.0625$, y $r_1 \approx -0.0625/1.375 = -0.045$. Toda la estructura está a distancia 7: un domingo se parece al domingo anterior, no al sábado. Por eso $\bar{r}_7 = 0.266$ (la predicción es $0.375/1.375 = 0.273$), mientras que r_1 y r_5 están cerca de cero.

Conexión con RANDU. Es el mismo fenómeno que con RANDU en la Tarea 2: RANDU pasaba las pruebas unidimensionales y de pares consecutivos y, sin embargo, sus ternas caían en solo 15 planos, porque su dependencia vivía en una combinación de los rezagos 1 y 2 que esas pruebas no miran. La prueba de retardo 1 solo puede ver estructura en el rezago 1; un proceso con la dependencia en otro lado (el rezago 7, o una combinación lineal de rezagos) la pasa sin problema. Pasar una prueba nunca demuestra independencia: solo dice que en la dirección que esa prueba mira no se encontró nada.

1.5. Inciso 0.5: la prueba que sí ve

La tabla 3 compara la tasa de rechazo de la prueba de retardo 1 con la de Ljung–Box al 5 %, con $m = 10$ (la recomendación de FPP2 sin estacionalidad) y con $m = 6 \approx \log(300) = 5.7$ (la sugerencia de Tsay). La implementación propia coincide con `statsmodels.stats.diagnostic.acorr_ljungbox` hasta el sexto decimal en el estadístico y en el valor-p; `parte0.py` lo verifica con un `assert` en una réplica de cada proceso.

Proceso	Rechazo r_1	LB $m = 10$	LB $m = 6$
Ruido blanco ($\phi = 0$)	0.046 (0.003)	0.053 (0.003)	0.053 (0.003)
(a) Tendencia	0.986 (0.002)	1.000 (0.000)	1.000 (0.000)
(b) Semanal	0.112 (0.004)	0.956 (0.003)	0.209 (0.006)

Tabla 3: Tasa de rechazo al 5 % sobre 5 000 réplicas, $n = 300$. Promedio (error estándar).

Con ruido blanco las dos versiones de Ljung–Box rechazan alrededor del 5 % (5.3 %), como deben. Con la tendencia rechazan siempre, igual que la prueba de retardo 1: ahí la estructura se ve en todos los rezagos.

El cambio está en el patrón semanal. Ljung–Box con $m = 10$ lo rechaza en el 95.6 % de las réplicas, contra el 11.2 % de la prueba de retardo 1, porque $Q(10)$ suma r_k^2 para $k = 1, \ldots, 10$ y eso incluye el $r_7 \approx 0.27$ que la prueba de retardo 1 no mira; elevado al cuadrado y multiplicado por $n(n+2)/(n-7)$, ese solo término aporta alrededor de 22 al estadístico, cuando el valor crítico de una χ^2_{10} al 5 % es 18.3. En cambio, con $m = 6$ la tasa cae a 20.9 %: seis rezagos no llegan al 7, así que $Q(6)$ es casi tan ciego como la prueba de retardo 1. Esta es la comparación que pedía el enunciado entre las dos reglas para escoger m, y la lección es que m tiene que cubrir al menos el periodo estacional; por eso FPP2 recomienda $m = 2s$ cuando hay estacionalidad. Con datos diarios de una tienda, la regla $m \approx \log n$ por sí sola no es suficiente.

2. Parte 1: limpieza

La limpieza vive en `limpiar.py` y la reproduce `parte1.py`. El archivo se carga con `datos.cargar_crudo()`, que lee `InvoiceNo`, `StockCode` y `CustomerID` como texto. El enunciado sugiere hacerlo y pide averiguar por qué; leyendo el archivo sin indicarle tipos a pandas se ve el problema en cada columna:

- `InvoiceNo` queda como una columna con 532 618 enteros (`536365`) y 9 291 cadenas (`C536379`) revueltos. Entonces `str.startswith('C')` devuelve `NaN`, no `False`, en todas las filas numéricas, y cualquier filtro de cancelaciones construido así falla en silencio.

- `StockCode` mezcla 487 036 códigos numéricos con 54 873 alfanuméricos (`85123A`, `POST`). Una regla sobre el texto del código, como "empieza con cinco dígitos", se salta todas las filas que pandas convirtió en enteros.
- `CustomerID` tiene faltantes, y como una columna entera de pandas no admite `NaN`, se convierte a `float`: `17850.0`. Un identificador no es una cantidad: no se suma ni se promedia, y no debería tener decimales.

2.1. Inciso 1.1: el archivo crudo

Concepto	Valor
Filas	541,909
Facturas distintas	25,900
Productos distintos (StockCode)	4,070
Productos distintos sin distinguir mayúsculas	3,958
Clientes distintos (CustomerID)	4,372
Filas sin CustomerID	135,080 (24.9 %)
Primera factura	2010-12-01 08:26:00
Última factura	2011-12-09 12:50:00

Tabla 4: Tamaño del archivo original, antes de limpiar.

El archivo tiene 541 909 líneas de 25 900 facturas, 4 070 códigos de producto y 4 372 clientes (tabla 4). El 24.9 % de las filas no tiene `CustomerID`. El número de productos depende de cómo se cuente: 117 códigos aparecen también en minúscula (`85123a` junto a `85123A`), y unificándolos quedan 3 958.

2.2. Inciso 1.2: caso por caso

La tabla 5 cuenta cada caso sobre los datos crudos, sin aplicar ninguna otra regla, y resume la decisión. El monto es la suma con signo de `Quantity` × `UnitPrice` de esas filas.

Caso	Filas	Monto neto (£)	Decisión
(a) Duplicados exactos	5,268	21,740.98	Se va
(b) Facturas con prefijo C	9,288	-896,812.49	Se queda (resta)
(b) Facturas con prefijo A	3	-11,062.06	Se va
(c) Códigos que no son productos	2,297	29,406.91	Se va
(c) Códigos en minúscula	1,943	30,702.15	Se transforma
(d) Precio negativo	2	-22,124.12	Se va
(d) Precio cero	2,515	0.00	Se va
(e) Cantidad negativa sin ser cancelación	1,336	0.00	Se va
(f) Sin CustomerID	135,080	1,447,682.12	Serie: se queda; RFM: se va

Tabla 5: Casos del inciso 1.2 sobre los datos crudos. Un caso puede traslapar con otro; el efecto conjunto está en la bitácora (tabla 7).

(a) Duplicados exactos: se van. Hay 5 268 filas idénticas en las ocho columnas a otra fila anterior: misma factura, mismo producto, misma cantidad y mismo minuto. Una factura que de

verdad incluyera dos veces el mismo artículo lo registraría como una línea con la cantidad sumada; dos líneas idénticas son una doble captura. Se conserva la primera. Representan £21 741.

(b) Facturas que no empiezan con un dígito. Hay dos prefijos. El `C` marca 9 288 cancelaciones, todas con cantidad negativa: *se quedan*, porque la venta neta diaria las define como líneas que restan el día en que ocurren. El `A` aparece en tres facturas del 12 de agosto de 2011 con el código `B`, "Adjust bad debt", por +11 062 y dos veces −11 062 libras: *se van*, porque son asientos contables de deuda incobrable, no ventas ni devoluciones de mercancía.

(c) Códigos que no son productos. La tabla 6 lista todos los códigos que no empiezan con cinco dígitos. No todos son iguales:

- *Se van* los cargos que no son mercancía: envío (`POST`, `DOT`, `C2`), comisiones (`AMAZONFEE`, `CRUK`), cargos bancarios, muestras (`S`), el ajuste de deuda `B` y los vales de regalo `gift_0001_*`, que son dinero adelantado y se contarían dos veces cuando se canjearan. El caso que más pesa es `AMAZONFEE`: 32 de sus 34 filas son "cancelaciones" de hasta £17 836, que en realidad son la comisión que cobra Amazon. Dejarlas habría restado £221 521 de ventas que nunca se devolvieron.
- *Se quedan* los `DCGS...` (artículos de la tienda *dotcom*, como bolsas de fiesta o collares) y `PADS`, que sí son productos aunque su código no tenga cinco dígitos.
- *Se quedan* también `D` (descuento) y `M` (ajuste manual). No son productos, pero corrigen el precio de mercancía que sí se vendió: un descuento reduce lo que la tienda cobró. El inciso 1.4 muestra qué pasa si se quitan: la factura 556444 cobró por error 60 canastas a £649.50 cada una, y la corrección es la línea `M` de la cancelación C556445. Si se quitaran las `M`, la serie se quedaría con una venta fantasma de £38 970.
- *Se transforman* los 117 códigos en minúscula, que se pasan a mayúscula.

StockCode	Filas	Monto neto (£)	Descripción	% cancelación	Decisión
POST	1,256	66,230.64	POSTAGE	10	Se va
DOT	710	206,245.48	DOTCOM POSTAGE	0	Se va
M	571	-68,674.19	Manual	43	Se queda
C2	144	6,986.00	CARRIAGE	1	Se va
D	77	-5,696.22	Discount	100	Se queda
S	63	-3,049.39	SAMPLES	97	Se va
DCGS...	45	398.45	SUNJAR LED NIGHT NIGHT LIGHT	0	Se queda
BANK CHARGES	37	-7,175.64	Bank Charges	68	Se va
AMAZONFEE	34	-221,520.50	AMAZON FEE	94	Se va
gift_0001_...	34	685.81	Dotcomgiftshop Gift Voucher £40.	0	Se va
CRUK	16	-7,933.43	CRUK Commission	100	Se va
PADS	4	0.00	PADS TO MATCH ALL CUSHIONS	0	Se queda
B	3	-11,062.06	Adjust bad debt	0	Se va
m	1	2.55	Manual	0	Se queda

Tabla 6: Códigos que no empiezan con cinco dígitos, en los datos crudos. La columna de cancelación es el porcentaje de sus filas en facturas `C`.

(d) Precios iguales a cero o negativos: se van. Los dos precios negativos son las líneas de deuda incobrable del caso (b). Los 2 515 precios en cero no aportan nada a la venta (su monto es exactamente cero), y casi todos son movimientos de inventario sin cliente: 1 336 tienen cantidad negativa (caso e) y, de las que tienen cantidad positiva, solo 40 tienen cliente, probablemente obsequios. Para la serie da igual quitarlos o no; se quitan para que no inflen la frecuencia de compra en la Parte 6.

(e) Cantidades negativas que no son cancelaciones: se van. Son 1 336 filas, todas con precio cero y ninguna con cliente. Su descripción lo explica: vacía (862), "check" (123), "damaged" o "damages" (103), "?" (41), "sold as set on dotcom", "thrown away", "wet damaged", "missing"... Son ajustes de inventario por mercancía dañada, perdida o reetiquetada, no devoluciones de clientes.

(f) Filas sin `CustomerID`: depende. Para la serie de ventas *se quedan*: una venta sin cliente identificado sigue siendo dinero que entró a la tienda. Después de la limpieza son el 24.8 % de las filas y el 15.4 % de la venta neta (£1.50 millones), casi todas del Reino Unido; quitarlas bajaría el nivel de la serie y, si su peso cambia con el tiempo, también su forma. Para la Parte 6 *se van*, porque el RFM necesita saber quién compró. Por eso `limpiar` tiene el argumento `requiere_cliente`.

2.3. Inciso 1.3: bitácora de limpieza

Las reglas se aplican en el orden de la tabla 7. La columna "Sola" cuenta las filas que la regla quitaría aplicada sobre los datos crudos; "En orden" cuenta las que realmente quita después de las anteriores. El monto corresponde a las filas que quita en orden: el neto es la suma con signo y el absoluto, la suma de $|\texttt{Quantity} \times \texttt{UnitPrice}|$. La regla 6 solo se aplica para la Parte 6.

Orden	Regla	Sola	En orden	Monto neto (£)	Monto absoluto (£)
1	Duplicados exactos	5,268	5,268	21,740.98	27,406.50
2	Facturas con prefijo A (ajuste de deuda)	3	3	-11,062.06	33,186.18
3	Códigos que no son productos	2,297	2,293	40,478.71	571,674.49
4	Precio igual a cero o negativo	2,517	2,499	0.00	0.00
5	Cantidad negativa sin ser cancelación	1,336	0	0.00	0.00
6	Sin CustomerID	135,080	131,656	1,495,555.05	1,573,094.09
	Total		141,719	1,546,712.68	2,205,361.26

Tabla 7: Bitácora de limpieza, en el orden en que se aplican las reglas.

El orden sí cambia los conteos. La regla 5 no quita ninguna fila en orden, pero aplicada sola quitaría 1 336: todas las cantidades negativas sin cancelación tienen precio cero, así que la regla 4 ya las eliminó. Si el orden fuera el inverso, la regla 5 se llevaría 1 336 filas y la 4, 1 336 menos. Del mismo modo, la regla 3 quita 2 293 filas y no 2 297 porque las tres líneas `B` ya cayeron con el prefijo `A` y una más era duplicado; y la regla 4 quita 2 499 y no 2 517 porque los dos precios negativos ya cayeron con el prefijo `A`, cinco eran duplicados y once tenían un código que no es producto. Ninguna de estas diferencias cambia el resultado final: las reglas solo deciden a qué renglón de la bitácora se le atribuye cada fila.

Para la serie de ventas (reglas 1 a 5) quedan 531 846 filas con una venta neta total de £9 696 590; 8 989 de esas filas son cancelaciones que suman −£628 382. Para el RFM (reglas 1 a 6) quedan 400 190 filas.

2.4. Inciso 1.4: las seis líneas más grandes

La tabla 8 muestra las seis líneas con mayor $|\texttt{Quantity} \times \texttt{UnitPrice}|$ en los datos crudos. Son tres pares venta–cancelación.

Factura	Fecha	Cliente	Producto	Cantidad	Precio	Monto (£)	¿Sobrevive?
C581484	09/12/2011 09:27	16446	Paper Craft , Little Birdie	-80,995	2.08	-168,469.60	Sí
581483	09/12/2011 09:15	16446	Paper Craft , Little Birdie	80,995	2.08	168,469.60	Sí
C541433	18/01/2011 10:17	12346	Medium Ceramic Top Storage Jar	-74,215	1.04	-77,183.60	Sí
541431	18/01/2011 10:01	12346	Medium Ceramic Top Storage Jar	74,215	1.04	77,183.60	Sí
C556445	10/06/2011 15:31	15098	Manual	-1	38,970.00	-38,970.00	Sí
556444	10/06/2011 15:28	15098	Picnic Basket Wicker 60 Pieces	60	649.50	38,970.00	Sí

Tabla 8: Las seis líneas con mayor monto absoluto antes de limpiar. "¿Sobrevive?" indica si la línea sigue en los datos limpios.

- **Paper Craft, Little Birdie (cliente 16446).** El 9 de diciembre de 2011 a las 9:15 la factura 581483 vende 80 995 unidades a £2.08, £168 470 en una sola línea, y doce minutos después la C581484 la cancela completa. El cliente solo tiene otra compra en todo el año: dos artículos por £2.90 en mayo. Es casi seguro un error de captura, corregido de inmediato.
- **Medium Ceramic Top Storage Jar (cliente 12346).** El 18 de enero de 2011 la factura 541431 vende 74 215 frascos a £1.04 (£77 184), y dieciséis minutos después la C541433 la cancela. Es la única actividad del cliente en todo el archivo, así que su venta neta total es cero; vuelve a aparecer en la Parte 6 como un cliente con $M \leq 0$.
- **Picnic Basket Wicker 60 Pieces (cliente 15098).** El 10 de junio de 2011 la secuencia completa es: 556442 vende 60 canastas pequeñas a £4.95 (£297); 556444 cobra 60 unidades a £649.50, que es el precio del juego de 60 piezas, no de una canasta (£38 970); C556445 lo corrige con una línea `Manual` de −£38 970; 556446 cobra el juego correcto, una unidad a £649.50; y C556448 cancela las canastas pequeñas. Lo que el cliente compró en realidad fue un juego de £649.50.

¿Las resuelve la limpieza? No: las seis sobreviven, y está bien que sobrevivan. Ninguna regla las identifica como errores (son productos reales, con precio positivo y con cliente), y quitar una sola mitad del par sería peor que dejar las dos. Si una regla quitara la venta de 80 995 unidades por "atípica", la cancelación quedaría huérfana y restaría £168 470 ese día. Por la misma razón la regla de códigos no quita la línea `M`: quitarla dejaría la venta de £38 970.

¿Las resuelve el neteo por día? Sí, porque en los tres casos la venta y su corrección ocurren el mismo día, con minutos de diferencia. En la venta neta del 18 de enero el par del frasco suma exactamente cero; la del 10 de junio recibe del cliente 15098 exactamente los £649.50 que compró; y el par del 9 de diciembre suma cero (además, la Parte 2 descarta ese día por incompleto). La serie diaria es inmune a estos errores siempre que se corrijan el mismo día. Un análisis por cliente o por factura no lo es: en la Parte 6 cada una de estas facturas cuenta como una compra para la frecuencia, aunque el monto neto sea cero.

3. Parte 2: el calendario

La serie se construye en `calendario.py`: se suma $\texttt{Quantity} \times \texttt{UnitPrice}$ por día sobre los datos de `limpiar(df)` (reglas 1 a 5, con cancelaciones restando y con las ventas sin cliente) y se lleva al

calendario completo. Las tablas y figuras de esta sección las genera `parte2.py`.

3.1. Inciso 2.1: la serie de venta neta diaria

Concepto	Días
Días calendario (1/12/2010 al 9/12/2011)	374
Días con al menos una transacción	305
Días sin transacciones	69
sábados	53
cierre de Navidad (sin sábados)	9
feriados de 2011	7

Tabla 9: Días calendario y días con transacciones.

Entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011, contando ambos, hay 374 días calendario, y en 305 hubo al menos una transacción (tabla 9). Es decir, en 69 días (el 18 %) la tienda no registró nada. La figura 3 muestra la serie en los días abiertos. Los cierres entre semana están marcados con una cruz sobre el eje; los sábados no se marcan porque ocurren todas las semanas.

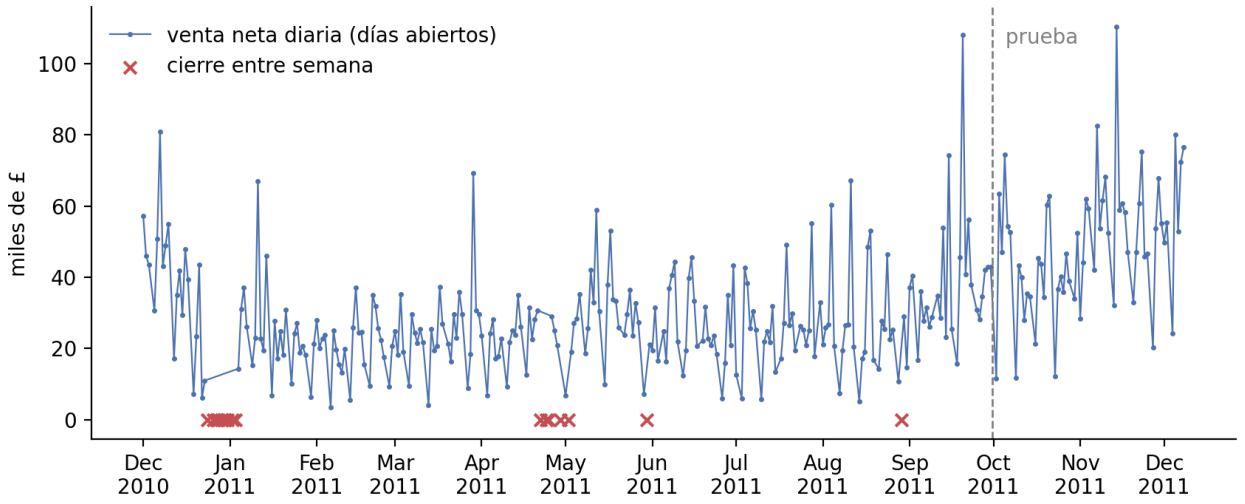


Figura 3: Venta neta diaria en los días abiertos, del 1 de diciembre de 2010 al 8 de diciembre de 2011. La línea une días abiertos consecutivos, así que salta por encima de los sábados y de los cierres. La línea punteada separa el entrenamiento (hasta el 30 de septiembre) de la prueba.

La figura ya anticipa lo que se va a modelar en las siguientes partes: un nivel de alrededor de £20–30 mil diarios entre enero y agosto, un crecimiento fuerte desde septiembre (la temporada navideña de una tienda de regalos que vende a mayoristas) y mucha variación de un día a otro, con picos aislados de más de £100 mil.

3.2. Inciso 2.2: los días sin transacciones

Los sábados. 53 de los 69 días faltantes son sábados: *todos* los sábados del periodo. No hay ni una sola transacción en sábado en todo el año, así que la tienda no abre ese día. En cambio sí abre

los domingos.

Los otros 16. La tabla 10 los lista y los clasifica usando el calendario de *bank holidays* de Inglaterra y Gales.

Fecha	Día	Tipo	Motivo
24/12/2010	viernes	Cierre de Navidad	Nochebuena
26/12/2010	domingo	Cierre de Navidad	Boxing Day (domingo)
27/12/2010	lunes	Cierre de Navidad	Feriado: traslado de Navidad
28/12/2010	martes	Cierre de Navidad	Feriado: traslado de Boxing Day
29/12/2010	miércoles	Cierre de Navidad	Entre Navidad y Año Nuevo
30/12/2010	jueves	Cierre de Navidad	Entre Navidad y Año Nuevo
31/12/2010	viernes	Cierre de Navidad	Fin de año
02/01/2011	domingo	Cierre de Navidad	Domingo antes del traslado
03/01/2011	lunes	Cierre de Navidad	Feriado: traslado de Año Nuevo
22/04/2011	viernes	Feriado móvil (Pascua)	Viernes Santo
24/04/2011	domingo	Feriado móvil (Pascua)	Domingo de Pascua
25/04/2011	lunes	Feriado móvil (Pascua)	Lunes de Pascua
29/04/2011	viernes	Feriado único	Boda real (Guillermo y Catalina)
02/05/2011	lunes	Feriado de lunes	Early May bank holiday
30/05/2011	lunes	Feriado de lunes	Spring bank holiday
29/08/2011	lunes	Feriado de lunes	Summer bank holiday

Tabla 10: Días entre semana (sin contar sábados) sin ninguna transacción.

- **Cierre de Navidad: 9 días**, del viernes 24 de diciembre de 2010 al lunes 3 de enero de 2011. En 2010 Navidad cayó en sábado y el *Boxing Day* en domingo, así que los feriados oficiales se trasladaron al lunes 27 y al martes 28; Año Nuevo de 2011 cayó en sábado y se trasladó al lunes 3 de enero. Los días que quedan en medio (29, 30 y 31 de diciembre y el domingo 2 de enero) no son feriados oficiales: la tienda simplemente cerró entre fiestas, algo común en un negocio que le vende a otros negocios.
- **Pascua: 3 días**, el Viernes Santo (22 de abril), el Domingo de Pascua (24 de abril) y el Lunes de Pascua (25 de abril). El domingo no es feriado oficial, pero la tienda, que sí abre otros domingos, no abrió entre los dos feriados.
- **La boda real: 1 día**, el viernes 29 de abril de 2011, el matrimonio del príncipe Guillermo con Catalina Middleton. Es el feriado que no se repite: el gobierno lo declaró solo para ese año.
- **Feriados de lunes: 3 días**, el *Early May bank holiday* (2 de mayo), el *Spring bank holiday* (30 de mayo) y el *Summer bank holiday* (29 de agosto).

Todos los feriados oficiales del periodo aparecen como días sin ventas, y fuera de los sábados no falta ningún otro día: no hay caídas del sistema ni días perdidos sin explicación.

¿Cuáles son móviles? Los de Pascua. La Pascua cae el primer domingo después de la primera luna llena de primavera, así que el Viernes Santo puede caer en cualquier fecha entre el 20 de marzo y el 23 de abril, y el Lunes de Pascua tres días después: de un año a otro se mueven hasta cinco semanas. Por eso FPP2 dice que son de lo más difícil de modelar con datos diarios: un modelo con

estacionalidad de 7 días o de 365 días no los puede anticipar, porque no caen a una distancia fija de nada. Los tres feriados de lunes también cambian de fecha de un año a otro, pero siguen una regla de calendario sencilla (primer o último lunes del mes), siempre caen en lunes y se conocen con años de anticipación. La Navidad tiene fecha fija, pero el día de la semana cambia y con él los traslados, como pasó en 2010. La boda real no se puede modelar con ningún patrón, porque solo ocurrió una vez.

3.3. Inciso 2.3: ¿cero o faltante?

Un día sin transacciones puede ser cualquiera de las dos cosas; depende de para qué se use la serie.

Cuándo es un cero. Cuando la pregunta es contable, como cuánto vendió la tienda en una semana o en un mes, o cuál es la venta promedio por día calendario. El sábado la caja recibió exactamente cero libras, y sumar la serie con ceros da el total correcto. Es el uso de la media móvil del inciso 3.1, donde el enunciado pide rellenar con cero: una semana con un feriado sí vendió menos que una semana normal, y la tendencia debe reflejarlo.

Cuándo es un faltante. Cuando se modela el comportamiento de la tienda en los días en que opera: los índices estacionales, la ACF, los modelos AR y SARIMA y la evaluación del pronóstico. Ahí un cero de sábado no es una observación de "un día malo": no hubo ningún día que observar. Si se deja como cero, el índice estacional del sábado sería cero (algo que ya se sabe y no hay que estimar); la media de la serie bajaría un 18 % (69 de 374 días); aparecería un r_7 enorme que no viene de la demanda sino del calendario; y un pronóstico que acierte "cero" cada sábado se vería artificialmente bueno. Por eso, de aquí en adelante, la serie tiene los días cerrados como faltantes y los modelos trabajan con una fila por día abierto.

3.4. Inciso 2.4: el último día

El 9 de diciembre de 2011 no está completo. Su última factura es de las 12:50 y suma £29 306 en 49 facturas, cuando un viernes de noviembre o diciembre vende una mediana de £52 410. Ningún día anterior del año registró su última factura antes de las 12:50: los datos se cortaron a mediodía, probablemente cuando se extrajo el archivo.

Se puede medir qué tan incompleto está. Para cada viernes anterior se calculó qué fracción de sus ventas se había registrado a las 12:50 (figura 4). La mediana es 54 %, así que el 9 de diciembre completo habría vendido alrededor de $29\,306/0.54 \approx$ £54 200, en línea con los viernes anteriores. Es decir, al día le falta casi la mitad.

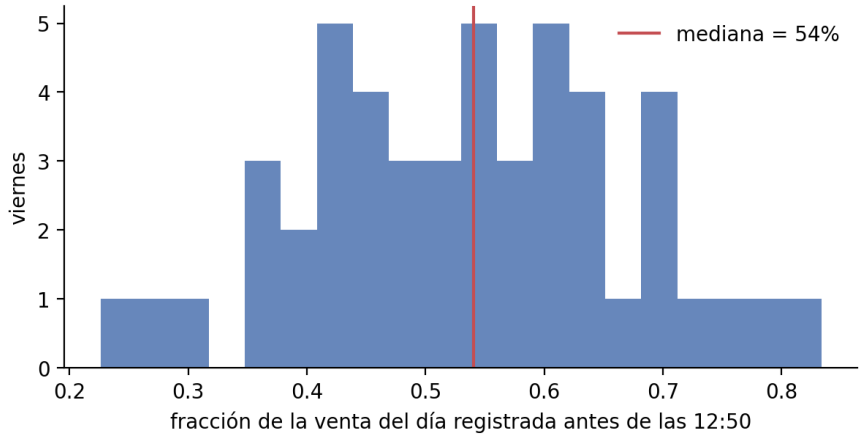


Figura 4: Fracción de la venta bruta de cada viernes registrada antes de las 12:50, la hora de la última factura del 9 de diciembre.

Se descarta. Dejarlo metería en el último punto de la serie una caída artificial a la mitad, justo en el día que más pesa al pronosticar, y es también el día del par venta–cancelación de £168 470 del inciso 1.4. Escalarlo por 1/0.54 inventaría un dato con un supuesto sobre el reparto de las ventas en el día. Como es el último día y no hay nada que interpolar, quitarlo no le cuesta nada a la serie. La serie de trabajo termina el jueves 8 de diciembre de 2011.

Referencias

[1] D. Chen. *Online Retail* [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`

[2] D. Chen, S. L. Sain y K. Guo. "Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining". *Journal of Database Marketing & Customer Strategy Management* 19.3 (2012), pp. 197–208.

[3] R. J. Hyndman y G. Athanasopoulos. *Forecasting: Principles and Practice*, 2a ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`

[4] R. S. Tsay. *Analysis of Financial Time Series*, 2a ed. Wiley, 2005.